

Agentes Inteligentes

Franz Mayr


`mayr@ort.edu.uy`

Universidad ORT Uruguay

14 de marzo de 2026

2. Bandidos de k brazos

Máquina tragamonedas (*bandido*)



Al accionar la palanca, una máquina tragamonedas paga una **recompensa** numérica (ej.: \$0, \$5) según una función **estocástica** que podemos suponer **estacionaria** (que no varía en el tiempo).

Bandidos de k brazos



Bandidos de k brazos



- **Acción:** elegir una palanca (o *brazo*) entre k posibles.

Bandidos de k brazos



- **Acción:** elegir una palanca (o *brazo*) entre k posibles.
- Cada palanca otorga una **recompensa** numérica, según su propia distribución de probabilidad.
- Todas las distribuciones son **estacionarias** (no varían en el tiempo) y **desconocidas**.
- Cada acción es **independiente** de las anteriores.

Bandidos de k brazos



- ▶ **Acción:** elegir una palanca (o *brazo*) entre k posibles.
- ▶ Cada palanca otorga una **recompensa** numérica, según su propia distribución de probabilidad.
- ▶ Todas las distribuciones son **estacionarias** (no varían en el tiempo) y **desconocidas**.
- ▶ Cada acción es **independiente** de las anteriores.
- ▶ **Objetivo:** Maximizar las recompensas acumuladas sobre cierto período de tiempo.

Bandidos de k brazos

Sea A_t la acción elegida en el tiempo t , con recompensa R_t .

Bandidos de k brazos

Sea A_t la acción elegida en el tiempo t , con recompensa R_t .

El **valor** de una acción $a \in \mathcal{A}$ se define como:

$$q_*(a) \doteq \mathbb{E}[R_t \mid A_t = a]$$

Bandidos de k brazos

Sea A_t la acción elegida en el tiempo t , con recompensa R_t .

El **valor** de una acción $a \in \mathcal{A}$ se define como:

$$q_*(a) \doteq \mathbb{E}[R_t \mid A_t = a]$$

$Q_t(a)$ es una **estimación** de $q_*(a)$ en el instante de tiempo t .

Bandidos de k brazos

Sea A_t la acción elegida en el tiempo t , con recompensa R_t .

El **valor** de una acción $a \in \mathcal{A}$ se define como:

$$q_*(a) \doteq \mathbb{E}[R_t \mid A_t = a]$$

$Q_t(a)$ es una **estimación** de $q_*(a)$ en el instante de tiempo t .

En el instante t , llamamos acción **greedy** a una acción a que tiene máximo valor estimado $Q_t(a)$. (OBSERVACIÓN: Puede haber más de una acción greedy.)

Bandidos de k brazos

Sea A_t la acción elegida en el tiempo t , con recompensa R_t .

El **valor** de una acción $a \in \mathcal{A}$ se define como:

$$q_*(a) \doteq \mathbb{E}[R_t \mid A_t = a]$$

$Q_t(a)$ es una **estimación** de $q_*(a)$ en el instante de tiempo t .

En el instante t , llamamos acción **greedy** a una acción a que tiene máximo valor estimado $Q_t(a)$. (OBSERVACIÓN: Puede haber más de una acción greedy.)

- **Explotación**: Elegir una acción greedy.
- **Exploración**: Elegir otra acción.

En el Aprendizaje Reforzado es importante buscar un **balance entre exploración y explotación**. Con la metáfora de los bandidos de k brazos podemos estudiarlo de manera simple.

Métodos action-value

Los **métodos action-value** estiman $Q_t(a)$ y usan esas estimaciones para seleccionar las acciones a ejecutar.

Métodos action-value

Los **métodos action-value** estiman $Q_t(a)$ y usan esas estimaciones para seleccionar las acciones a ejecutar.

La forma más sencilla de computar la estimación $Q_t(a)$ es calcular el **promedio de recompensas** obtenidas al seguir la acción a :

Métodos action-value

Los **métodos action-value** estiman $Q_t(a)$ y usan esas estimaciones para seleccionar las acciones a ejecutar.

La forma más sencilla de computar la estimación $Q_t(a)$ es calcular el **promedio de recompensas** obtenidas al seguir la acción a :

$$\begin{aligned} Q_t(a) &\doteq \frac{\text{suma de recompensas al tomar } a \text{ antes de } t}{\text{cantidad de veces que se tomó } a \text{ antes de } t} \\ &= \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{1}_{A_i=a}}{\sum_{i=1}^{t-1} \mathbb{1}_{A_i=a}} \end{aligned}$$

(o bien 0 si el denominador es 0)

Métodos action-value

Los **métodos action-value** estiman $Q_t(a)$ y usan esas estimaciones para seleccionar las acciones a ejecutar.

La forma más sencilla de computar la estimación $Q_t(a)$ es calcular el **promedio de recompensas** obtenidas al seguir la acción a :

$$\begin{aligned} Q_t(a) &\doteq \frac{\text{suma de recompensas al tomar } a \text{ antes de } t}{\text{cantidad de veces que se tomó } a \text{ antes de } t} \\ &= \frac{\sum_{i=1}^{t-1} R_i \cdot \mathbb{1}_{A_i=a}}{\sum_{i=1}^{t-1} \mathbb{1}_{A_i=a}} \end{aligned}$$

(o bien 0 si el denominador es 0)

OBSERVACIÓN: A medida que crece el denominador, $Q_t(a)$ converge a $q_*(a)$, gracias a la ley de los grandes números.

Métodos action-value

Si ya computamos $Q_t(a)$ para todas las acciones disponibles, podemos usarla para seleccionar una acción **greedy**:

$$A_t \doteq \arg \max_a Q_t(a)$$

(con desempate aleatorio)

Métodos action-value

Si ya computamos $Q_t(a)$ para todas las acciones disponibles, podemos usarla para seleccionar una acción **greedy**:

$$A_t \doteq \arg \max_a Q_t(a)$$

(con desempate aleatorio)


Otra forma de usar $Q_t(a)$ para elegir una acción:

- ▶ Con probabilidad ε (baja), se elige una acción al azar.
- ▶ Con probabilidad $1 - \varepsilon$, se elige una acción greedy.

A este método se lo conoce como **ε -greedy**.

Ejemplo: 10-armed bandits

Simulación de bandidos de k brazos ($k = 10$). Los valores $q_*(a)$ de las acciones $a = 1, \dots, 10$ se muestran a continuación:




Ejemplo: 10-armed bandits

Una ejecución = Aplicación durante 1000 instantes de tiempo de un método de aprendizaje ε -greedy.

Ejemplo: 10-armed bandits

Una ejecución = Aplicación durante 1000 instantes de tiempo de un método de aprendizaje ϵ -greedy.


Evolución de la recompensa obtenida en cada instante, promediada sobre 2000 ejecuciones:



Ejemplo: 10-armed bandits

Una ejecución = Aplicación durante 1000 instantes de tiempo de un método de aprendizaje ε -greedy.

Evolución del porcentaje de elecciones óptimas, promediado sobre 2000 ejecuciones:



Implementación incremental

$$\begin{aligned}Q_{n+1} &= \frac{1}{n} \sum_{i=1}^n R_i \\&= \frac{1}{n} \left(R_n + \sum_{i=1}^{n-1} R_i \right) \\&= \frac{1}{n} \left(R_n + (n-1) \frac{1}{n-1} \sum_{i=1}^{n-1} R_i \right) \\&= \frac{1}{n} \left(R_n + (n-1) Q_n \right) \\&= \frac{1}{n} \left(R_n + n Q_n - Q_n \right) \\&= Q_n + \frac{1}{n} \left[R_n - Q_n \right]\end{aligned}$$

(para $n = 1$: $Q_2 = R_1$ con Q_1 arbitrario)

Esto requiere almacenar sólo Q_n y n en memoria, y la actualización luego de tomar cada acción es $O(1)$. Mucho mejor que almacenar todas las recompensas.

Bandidos de k brazos: Algoritmo

Inicializar, para cada $a = 1 \dots k$:

$$Q(a) \leftarrow 0$$

$$N(a) \leftarrow 0$$

Repetir:

$$A \leftarrow \begin{cases} \text{una acción al azar} & \text{con probabilidad } \varepsilon \\ \arg \max_a Q(a) & \text{con probabilidad } 1 - \varepsilon \end{cases}$$

$$R \leftarrow \text{bandido}(A)$$

$$N(A) \leftarrow N(A) + 1$$

$$Q(A) \leftarrow Q(A) + \frac{1}{N(A)} [R - Q(A)]$$

(Si hay empate en el caso greedy $(1 - \varepsilon)$, se desempata al azar.)

Actualización de estimaciones

$$Q_{n+1} = Q_n + \frac{1}{n} [R_n - Q_n]$$

Actualización de estimaciones

$$Q_{n+1} = Q_n + \frac{1}{n} [R_n - Q_n]$$

Esta forma de actualizar estimaciones es frecuente en el Aprendizaje Reforzado:

$$NuevaEst = ViejaEst + TasaAct [Objetivo - ViejaEst]$$

Actualización de estimaciones

$$Q_{n+1} = Q_n + \frac{1}{n} [R_n - Q_n]$$

Esta forma de actualizar estimaciones es frecuente en el Aprendizaje Reforzado:

$$NuevaEst = ViejaEst + TasaAct [Objetivo - ViejaEst]$$

donde:

- ▶ *ViejaEst* y *NuevaEst* son las estimaciones vieja y nueva.
- ▶ *TasaAct* es una **tasa de actualización**; suele denotarse α .
- ▶ $[Objetivo - ViejaEst]$ se denomina **error de estimación**.

Problemas no estacionarios

El método visto es efectivo para problemas **estacionarios**, en los cuales los **valores** de las acciones **no varían** en el tiempo.

Para problemas **no estacionarios** (el caso más realista), tiene sentido dar mayor peso a recompensas **recientes** al actualizar nuestras estimaciones.

Problemas no estacionarios

El método visto es efectivo para problemas **estacionarios**, en los cuales los **valores** de las acciones **no varían** en el tiempo.

Para problemas **no estacionarios** (el caso más realista), tiene sentido dar mayor peso a recompensas **recientes** al actualizar nuestras estimaciones.

Por ejemplo, puede usarse una tasa $\alpha \in (0, 1]$ constante:

$$\begin{aligned} Q_{n+1} &\doteq Q_n + \alpha [R_n - Q_n] \\ &= (1 - \alpha)^n Q_1 + \sum_{i=1}^n \alpha (1 - \alpha)^{n-i} R_i \end{aligned}$$

(ver próxima página)

Q_{n+1} es el **promedio ponderado de recompensas pasadas**.

Problemas no estacionarios

El método visto es efectivo para problemas **estacionarios**, en los cuales los **valores** de las acciones **no varían** en el tiempo.

Para problemas **no estacionarios** (el caso más realista), tiene sentido dar mayor peso a recompensas **recientes** al actualizar nuestras estimaciones.

Por ejemplo, puede usarse una tasa $\alpha \in (0, 1]$ constante:

$$\begin{aligned} Q_{n+1} &\doteq Q_n + \alpha [R_n - Q_n] \\ &= (1 - \alpha)^n Q_1 + \sum_{i=1}^n \alpha (1 - \alpha)^{n-i} R_i \end{aligned}$$

(ver próxima página)

Q_{n+1} es el **promedio ponderado de recompensas pasadas**.

OBSERVACIÓN: Como $1 - \alpha < 1$, entonces $(1 - \alpha)^{n-i}$ decrece exponencialmente cuando $i \rightarrow 0$ (EJERCICIO: probarlo).

Problemas no estacionarios

$$\begin{aligned}Q_{n+1} &\doteq Q_n + \alpha \left[R_n - Q_n \right] \\&= \alpha R_n + (1 - \alpha) Q_n \\&= \alpha R_n + (1 - \alpha) \left[\alpha R_{n-1} + (1 - \alpha) Q_{n-1} \right] \\&= \alpha R_n + (1 - \alpha) \alpha R_{n-1} + (1 - \alpha)^2 Q_{n-1} \\&= \alpha R_n + (1 - \alpha) \alpha R_{n-1} + (1 - \alpha)^2 \alpha R_{n-2} + \\&\quad \dots + (1 - \alpha)^{n-1} \alpha R_1 + (1 - \alpha)^n Q_1 \\&= (1 - \alpha)^n Q_1 + \sum_{i=1}^n \alpha (1 - \alpha)^{n-i} R_i\end{aligned}$$

Valores iniciales optimistas


Los **valores iniciales** de las acciones (es decir, $Q_1(a)$) pueden usarse para guiar o alentar la exploración inicial.

Volviendo al ejemplo, con Q_1 muy alto para todas las acciones, forzamos la **exploración de todas las acciones** al menos una vez.

Valores iniciales optimistas

Los **valores iniciales** de las acciones (es decir, $Q_1(a)$) pueden usarse para guiar o alentar la exploración inicial.


Volviendo al ejemplo, con Q_1 muy alto para todas las acciones, forzamos la **exploración de todas las acciones** al menos una vez.



Valores iniciales optimistas

Los **valores iniciales** de las acciones (es decir, $Q_1(a)$) pueden usarse para guiar o alentar la exploración inicial.

Volviendo al ejemplo, con Q_1 muy alto para todas las acciones, forzamos la **exploración de todas las acciones** al menos una vez.



EJERCICIO: El pico al principio de la curva azul no es ruido del azar (recordar que cada curva promedia 2000 ejecuciones). ¿A qué se debe?

Métodos Upper-Confidence-Bound (UCB)

En los métodos ε -greedy, la elección aleatoria de acciones se hace sin ningún criterio. Sería mejor orientar la exploración para **reducir la incertidumbre** de las acciones.

Un ejemplo es el método **upper-confidence-bound** (UCB, o cota superior de confianza) para selección de acciones:


$$A_t \doteq \arg \max_a \left[Q_t(a) + c \sqrt{\frac{\ln t}{N_t(a)}} \right]$$

El parámetro c controla el grado de exploración.

Si $N_t(a) = 0$, a es una acción seleccionable.

Comparación de métodos

Estudio comparativo de los parámetros de los algoritmos vistos:



Cada punto es la recompensa promedio obtenida tras 1000 instantes de tiempo con un algoritmo dado y con el valor especificado para el parámetro correspondiente.

Resumen - Bandidos de k brazos

- ▶ Acciones, recompensas estocásticas con distribución estacionaria y desconocida.
- ▶ Valor de una acción: $q_*(a)$; y su estimación: $Q_t(a)$.
- ▶ Dilema de exploración vs. explotación.
- ▶ Métodos action-value y selección ε -greedy de acciones.
- ▶ Fórmula general de actualización de estimaciones en Aprendizaje Reforzado.
- ▶ Problemas no estacionarios: ponderación de recompensas más recientes.
- ▶ Variantes: valores iniciales optimistas, UCB.