

Agentes Inteligentes

Franz Mayr

`mayr@ort.edu.uy`

Universidad ORT Uruguay

2 de junio de 2025

10. Bootstrapping de n pasos

Unificación de métodos MC y TD

Los **métodos MC** actualizan su estimación V de v_π al final de cada episodio, una vez que conocen el retorno del mismo:

$$V_{t+1}(S_t) \leftarrow V_t(S_t) + \alpha \left[G_t - V_t(S_t) \right]$$

El objetivo G_t es el **retorno observado** desde S_t . Es decir, el objetivo es la **secuencia de recompensas** descontadas hasta el final del episodio:
 $R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots + \gamma^{T-t-1} R_T.$

Unificación de métodos MC y TD

Los **métodos MC** actualizan su estimación V de v_π al final de cada episodio, una vez que conocen el retorno del mismo:

$$V_{t+1}(S_t) \leftarrow V_t(S_t) + \alpha \left[G_t - V_t(S_t) \right]$$

El objetivo G_t es el **retorno observado** desde S_t . Es decir, el objetivo es la **secuencia de recompensas** descontadas hasta el final del episodio: $R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots + \gamma^{T-t-1} R_T$.

En contraste, los **métodos TD** no esperan hasta el final del episodio, y actualizan V en cada paso, con bootstrapping:

$$V_{t+1}(S_t) \leftarrow V_t(S_t) + \alpha \left[R_{t+1} + \gamma V_t(S_{t+1}) - V_t(S_t) \right]$$

La actualización se hace en base a **una sola recompensa observada** y haciendo **bootstrapping** para estimar las recompensas restantes hasta el final del episodio.

Unificación de métodos MC y TD

Los **métodos MC** actualizan su estimación V de v_π al final de cada episodio, una vez que conocen el retorno del mismo:

$$V_{t+1}(S_t) \leftarrow V_t(S_t) + \alpha \left[G_t - V_t(S_t) \right]$$

El objetivo G_t es el **retorno observado** desde S_t . Es decir, el objetivo es la **secuencia de recompensas** descontadas hasta el final del episodio: $R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots + \gamma^{T-t-1} R_T$.

En contraste, los **métodos TD** no esperan hasta el final del episodio, y actualizan V en cada paso, con bootstrapping:

$$V_{t+1}(S_t) \leftarrow V_t(S_t) + \alpha \left[R_{t+1} + \gamma V_t(S_{t+1}) - V_t(S_t) \right]$$

La actualización se hace en base a **una sola recompensa observada** y haciendo **bootstrapping** para estimar las recompensas restantes hasta el final del episodio.

Con **n -step bootstrapping** se unifican ambos métodos: **n -step TD**.

Evaluación n -step TD de una política π

DEFINICIÓN: Retorno de n pasos:

$$G_{t:t+n} \doteq R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{n-1} R_{t+n} + \gamma^n V_{t+n-1}(S_{t+n})$$

$$\forall n, t \text{ tales que } n \geq 1, 0 \leq t < T - n$$

Después de n pasos, se estima el retorno G_{t+n+1} con bootstrapping.

Evaluación *n*-step TD de una política π

DEFINICIÓN: Retorno de n pasos:

$$G_{t:t+n} \doteq R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{n-1} R_{t+n} + \gamma^n V_{t+n-1}(S_{t+n})$$

$$\forall n, t \text{ tales que } n \geq 1, 0 \leq t < T - n$$

Después de n pasos, se estima el retorno G_{t+n+1} con bootstrapping.

En particular, el objetivo de TD es el *retorno de un paso* (1-step TD):

$$G_{t:t+1} \doteq R_{t+1} + \gamma V_t(S_{t+1})$$

Evaluación *n*-step TD de una política π

DEFINICIÓN: Retorno de n pasos:

$$G_{t:t+n} \doteq R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{n-1} R_{t+n} + \gamma^n V_{t+n-1}(S_{t+n})$$

$$\forall n, t \text{ tales que } n \geq 1, 0 \leq t < T - n$$

Después de n pasos, se estima el retorno G_{t+n+1} con bootstrapping.

En particular, el objetivo de TD es el *retorno de un paso* (1-step TD):

$$G_{t:t+1} \doteq R_{t+1} + \gamma V_t(S_{t+1})$$

y el objetivo de MC es el *retorno de ∞ pasos* (∞ -step TD):

$$G_{t:t+\infty} \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots + \gamma^{T-t-1} R_T$$

Evaluación n -step TD de una política π

DEFINICIÓN: Retorno de n pasos:

$$G_{t:t+n} \doteq R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{n-1} R_{t+n} + \gamma^n V_{t+n-1}(S_{t+n})$$

$$\forall n, t \text{ tales que } n \geq 1, 0 \leq t < T - n$$

Evaluación n -step TD de una política π

DEFINICIÓN: Retorno de n pasos:

$$G_{t:t+n} \doteq R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{n-1} R_{t+n} + \gamma^n V_{t+n-1}(S_{t+n})$$

$$\forall n, t \text{ tales que } n \geq 1, 0 \leq t < T - n$$

EJEMPLO: El objetivo de 2-step TD es:

$$G_{t:t+2} \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 V_{t+1}(S_{t+2})$$

Evaluación n -step TD de una política π

DEFINICIÓN: Retorno de n pasos:

$$G_{t:t+n} \doteq R_{t+1} + \gamma R_{t+2} + \dots + \gamma^{n-1} R_{t+n} + \gamma^n V_{t+n-1}(S_{t+n})$$

$$\forall n, t \text{ tales que } n \geq 1, 0 \leq t < T - n$$

EJEMPLO: El objetivo de 2-step TD es:

$$G_{t:t+2} \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 V_{t+1}(S_{t+2})$$

Entonces, la estimación se actualiza de esta manera ($0 \leq t < T$):

$$V_{t+n}(S_t) \doteq V_{t+n-1}(S_t) + \alpha [G_{t:t+n} - V_{t+n-1}(S_t)]$$

OBSERVACIÓN: En el instante $t + n$ se actualiza el valor del estado por el cual pasamos hace n instantes (S_t).

1-step TD
and TD(0)



2-step TD



3-step TD



...

n-step TD



...

∞ -step TD
and Monte Carlo



En cada método, la estimación del valor del estado amarillo se actualiza al llegar al estado verde.

Algoritmo *n*-step TD para estimar v_π

Inicializar $V(s)$ arbitrariamente $\forall s \in \mathcal{S}$

Repetir:

 Inicializar S_0

$T \leftarrow \infty$

 Repetir para $t = 0, 1, 2, \dots$:

 Si $t < T$:

$A \leftarrow$ acción desde S_t según π

 Ejecutar la acción A ; observar R_{t+1}, S_{t+1}

 Si S_{t+1} es terminal: $T \leftarrow t + 1$

$\tau \leftarrow t - n + 1$ (vamos a actualizar $V(S_\tau)$)

 Si $\tau \geq 0$:

$G \leftarrow \sum_{i=\tau+1}^{\min(\tau+n, T)} \gamma^{i-\tau-1} R_i$

 Si $\tau + n < T$: $G \leftarrow G + \gamma^n V(S_{\tau+n})$ ($G_{\tau:\tau+n}$)

$V(S_\tau) \leftarrow V(S_\tau) + \alpha [G - V(S_\tau)]$

 hasta que $\tau = T - 1$

Control *n*-step TD

La idea es la misma que SARSA, pero reemplazando la actualización de $Q(s, a)$ por la siguiente:

$$Q_{t+n}(S_t, A_t) \leftarrow Q_{t+n-1}(S_t, A_t) + \alpha [G_{t:t+n} - Q_{t+n-1}(S_t, A_t)]$$
$$0 \leq t < T$$

(Algoritmo completo de n -step SARSA: sección 7.2 del libro de Sutton & Barto 2018.)

Resumen: Bootstrapping de n pasos

- ▶ Retorno de n pasos: $G_{t:t+n}$
- ▶ Casos particulares de n -step TD:
 - ▶ ∞ -step TD: Monte Carlo
 - ▶ 1-step TD: Diferencias Temporales
- ▶ Algoritmos n -step TD para estimar v_π y para control