

Agentes Inteligentes

Franz Mayr

mayr@ort.edu.uy

Universidad ORT Uruguay

16 de junio de 2025

13. Métodos de gradiente de políticas

Métodos de gradiente de políticas

Los métodos vistos hasta ahora aprenden **funciones de valor**, y en base a ellas seleccionan las acciones a tomar.

Métodos de gradiente de políticas

Los métodos vistos hasta ahora aprenden **funciones de valor**, y en base a ellas seleccionan las acciones a tomar.

En cambio, los **métodos de gradiente de políticas** buscan aprender una **política parametrizada** que pueda seleccionar acciones sin consultar a una función de valor:

$$\pi(a \mid s, \boldsymbol{\theta}) = \Pr \{A_t = a \mid S_t = s, \boldsymbol{\theta}_t = \boldsymbol{\theta}\}$$

donde $\boldsymbol{\theta} \in \mathbb{R}^{d'}$ es el vector de parámetros de la política.

Métodos de gradiente de políticas

Los métodos vistos hasta ahora aprenden **funciones de valor**, y en base a ellas seleccionan las acciones a tomar.

En cambio, los **métodos de gradiente de políticas** buscan aprender una **política parametrizada** que pueda seleccionar acciones sin consultar a una función de valor:

$$\pi(a \mid s, \boldsymbol{\theta}) = \Pr \{A_t = a \mid S_t = s, \boldsymbol{\theta}_t = \boldsymbol{\theta}\}$$

donde $\boldsymbol{\theta} \in \mathbb{R}^{d'}$ es el vector de parámetros de la política.

Si tenemos una medida de desempeño $J(\boldsymbol{\theta})$, buscamos maximizar el desempeño mediante actualizaciones de ascenso por el gradiente en J :


$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t + \alpha \widehat{\nabla J(\boldsymbol{\theta}_t)}$$

donde $\widehat{\nabla J(\boldsymbol{\theta}_t)}$ es una aproximación de $\nabla J(\boldsymbol{\theta}_t)$.

Métodos de gradiente de políticas

Por ejemplo, $\pi(a | s, \theta)$ puede ser computada por una red neuronal que aprenda “preferencias” numéricas $h(s, a, \theta) \in \mathbb{R}$ para cada par estado-acción, con una última capa soft-max tal que:


$$\pi(a | s, \theta) \doteq \frac{e^{h(s, a, \theta)}}{\sum_b e^{h(s, b, \theta)}}$$



Métodos de gradiente de políticas

Por ejemplo, $\pi(a | s, \theta)$ puede ser computada por una red neuronal que aprenda “preferencias” numéricas $h(s, a, \theta) \in \mathbb{R}$ para cada par estado-acción, con una última capa soft-max tal que:

$$\pi(a | s, \theta) \doteq \frac{e^{h(s, a, \theta)}}{\sum_b e^{h(s, b, \theta)}}$$




- Esto permite aprender políticas determinísticas y estocásticas de manera natural.
- En algunos problemas puede resultar más sencillo aproximar una política que una función de valor.

Métodos de gradiente de políticas

Por ejemplo, $\pi(a | s, \theta)$ puede ser computada por una red neuronal que aprenda “preferencias” numéricas $h(s, a, \theta) \in \mathbb{R}$ para cada par estado-acción, con una última capa soft-max tal que:

$$\pi(a | s, \theta) \doteq \frac{e^{h(s, a, \theta)}}{\sum_b e^{h(s, b, \theta)}}$$



- Esto permite aprender políticas determinísticas y estocásticas de manera natural.
- En algunos problemas puede resultar más sencillo aproximar una política que una función de valor.
- Recordemos que queremos actualizar $\theta_{t+1} = \theta_t + \alpha \widehat{\nabla J(\theta_t)}$. Veamos cómo podemos aproximar $\nabla J(\theta_t)$.

Gradiente MC de políticas

Si definimos $J(\boldsymbol{\theta}) \doteq v_{\pi_{\boldsymbol{\theta}}}(s_0)$, donde s_0 es un estado inicial y $v_{\pi_{\boldsymbol{\theta}}}$ es la función de valor para $\pi_{\boldsymbol{\theta}}$, puede probarse¹ que:

$$\nabla J(\boldsymbol{\theta}) \propto \sum_s \mu(s) \sum_a q_{\pi}(s, a) \nabla \pi(a | s, \boldsymbol{\theta})$$

donde $\mu(s)$ es la distribución on-policy de estados según π

¹Ver S&B, sección 13.2, “The Policy Gradient Theorem”

Gradiente MC de políticas

Si definimos $J(\boldsymbol{\theta}) \doteq v_{\pi_{\boldsymbol{\theta}}}(s_0)$, donde s_0 es un estado inicial y $v_{\pi_{\boldsymbol{\theta}}}$ es la función de valor para $\pi_{\boldsymbol{\theta}}$, puede probarse¹ que:

$$\nabla J(\boldsymbol{\theta}) \propto \sum_s \mu(s) \sum_a q_{\pi}(s, a) \nabla \pi(a | s, \boldsymbol{\theta})$$

donde $\mu(s)$ es la distribución on-policy de estados según π

$$= \mathbb{E}_{\pi} \left[\sum_a q_{\pi}(S_t, a) \nabla \pi(a | S_t, \boldsymbol{\theta}) \right]$$

porque si seguimos π , los estados aparecen según μ

¹Ver S&B, sección 13.2, “The Policy Gradient Theorem”

Gradiente MC de políticas

Si definimos $J(\boldsymbol{\theta}) \doteq v_{\pi_{\boldsymbol{\theta}}}(s_0)$, donde s_0 es un estado inicial y $v_{\pi_{\boldsymbol{\theta}}}$ es la función de valor para $\pi_{\boldsymbol{\theta}}$, puede probarse¹ que:

$$\nabla J(\boldsymbol{\theta}) \propto \sum_s \mu(s) \sum_a q_{\pi}(s, a) \nabla \pi(a | s, \boldsymbol{\theta})$$

donde $\mu(s)$ es la distribución on-policy de estados según π

$$= \mathbb{E}_{\pi} \left[\sum_a q_{\pi}(S_t, a) \nabla \pi(a | S_t, \boldsymbol{\theta}) \right]$$

porque si seguimos π , los estados aparecen según μ

$$\begin{aligned} &= \mathbb{E}_{\pi} \left[\sum_a \pi(a | S_t, \boldsymbol{\theta}) q_{\pi}(S_t, a) \frac{\nabla \pi(a | S_t, \boldsymbol{\theta})}{\pi(a | S_t, \boldsymbol{\theta})} \right] \\ &= \mathbb{E}_{\pi} \left[q_{\pi}(S_t, A_t) \frac{\nabla \pi(A_t | S_t, \boldsymbol{\theta})}{\pi(A_t | S_t, \boldsymbol{\theta})} \right] \end{aligned}$$

porque las acciones se eligen según π

¹Ver S&B, sección 13.2, “The Policy Gradient Theorem”

Gradiente MC de políticas

Así llegamos a:

$$\begin{aligned}\nabla J(\boldsymbol{\theta}) &\propto \mathbb{E}_{\pi} \left[q_{\pi}(S_t, A_t) \frac{\nabla \pi(A_t | S_t, \boldsymbol{\theta})}{\pi(A_t | S_t, \boldsymbol{\theta})} \right] \\ &= \mathbb{E}_{\pi} \left[G_t \frac{\nabla \pi(A_t | S_t, \boldsymbol{\theta})}{\pi(A_t | S_t, \boldsymbol{\theta})} \right]\end{aligned}$$

Gradiente MC de políticas

Así llegamos a:

$$\begin{aligned}\nabla J(\boldsymbol{\theta}) &\propto \mathbb{E}_{\pi} \left[q_{\pi}(S_t, A_t) \frac{\nabla \pi(A_t | S_t, \boldsymbol{\theta})}{\pi(A_t | S_t, \boldsymbol{\theta})} \right] \\ &= \mathbb{E}_{\pi} \left[G_t \frac{\nabla \pi(A_t | S_t, \boldsymbol{\theta})}{\pi(A_t | S_t, \boldsymbol{\theta})} \right]\end{aligned}$$

De aquí sale la actualización de REINFORCE:

$$\boldsymbol{\theta}_{t+1} \doteq \boldsymbol{\theta}_t + \alpha G_t \frac{\nabla \pi(A_t | S_t, \boldsymbol{\theta}_t)}{\pi(A_t | S_t, \boldsymbol{\theta}_t)}$$

$\boldsymbol{\theta}$ crece con el retorno G_t , que medimos con MC, en la dirección que maximiza la prob. de volver a elegir a A_t en S_t , y en forma inv. proporcional a la probabilidad de elegir a A_t en S_t , para no beneficiar injustamente a las acciones más frecuentes.

Gradiente MC de políticas

Así llegamos a:

$$\begin{aligned}\nabla J(\boldsymbol{\theta}) &\propto \mathbb{E}_{\pi} \left[q_{\pi}(S_t, A_t) \frac{\nabla \pi(A_t | S_t, \boldsymbol{\theta})}{\pi(A_t | S_t, \boldsymbol{\theta})} \right] \\ &= \mathbb{E}_{\pi} \left[G_t \frac{\nabla \pi(A_t | S_t, \boldsymbol{\theta})}{\pi(A_t | S_t, \boldsymbol{\theta})} \right]\end{aligned}$$

De aquí sale la actualización de REINFORCE:

$$\boldsymbol{\theta}_{t+1} \doteq \boldsymbol{\theta}_t + \alpha G_t \frac{\nabla \pi(A_t | S_t, \boldsymbol{\theta}_t)}{\pi(A_t | S_t, \boldsymbol{\theta}_t)}$$

$\boldsymbol{\theta}$ crece con el retorno G_t , que medimos con MC, en la dirección que maximiza la prob. de volver a elegir a A_t en S_t , y en forma inv. proporcional a la probabilidad de elegir a A_t en S_t , para no beneficiar injustamente a las acciones más frecuentes.

Por último, $\boxed{\boldsymbol{\theta}_{t+1} \doteq \boldsymbol{\theta}_t + \alpha G_t \nabla \ln \pi(A_t | S_t, \boldsymbol{\theta}_t)}$ porque $\nabla \ln x = \frac{\nabla x}{x}$.

Algoritmo REINFORCE para estimar π_*

$\pi : \mathcal{S} \times \mathcal{A} \times \mathbb{R}^{d'} \rightarrow [0, 1]$ es una función parametrizable
con pesos $\boldsymbol{\theta} \in \mathbb{R}^{d'}$ (ej.: red neuronal)

Inicializar $\boldsymbol{\theta} \in \mathbb{R}^{d'}$ arbitrariamente

Repetir:

Generar un episodio según π : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$.

$G \leftarrow 0$

Para cada paso del episodio, $t = T - 1, T - 2, \dots, 0$:

$G \leftarrow \gamma G + R_{t+1}$

$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha G \nabla \ln \pi(A_t | S_t, \boldsymbol{\theta})$

Algoritmo REINFORCE con baseline para estimar π_*

$\pi : \mathcal{S} \times \mathcal{A} \times \mathbb{R}^{d'} \rightarrow [0, 1]$ es una función parametrizable con pesos $\boldsymbol{\theta} \in \mathbb{R}^{d'}$

$\hat{v} : \mathcal{S} \times \mathbb{R}^d \rightarrow \mathbb{R}$ es una función parametrizable con pesos $\mathbf{w} \in \mathbb{R}^d$

Inicializar $\boldsymbol{\theta} \in \mathbb{R}^{d'}$ arbitrariamente

Repetir:

Generar un episodio según π : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$.

$G \leftarrow 0$

Para cada paso del episodio, $t = T - 1, T - 2, \dots, 0$:

$G \leftarrow \gamma G + R_{t+1}$

(1) $\delta \leftarrow G - \hat{v}(S_t, \mathbf{w})$

(2) $\mathbf{w} \leftarrow \mathbf{w} + \alpha \mathbf{w} \delta \nabla \hat{v}(S_t, \mathbf{w})$


(3) $\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha \boldsymbol{\theta} \delta \nabla \ln \pi(A_t | S_t, \boldsymbol{\theta})$

La línea (1) estima cuánto mejora el retorno desde S_t respecto de la estimación actual del valor de S_t , y almacena esta mejora en δ .

La línea (2) actualiza los pesos de $\hat{v}(S_t, \mathbf{w})$ de la manera usual.

La línea (3) actualiza los pesos de $\pi(A_t | S_t, \boldsymbol{\theta})$, ahora con respecto a δ .

Algoritmo REINFORCE con y sin baseline



Métodos actor-crítico

Actualización de REINFORCE con baseline:

$$\boldsymbol{\theta}_{t+1} \doteq \boldsymbol{\theta}_t + \alpha \left(G_t - \hat{v}(S_t, \mathbf{w}) \right) \nabla \ln \pi(A_t | S_t, \boldsymbol{\theta})$$

Si en lugar de medir G_t (como en Monte Carlo), hacemos **bootstrapping** (como en Diferencias Temporales), obtenemos la actualización de los métodos actor-crítico (*actor-critic*):

$$\boldsymbol{\theta}_{t+1} \doteq \boldsymbol{\theta}_t + \alpha \left(R_{t+1} + \gamma \hat{v}(S_{t+1}, \mathbf{w}) - \hat{v}(S_t, \mathbf{w}) \right) \cdot \nabla \ln \pi(A_t | S_t, \boldsymbol{\theta})$$

π y $\hat{v}$ reciben los nombres de **actor** y **crítico**, respectivamente.

Esto vendría a ser la versión semi-gradiente TD(0) del algoritmo REINFORCE.

Resumen: Métodos de gradiente de políticas

- ▶ Política parametrizada $\pi : \mathcal{S} \times \mathcal{A} \times \mathbb{R}^{d'} \rightarrow [0, 1]$
- ▶ Métodos REINFORCE con y sin baseline.
- ▶ Métodos actor-crítico
- ▶ Esto permite aprender políticas determinísticas y estocásticas de manera natural.
- ▶ En algunos problemas puede resultar más sencillo aproximar una política que una función de valor.