

Agentes Inteligentes

Franz Mayr

mayr@ort.edu.uy

Universidad ORT Uruguay

6 de abril de 2026

4. Métodos de Programación Dinámica

Evaluación de una política π

Empecemos viendo cómo calcular la función de valor v_π para una política particular π . A esto se lo llama evaluar a π .

Evaluación de una política π

Empecemos viendo **cómo calcular la función de valor v_π** para una política particular π . A esto se lo llama **evaluar** a π .

Vimos la ecuación de Bellman para v_π :

$$v_\pi(s) = \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) \left[r + \gamma v_\pi(s') \right]$$

Normalmente, la resolución directa de esta ecuación es impracticable. Entonces, veamos un **método iterativo** que vaya aproximando gradualmente v_π .

Evaluación de una política π

Empecemos viendo **cómo calcular la función de valor v_π** para una política particular π . A esto se lo llama **evaluar** a π .

Vimos la ecuación de Bellman para v_π :

$$v_\pi(s) = \sum_a \pi(a|s) \sum_{s', r} p(s', r | s, a) \left[r + \gamma v_\pi(s') \right]$$

Normalmente, la resolución directa de esta ecuación es impracticable. Entonces, veamos un **método iterativo** que vaya aproximando gradualmente v_π .

Idea: Usar un arreglo V con $|S|$ posiciones para almacenar la aproximación de $v_\pi(s)$ en la k -ésima iteración del algoritmo, y transformar la ecuación de arriba en una asignación.

Algoritmo iterativo para estimar v_π

$$V(s) \leftarrow \sum_a \pi(a|s) \sum_{s',r} p(s',r | s, a) [r + \gamma V(s')]$$

Algoritmo iterativo para estimar v_π

Repetir:

$$\Delta \leftarrow 0$$

Para cada $s \in \mathcal{S}$:

$$v \leftarrow V(s)$$

$$V(s) \leftarrow \sum_a \pi(a|s) \sum_{s',r} p(s',r | s, a) [r + \gamma V(s')]$$

$$\Delta \leftarrow \max(\Delta, |v - V(s)|)$$

Hasta que $\Delta < \theta$ para algún umbral θ pequeño, que determina la precisión de la aproximación.

Algoritmo iterativo para estimar v_π

Inicializar $V(s)$ arbitrariamente, excepto $V(\text{terminal}) = 0$.

Repetir:

$$\Delta \leftarrow 0$$

Para cada $s \in \mathcal{S}$:

$$v \leftarrow V(s)$$

$$V(s) \leftarrow \sum_a \pi(a|s) \sum_{s',r} p(s',r | s, a) [r + \gamma V(s')]$$

$$\Delta \leftarrow \max(\Delta, |v - V(s)|)$$


Hasta que $\Delta < \theta$ para algún umbral θ pequeño, que determina la precisión de la aproximación.

Devolver $V \approx v_\pi$.


Algoritmo iterativo para estimar v_π

EJERCICIO: Ejecutar a mano en el Grid World de ejemplo el algoritmo iterativo para estimar v_π para la política indicada.

Ambiente ($\gamma = 0,9$)



Política π



Mejora de una política π

Una vez conseguida una estimación de v_π , lo siguiente que podemos hacer es **mejorar** una política π .

Supongamos que, en un estado s , hay una acción a distinta a la acción que elige π . Es decir: $a \neq \pi(s)$.

Si vale $q_\pi(s, a) > v_\pi(s)$, entonces podemos mejorar la política π si **elegimos en s la acción a en lugar de $\pi(s)$** .

Mejora de una política π

Una vez conseguida una estimación de v_π , lo siguiente que podemos hacer es **mejorar** una política π .

Supongamos que, en un estado s , hay una acción a distinta a la acción que elige π . Es decir: $a \neq \pi(s)$.

Si vale $q_\pi(s, a) > v_\pi(s)$, entonces podemos mejorar la política π si **elegimos en s la acción a en lugar de $\pi(s)$** .

En general, podemos definir una política π' de esta forma:

$$\pi'(s) \doteq \arg \max_a q_\pi(s, a)$$

Mejora de una política π

Una vez conseguida una estimación de v_π , lo siguiente que podemos hacer es **mejorar** una política π .

Supongamos que, en un estado s , hay una acción a distinta a la acción que elige π . Es decir: $a \neq \pi(s)$.

Si vale $q_\pi(s, a) > v_\pi(s)$, entonces podemos mejorar la política π si **elegimos en s la acción a en lugar de $\pi(s)$** .

En general, podemos definir una política π' de esta forma:

$$\begin{aligned}\pi'(s) &\doteq \arg \max_a q_\pi(s, a) \\ &= \arg \max_a \mathbb{E}[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s, A_t = a]\end{aligned}$$

Mejora de una política π

Una vez conseguida una estimación de v_π , lo siguiente que podemos hacer es **mejorar** una política π .

Supongamos que, en un estado s , hay una acción a distinta a la acción que elige π . Es decir: $a \neq \pi(s)$.

Si vale $q_\pi(s, a) > v_\pi(s)$, entonces podemos mejorar la política π si **elegimos en s la acción a en lugar de $\pi(s)$** .

En general, podemos definir una política π' de esta forma:


$$\begin{aligned}\pi'(s) &\doteq \arg \max_a q_\pi(s, a) \\ &= \arg \max_a \mathbb{E}[R_{t+1} + \gamma v_\pi(S_{t+1}) \mid S_t = s, A_t = a] \\ &= \arg \max_a \sum_{s', r} p(s', r \mid s, a) [r + \gamma v_\pi(s')]\end{aligned}$$

y decimos que π' es una **mejora greedy** de π .


Mejora de una política π

EJERCICIO: Suponiendo que conocemos q_π , ¿cómo podemos mejorar la política π ?

Política π




q_π




Mejora de una política π

EJERCICIO: Suponiendo que conocemos q_π , ¿cómo podemos mejorar la política π ?

Política π



q_π



Repetir el procedimiento, pero ahora suponiendo que lo que conocemos es $p(s', r | s, a)$ y v_π .

Policy Iteration

Ya tenemos las dos operaciones necesarias para avanzar en forma iterativa hacia una política óptima:

evaluar π ; mejorar π ; repetir.

Policy Iteration

Ya tenemos las dos operaciones necesarias para avanzar en forma iterativa hacia una política óptima:

evaluar π ; mejorar π ; repetir.

Dicho de otra forma:

$$\pi_0$$

Policy Iteration

Ya tenemos las dos operaciones necesarias para **avanzar en forma iterativa hacia una política óptima**:

evaluar π ; mejorar π ; repetir.

Dicho de otra forma:

$$\pi_0 \xrightarrow{\text{eval}} v_{\pi_0}$$

Policy Iteration

Ya tenemos las dos operaciones necesarias para **avanzar en forma iterativa hacia una política óptima**:

evaluar π ; mejorar π ; repetir.

Dicho de otra forma:

$$\pi_0 \xrightarrow{\text{eval}} v_{\pi_0} \xrightarrow{\text{mej}} \pi_1$$

Policy Iteration

Ya tenemos las dos operaciones necesarias para avanzar en forma iterativa hacia una política óptima:

evaluar π ; mejorar π ; repetir.

Dicho de otra forma:

$$\pi_0 \xrightarrow{\text{eval}} v_{\pi_0} \xrightarrow{\text{mej}} \pi_1 \xrightarrow{\text{eval}} v_{\pi_1} \xrightarrow{\text{mej}} \pi_2$$

Policy Iteration

Ya tenemos las dos operaciones necesarias para **avanzar en forma iterativa hacia una política óptima**:

evaluar π ; mejorar π ; repetir.

Dicho de otra forma:

$$\pi_0 \xrightarrow{\text{eval}} v_{\pi_0} \xrightarrow{\text{mej}} \pi_1 \xrightarrow{\text{eval}} v_{\pi_1} \xrightarrow{\text{mej}} \pi_2 \xrightarrow{\text{eval}} \dots \xrightarrow{\text{mej}} \pi_* \xrightarrow{\text{eval}} v_*$$

donde $\xrightarrow{\text{eval}}$ y $\xrightarrow{\text{mej}}$ son una evaluación y una mejora de una política, respectivamente.

Algoritmo Policy Iteration para estimar π_*

1. Inicialización

Inicializar $V(s) \in \mathbb{R}$, $\pi(s) \in \mathcal{A}(s)$ arbitrariamente, para todo $s \in \mathcal{S}$

Algoritmo Policy Iteration para estimar π_*

1. Inicialización

Inicializar $V(s) \in \mathbb{R}$, $\pi(s) \in \mathcal{A}(s)$ arbitrariamente, para todo $s \in \mathcal{S}$

2. Evaluación de la política actual

Repetir:

$$\Delta \leftarrow 0$$

Para cada $s \in \mathcal{S}$:

$$v \leftarrow V(s)$$

$$V(s) \leftarrow \sum_{s',r} p(s',r | s, \pi(s)) [r + \gamma V(s')]$$

$$\Delta \leftarrow \max(\Delta, |v - V(s)|)$$

Hasta que $\Delta < \theta$ para algún umbral θ pequeño, que determina la precisión de la aproximación.

Algoritmo Policy Iteration para estimar π_*

1. Inicialización

Inicializar $V(s) \in \mathbb{R}, \pi(s) \in \mathcal{A}(s)$ arbitrariamente, para todo $s \in \mathcal{S}$

2. Evaluación de la política actual

Repetir:

$$\Delta \leftarrow 0$$

Para cada $s \in \mathcal{S}$:

$$v \leftarrow V(s)$$

$$V(s) \leftarrow \sum_{s',r} p(s', r | s, \pi(s)) [r + \gamma V(s')]$$

$$\Delta \leftarrow \max(\Delta, |v - V(s)|)$$

Hasta que $\Delta < \theta$ para algún umbral θ pequeño, que determina la precisión de la aproximación.

3. Mejora de la política actual

política-estable $\leftarrow$ True

Para cada $s \in \mathcal{S}$:

$$\text{acción-vieja} \leftarrow \pi(s)$$

$$\pi(s) \leftarrow \arg \max_a \sum_{s',r} p(s', r | s, a) [r + \gamma V(s')]$$

Si *acción-vieja* $\neq \pi(s)$: *política-estable* $\leftarrow$ False

Si *política-estable*: Devolver $V \approx v_*$ y $\pi \approx \pi_*$. Si no, volver al paso 2.

De Policy Iteration a Value Iteration

Una seria **desventaja** de Policy Iteration es que hacer una evaluación completa de π_k en cada paso demora mucho tiempo.

De Policy Iteration a Value Iteration

Una seria **desventaja** de Policy Iteration es que hacer una evaluación completa de π_k en cada paso demora mucho tiempo.

Si transformamos la ecuación de optimalidad de Bellman para v_* en una asignación, podemos juntar cada evaluación y mejora en un solo paso:

$$v_*(s) = \max_a \sum_{s', r} p(s', r | s, a) \left[r + \gamma v_*(s') \right]$$

De Policy Iteration a Value Iteration

Una seria **desventaja** de Policy Iteration es que hacer una evaluación completa de π_k en cada paso demora mucho tiempo.

Si transformamos la ecuación de optimalidad de Bellman para v_* en una asignación, podemos juntar cada evaluación y mejora en un solo paso:

$$v_*(s) = \max_a \sum_{s',r} p(s', r | s, a) \left[r + \gamma v_*(s') \right]$$

$$V(s) \leftarrow \max_a \sum_{s',r} p(s', r | s, a) \left[r + \gamma V(s') \right]$$

Algoritmo Value Iteration para estimar π_*

$$V(s) \leftarrow \max_a \sum_{s',r} p(s', r \mid s, a) [r + \gamma V(s')]$$

Algoritmo Value Iteration para estimar π_*

Repetir:

$$\Delta \leftarrow 0$$

Para cada $s \in \mathcal{S}$:

$$v \leftarrow V(s)$$

$$V(s) \leftarrow \max_a \sum_{s',r} p(s', r | s, a) [r + \gamma V(s')]$$

$$\Delta \leftarrow \max(\Delta, |v - V(s)|)$$

Hasta que $\Delta < \theta$ para algún umbral θ pequeño, que determina la precisión de la aproximación.

Algoritmo Value Iteration para estimar π_*

Inicializar $V(s)$ arbitrariamente $\forall s \in \mathcal{S}$, excepto $V(\text{terminal}) = 0$.

Repetir:

$$\Delta \leftarrow 0$$

Para cada $s \in \mathcal{S}$:

$$v \leftarrow V(s)$$

$$V(s) \leftarrow \max_a \sum_{s',r} p(s', r | s, a) [r + \gamma V(s')]$$

$$\Delta \leftarrow \max(\Delta, |v - V(s)|)$$

Hasta que $\Delta < \theta$ para algún umbral θ pequeño, que determina la precisión de la aproximación.


Devolver una política determinística $\pi \approx \pi_*$ tal que:

$$\pi(s) = \arg \max_a \sum_{s',r} p(s', r | s, a) [r + \gamma V(s')]$$

Algoritmo Value Iteration para estimar π_*

EJERCICIO: Ejecutar a mano en el Grid World de ejemplo el algoritmo Value Iteration, para estimar π_* .

Ambiente ($\gamma = 0,9$)



Resumen - Métodos de Programación Dinámica

Algoritmos de programación dinámica:

- ▶ para estimar el valor de los estados según la política π (es decir, v_π)
- ▶ para mejorar una política π a partir de $p(s', r | s, a)$ y v_π
- ▶ Policy Iteration, para estimar π_* (muy lento)
- ▶ Value Iteration, para estimar π_*