

Agentes Inteligentes

Franz Mayr

mayr@ort.edu.uy

Universidad ORT Uruguay

20 de abril de 2026

6. Métodos de Diferencias Temporales

Repaso: Estimación Monte Carlo de $v_\pi(s)$

Inicializar:

$V(s) \in \mathbb{R}$ arbitrariamente, $\forall s \in \mathcal{S}$

$Retornos(s) \leftarrow$ lista vacía, $\forall s \in \mathcal{S}$

Repetir:

Generar un episodio según π : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

Para cada paso del episodio, $t = T - 1, T - 2, \dots, 0$:

$G \leftarrow \gamma G + R_{t+1}$

Si S_t no aparece en $S_0, S_1, \dots, S_{t-1}$:

Agregar G a $Retornos(S_t)$

$V(S_t) \leftarrow$ promedio($Retornos(S_t)$)

$V(s)$ converge a $v_\pi(s)$ (para los estados visitados).

Repaso: Estimación Monte Carlo de $v_\pi(s)$

Inicializar:

$V(s) \in \mathbb{R}$ arbitrariamente, $\forall s \in \mathcal{S}$

$Retornos(s) \leftarrow$ lista vacía, $\forall s \in \mathcal{S}$

Repetir:

Generar un episodio según π : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

Para cada paso del episodio, $t = T - 1, T - 2, \dots, 0$:

$G \leftarrow \gamma G + R_{t+1}$

Si S_t no aparece en $S_0, S_1, \dots, S_{t-1}$:

Agregar G a $Retornos(S_t)$

$V(S_t) \leftarrow$ promedio($Retornos(S_t)$)

$V(s)$ converge a $v_\pi(s)$ (para los estados visitados).

También vimos estimación MC de $q_\pi(s, a)$, control MC, con exploración inicial y con políticas ε -greedy.

Repaso: Estimación Monte Carlo de $v_{\pi}(s)$

Después de k episodios que pasaron por un estado $s \in \mathcal{S}$, el valor estimado de s es:

$$V = \frac{G^{(1)} + G^{(2)} + G^{(3)} + \dots + G^{(k)}}{k}$$

donde $G^{(i)}$ es el retorno medido desde v en la i -ésima iteración.

Repaso: Estimación Monte Carlo de $v_{\pi}(s)$

Después de k episodios que pasaron por un estado $s \in \mathcal{S}$, el valor estimado de s es:

$$V = \frac{G^{(1)} + G^{(2)} + G^{(3)} + \dots + G^{(k)}}{k}$$

donde $G^{(i)}$ es el retorno medido desde v en la i -ésima iteración.

Al terminar el episodio $k + 1$, el valor estimado de s es:

$$V' = \frac{G^{(1)} + G^{(2)} + G^{(3)} + \dots + G^{(k)} + G^{(k+1)}}{k + 1}$$

Repaso: Estimación Monte Carlo de $v_{\pi}(s)$

Después de k episodios que pasaron por un estado $s \in \mathcal{S}$, el valor estimado de s es:

$$V = \frac{G^{(1)} + G^{(2)} + G^{(3)} + \dots + G^{(k)}}{k}$$

donde $G^{(i)}$ es el retorno medido desde v en la i -ésima iteración.

Al terminar el episodio $k + 1$, el valor estimado de s es:

$$\begin{aligned} V' &= \frac{G^{(1)} + G^{(2)} + G^{(3)} + \dots + G^{(k)} + G^{(k+1)}}{k + 1} \\ &= \frac{V \cdot k + G^{(k+1)}}{k + 1} \end{aligned}$$

Repaso: Estimación Monte Carlo de $v_{\pi}(s)$

Después de k episodios que pasaron por un estado $s \in \mathcal{S}$, el valor estimado de s es:

$$V = \frac{G^{(1)} + G^{(2)} + G^{(3)} + \dots + G^{(k)}}{k}$$

donde $G^{(i)}$ es el retorno medido desde v en la i -ésima iteración.

Al terminar el episodio $k + 1$, el valor estimado de s es:

$$\begin{aligned} V' &= \frac{G^{(1)} + G^{(2)} + G^{(3)} + \dots + G^{(k)} + G^{(k+1)}}{k + 1} \\ &= \frac{V \cdot k + G^{(k+1)}}{k + 1} \\ &= \frac{V \cdot k}{k + 1} + \frac{G^{(k+1)}}{k + 1} + \frac{V}{k + 1} - \frac{V}{k + 1} \end{aligned}$$

Repaso: Estimación Monte Carlo de $v_{\pi}(s)$

Después de k episodios que pasaron por un estado $s \in \mathcal{S}$, el valor estimado de s es:

$$V = \frac{G^{(1)} + G^{(2)} + G^{(3)} + \dots + G^{(k)}}{k}$$

donde $G^{(i)}$ es el retorno medido desde v en la i -ésima iteración.

Al terminar el episodio $k + 1$, el valor estimado de s es:

$$\begin{aligned} V' &= \frac{G^{(1)} + G^{(2)} + G^{(3)} + \dots + G^{(k)} + G^{(k+1)}}{k + 1} \\ &= \frac{V \cdot k + G^{(k+1)}}{k + 1} \\ &= \frac{V \cdot k}{k + 1} + \frac{G^{(k+1)}}{k + 1} + \frac{V}{k + 1} - \frac{V}{k + 1} \\ &= V \cdot \frac{k + 1}{k + 1} + \frac{G^{(k+1)}}{k + 1} - \frac{V}{k + 1} \end{aligned}$$

Repaso: Estimación Monte Carlo de $v_\pi(s)$

Después de k episodios que pasaron por un estado $s \in \mathcal{S}$, el valor estimado de s es:

$$V = \frac{G^{(1)} + G^{(2)} + G^{(3)} + \dots + G^{(k)}}{k}$$

donde $G^{(i)}$ es el retorno medido desde v en la i -ésima iteración.

Al terminar el episodio $k + 1$, el valor estimado de s es:

$$\begin{aligned} V' &= \frac{G^{(1)} + G^{(2)} + G^{(3)} + \dots + G^{(k)} + G^{(k+1)}}{k + 1} \\ &= \frac{V \cdot k + G^{(k+1)}}{k + 1} \\ &= \frac{V \cdot k}{k + 1} + \frac{G^{(k+1)}}{k + 1} + \frac{V}{k + 1} - \frac{V}{k + 1} \\ &= V \cdot \frac{k + 1}{k + 1} + \frac{G^{(k+1)}}{k + 1} - \frac{V}{k + 1} \\ &= V + \frac{1}{k + 1} \cdot (G^{(k+1)} - V) \end{aligned}$$

Métodos de Diferencias Temporales

Recordemos la asignación que vimos hace un tiempo:

$$NuevaEst \leftarrow ViejaEst + TasaAct \left[\textit{Objetivo} - ViejaEst \right]$$

Métodos de Diferencias Temporales

Recordemos la asignación que vimos hace un tiempo:

$$NuevaEst \leftarrow ViejaEst + TasaAct \left[\textit{Objetivo} - ViejaEst \right]$$

Los métodos MC actualizan su estimación V de v_π al final de cada episodio, una vez que conocen el retorno del mismo:

$$V(S_t) \leftarrow V(S_t) + \alpha \left[G_t - V(S_t) \right]$$

Métodos de Diferencias Temporales

Recordemos la asignación que vimos hace un tiempo:

$$NuevaEst \leftarrow ViejaEst + TasaAct \left[\textit{Objetivo} - ViejaEst \right]$$

Los métodos MC actualizan su estimación V de v_π al final de cada episodio, una vez que conocen el retorno del mismo:

$$V(S_t) \leftarrow V(S_t) + \alpha \left[G_t - V(S_t) \right]$$

En contraste, los métodos de diferencias temporales (TD) no esperan hasta el final del episodio, sino que actualizan V en cada paso del episodio:

$$V(S_t) \leftarrow V(S_t) + \alpha \left[R_{t+1} + \gamma V(S_{t+1}) - V(S_t) \right]$$

Métodos de Diferencias Temporales

Recordemos la asignación que vimos hace un tiempo:

$$NuevaEst \leftarrow ViejaEst + TasaAct \left[\text{Objetivo} - ViejaEst \right]$$

Los métodos MC actualizan su estimación V de v_π al final de cada episodio, una vez que conocen el retorno del mismo:

$$V(S_t) \leftarrow V(S_t) + \alpha \left[G_t - V(S_t) \right]$$

En contraste, los métodos de diferencias temporales (TD) no esperan hasta el final del episodio, sino que actualizan V en cada paso del episodio:

$$V(S_t) \leftarrow V(S_t) + \alpha \left[R_{t+1} + \gamma V(S_{t+1}) - V(S_t) \right]$$

Al término $G_t - V(S_t)$ se lo denomina **error MC**, y al término $R_{t+1} + \gamma V(S_{t+1}) - V(S_t)$, **error TD**.

Estimación TD de $v_{\pi}(s)$: Algoritmo TD(0)

Inicializar $V(s)$ arbitrariamente $\forall s \in \mathcal{S}$

Estimación TD de $v_{\pi}(s)$: Algoritmo TD(0)

Inicializar $V(s)$ arbitrariamente $\forall s \in \mathcal{S}$

Repetir:

 Inicializar S

 Repetir:

$A \leftarrow$ acción desde S según π

 Ejecutar la acción A ; observar R, S'

$S \leftarrow S'$

 hasta que S sea terminal

Estimación TD de $v_{\pi}(s)$: Algoritmo TD(0)

Inicializar $V(s)$ arbitrariamente $\forall s \in \mathcal{S}$

Repetir:

 Inicializar S

 Repetir:

$A \leftarrow$ acción desde S según π

 Ejecutar la acción A ; observar R, S'

$V(S) \leftarrow V(S) + \alpha [R + \gamma V(S') - V(S)]$

$S \leftarrow S'$

 hasta que S sea terminal

Estimación TD de $v_{\pi}(s)$: Algoritmo TD(0)

Inicializar $V(s)$ arbitrariamente $\forall s \in \mathcal{S}$

Repetir:

 Inicializar S

 Repetir:

$A \leftarrow$ acción desde S según π

 Ejecutar la acción A ; observar R, S'

$V(S) \leftarrow V(S) + \alpha [R + \gamma V(S') - V(S)]$

$S \leftarrow S'$

 hasta que S sea terminal

La tasa de aprendizaje $\alpha \in (0, 1]$ es un parámetro del algoritmo.

Métodos de Diferencias Temporales

OBSERVACIÓN:

$$v_{\pi}(s) \doteq \mathbb{E}_{\pi}[G_t \mid S_t = s] \quad (1)$$

$$= \mathbb{E}_{\pi}[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \quad (2)$$

$$= \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \quad (3)$$

¹Sin relación con el método estadístico de muestreo con reemplazo.

Métodos de Diferencias Temporales

OBSERVACIÓN:

$$v_{\pi}(s) \doteq \mathbb{E}_{\pi}[G_t \mid S_t = s] \quad (1)$$

$$= \mathbb{E}_{\pi}[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \quad (2)$$

$$= \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \quad (3)$$

En la línea (1) vemos el objetivo de MC: G_t .

En la línea (3) vemos el objetivo de TD: $R_{t+1} + \gamma V(S_{t+1})$.

Esto muestra que ambos métodos convergen a la misma estimación de $v_{\pi}(s)$.

¹Sin relación con el método estadístico de muestreo con reemplazo.

Métodos de Diferencias Temporales

OBSERVACIÓN:

$$v_{\pi}(s) \doteq \mathbb{E}_{\pi}[G_t \mid S_t = s] \quad (1)$$

$$= \mathbb{E}_{\pi}[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \quad (2)$$

$$= \mathbb{E}_{\pi}[R_{t+1} + \gamma v_{\pi}(S_{t+1}) \mid S_t = s] \quad (3)$$

En la línea (1) vemos el objetivo de MC: G_t .

En la línea (3) vemos el objetivo de TD: $R_{t+1} + \gamma V(S_{t+1})$.

Esto muestra que ambos métodos convergen a la misma estimación de $v_{\pi}(s)$.

La gran diferencia entre ambos es que MC basa su estimación en un valor real de G_t , pero TD la basa en otro valor estimado.

La literatura de Aprendizaje Reforzado se refiere a esta característica como **bootstrapping**.¹

¹Sin relación con el método estadístico de muestreo con reemplazo.

MC vs. TD - Ejemplo: Conduciendo a casa

Estado	Hora	Tiempo restante predicho	Tiempo total predicho
Saliendo del trabajo	18:00	30	30

MC vs. TD - Ejemplo: Conduciendo a casa

Estado	Hora	Tiempo restante predicho	Tiempo total predicho
Saliendo del trabajo	18:00	30	30
En el auto, llueve	18:05	35	40

MC vs. TD - Ejemplo: Conduciendo a casa

Estado	Hora	Tiempo restante predicho	Tiempo total predicho
Saliendo del trabajo	18:00	30	30
En el auto, llueve	18:05	35	40
Saliendo de autopista	18:20	15	35

MC vs. TD - Ejemplo: Conduciendo a casa

Estado	Hora	Tiempo restante predicho	Tiempo total predicho
Saliendo del trabajo	18:00	30	30
En el auto, llueve	18:05	35	40
Saliendo de autopista	18:20	15	35
Ruta local, atrás de camión	18:30	10	40

MC vs. TD - Ejemplo: Conduciendo a casa


Estado	Hora	Tiempo restante predicho	Tiempo total predicho
Saliendo del trabajo	18:00	30	30
En el auto, llueve	18:05	35	40
Saliendo de autopista	18:20	15	35
Ruta local, atrás de camión	18:30	10	40
Calle de casa	18:40	3	43

MC vs. TD - Ejemplo: Conduciendo a casa

Estado	Hora	Tiempo restante predicho	Tiempo total predicho
Saliendo del trabajo	18:00	30	30
En el auto, llueve	18:05	35	40
Saliendo de autopista	18:20	15	35
Ruta local, atrás de camión	18:30	10	40
Calle de casa	18:40	3	43
Entrando en casa	18:43	0	43

MC vs. TD - Ejemplo: Conduciendo a casa


Estado	Hora	Tiempo restante predicho	Tiempo total predicho
Saliendo del trabajo	18:00	30	30
En el auto, llueve	18:05	35	40
Saliendo de autopista	18:20	15	35
Ruta local, atrás de camión	18:30	10	40
Calle de casa	18:40	3	43
Entrando en casa	18:43	0	43




Métodos Monte Carlo

MC vs. TD - Ejemplo: Conduciendo a casa

Estado	Hora	Tiempo restante predicho	Tiempo total predicho
Saliendo del trabajo	18:00	30	30
En el auto, llueve	18:05	35	40
Saliendo de autopista	18:20	15	35
Ruta local, atrás de camión	18:30	10	40
Calle de casa	18:40	3	43
Entrando en casa	18:43	0	43



Métodos Monte Carlo



Métodos TD

MC vs. TD - Ejemplo: Random walk




$$\pi(\leftarrow | s) = \pi(\rightarrow | s) = 0,5 \quad \forall s \in \{A, B, C, D, E\}; \quad \gamma = 1$$


MC vs. TD - Ejemplo: Random walk



$$\pi(\leftarrow | s) = \pi(\rightarrow | s) = 0,5 \quad \forall s \in \{A, B, C, D, E\}; \quad \gamma = 1$$



Eje y : valores de los estados, aprendidos por TD(0) después del número indicado de episodios.



Eje y : RMSE de los valores aprendidos respecto de los reales, promediado para los 5 estados.

Estimación TD de $q_{\pi}(s, a)$: Algoritmo TD(0)

El algoritmo TD(0) para estimar la función de valor de los pares estado-acción es análogo:

Inicializar $Q(s, a)$ arbitrariamente $\forall s \in \mathcal{S}, a \in \mathcal{A}(s)$

Repetir:

 Inicializar S

$A \leftarrow$ acción desde S según π

 Repetir:

 Ejecutar la acción A ; observar R, S'

$A' \leftarrow$ acción desde S' según π

$Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma Q(S', A') - Q(S, A)]$

$S \leftarrow S'$

$A \leftarrow A'$

 hasta que S sea terminal

La tasa de aprendizaje $\alpha \in (0, 1]$ es un parámetro del algoritmo.

On-policy TD control: Sarsa

En MC, la actualización de la estimación de $q_\pi(s, a)$ se realiza al final de cada episodio, una vez conocido el objetivo G_t :

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[G_t - Q(S_t, A_t) \right]$$

On-policy TD control: Sarsa

En MC, la actualización de la estimación de $q_\pi(s, a)$ se realiza al final de cada episodio, una vez conocido el objetivo G_t :

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[G_t - Q(S_t, A_t) \right]$$

En TD, esta estimación se actualiza después de tomar cada acción A_t y observar (S_{t+1}, R_{t+1}) (bootstrapping):

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t) \right]$$

donde A_{t+1} es una acción desde S_{t+1} elegida según una política basada en Q (p.ej., ε -greedy).

On-policy TD control: Sarsa


En MC, la actualización de la estimación de $q_\pi(s, a)$ se realiza al final de cada episodio, una vez conocido el objetivo G_t :

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[G_t - Q(S_t, A_t) \right]$$

En TD, esta estimación se actualiza después de tomar cada acción A_t y observar (S_{t+1}, R_{t+1}) (bootstrapping):

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t) \right]$$

donde A_{t+1} es una acción desde S_{t+1} elegida según una política basada en Q (p.ej., ε -greedy).



Esta regla usa la quintupla $S_t, A_t, R_{t+1}, S_{t+1}, A_{t+1}$, de ahí su nombre.

On-policy TD control: Sarsa

Inicializar $Q(s, a)$ arbitrariamente $\forall s \in \mathcal{S}, a \in \mathcal{A}(s)$

Repetir:

 Inicializar S

$A \leftarrow$ acción desde S según política ε -greedy basada en Q

 Repetir:

 Ejecutar la acción A ; observar R, S'

$A' \leftarrow$ acción desde S' según política ε -greedy basada en Q

$Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma Q(S', A') - Q(S, A)]$

$S \leftarrow S'$

$A \leftarrow A'$

 hasta que S sea terminal

La tasa de aprendizaje $\alpha \in (0, 1]$ es un parámetro del algoritmo.

Off-policy TD control: Q-learning

Sarsa usa la misma política ε -greedy basada en Q para elegir la siguiente acción A_{t+1} y para estimar el retorno G_t (en rojo) en la regla de actualización de Q :

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t) \right]$$

Por eso, SARSA es un método **on-policy**.

Con este cambio a la regla de actualización de Q :

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t) \right]$$

desacoplamos la estimación del retorno G_t (ahora se supone una política greedy pura) de la política seguida para elegir la siguiente acción del episodio (ε -greedy).

Por eso, Q-learning es un método **off-policy**.

Off-policy TD control: Q-learning

Inicializar $Q(s, a)$ arbitrariamente $\forall s \in \mathcal{S}, a \in \mathcal{A}(s)$

Repetir:

 Inicializar S

 Repetir:

$A \leftarrow$ acción desde S según política ε -greedy basada en Q

 Ejecutar la acción A ; observar R, S'

$Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma \max_a Q(S', a) - Q(S, A)]$

$S \leftarrow S'$

 hasta que S sea terminal

La tasa de aprendizaje $\alpha \in (0, 1]$ es un parámetro del algoritmo.

Resumen - Métodos de Diferencias Temporales

Los métodos TD no esperan al final del episodio para actualizar sus estimaciones, sino que lo hacen luego de cada paso en el episodio.

- ▶ Algoritmo TD(0) para estimar $v_\pi(s)$ o $q_\pi(s, a)$.
- ▶ On-policy TD control: algoritmo Sarsa.
- ▶ Off-policy TD control: algoritmo Q-learning.

Próximas clases:

- ▶ Introducción a redes neuronales y deep learning.
- ▶ Métodos de aproximación de funciones; deep reinforcement learning.