

Agentes Inteligentes

Franz Mayr

mayr@ort.edu.uy

Universidad ORT Uruguay

22 de junio de 2026

Repaso de la materia

Mapa del curso

Problema: aprender a tomar decisiones secuenciales bajo incertidumbre

- ▶ **Representación:** estados S_t , acciones A_t , recompensas R_t , retorno G_t y política $\pi(a|s)$.
- ▶ **Objetivo:** encontrar una política que maximice recompensa acumulada esperada.
- ▶ **Idea común:** estimar algo útil y actualizarlo con experiencia:

$$NuevaEst = ViejaEst + \alpha [Objetivo - ViejaEst]$$

- ▶ **Familias de métodos:** DP, Monte Carlo, TD, n -pasos, planning, aproximación de funciones y gradientes de política.


Bandidos de k brazos



- ▶ A_t : acción elegida en el tiempo t , con recompensa R_t .
- ▶ $q_*(a) \doteq \mathbb{E}[R_t \mid A_t = a]$ es el **valor** de una acción $a \in \mathcal{A}$.
- ▶ $Q_t(a)$ es una **estimación** de $q_*(a)$ en el instante de tiempo t .
- ▶ Actualización de estimaciones: $Q_{t+1}(a) = Q_t(a) + \alpha [R_t - Q_t(a)]$
- ▶

$NuevaEst = ViejaEst + TasaAct [Objetivo - ViejaEst]$
- ▶ Explotación vs. exploración: selección ε -greedy de acciones.

Procesos de Decisión de Markov



$$S_t \in \mathcal{S}$$

$$A_t \in \mathcal{A}(S_t)$$

$$R_t \in \mathcal{R} \subset \mathbb{R}$$

- **Ambiente** caracterizado por:
$$p(s', r | s, a) \doteq \Pr\{S_t = s', R_t = r | S_{t-1} = s, A_{t-1} = a\}$$
- **Retorno** $G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$
- **Política** $\pi(a|s)$ (estocástica o determinística)
- **Valor** del estado s , según π : $v_\pi(s) \doteq \mathbb{E}_\pi[G_t | S_t = s]$
- **Valor** de la acción a en el estado s , según π :
$$q_\pi(s, a) \doteq \mathbb{E}_\pi[G_t | S_t = s, A_t = a]$$
- Vimos varios métodos para aproximar funciones de valor de políticas dadas (**evaluación**), o de políticas óptimas (**control**).

Familias de métodos

Método	Qué necesita	Qué actualiza / estima
Programación Dinámica	Modelo del ambiente $p(s', r s, a)$	Valores usando esperanzas sobre transiciones posibles.
Monte Carlo	Episodios completos de experiencia	Valores usando retornos observados G_t .
TD(0)	Experiencia paso a paso	Valores usando recompensa inmediata y bootstrap.
n -pasos	Trayectorias parciales	Interpola entre TD y MC: más profundidad antes de bootstrap.
Planning	Modelo aprendido o dado	Simula experiencia para actualizar valores o acciones.


- La pregunta guía no es “¿cuál es mejor?”, sino **qué información tengo y qué costo puedo pagar**.

Algunas dimensiones de los métodos vistos

- ▶ Profundidad de la actualización / grado de bootstrapping
- ▶ Actualización basada en muestreos vs. esperanzas
- ▶ Métodos on-policy vs. off-policy
- ▶ Experiencia real (aprendizaje) vs. simulada (planning)
- ▶ Métodos tabulares vs. de aproximación de funciones de valor
- ▶ Aprendizaje de funciones de valor (para definir políticas) vs. aprendizaje de políticas parametrizadas.

Algunas dimensiones de los métodos vistos

- Profundidad de la actualización / grado de bootstrapping
- Actualización basada en muestreos vs. esperanzas



On-policy vs. off-policy

- ▶ En **control** queremos aprender una política buena, pero también necesitamos explorar.
- ▶ **On-policy**: aprendemos el valor de la misma política que usamos para actuar.

$$\text{SARSA: } Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)]$$

- ▶ **Off-policy**: aprendemos sobre una política objetivo distinta de la que genera la experiencia.

$$\text{Q-learning: } Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t)]$$

- ▶ Intuición: SARSA incorpora el costo de explorar; Q-learning mira la mejor acción estimada en el próximo estado.

Aprendizaje vs. planificación

- ▶ En **aprendizaje** actualizamos usando experiencia real:

$$S_t, A_t, R_{t+1}, S_{t+1}$$

- ▶ En **planning** usamos un modelo para generar experiencia simulada:

$$\text{modelo: } (s, a) \mapsto (s', r)$$

- ▶ **Dyna**: combina ambas ideas:

1. interactuar con el ambiente,
2. actualizar valores,
3. actualizar el modelo,
4. simular transiciones y volver a actualizar.

- ▶ Intuición: si el modelo es razonable, cada interacción real puede rendir mucho más.

Tabular vs. aproximación de funciones

- ▶ En métodos **tabulares** guardamos una estimación por estado o par estado-acción:

$$V(s) \quad \text{o} \quad Q(s, a)$$

- ▶ Esto funciona si podemos visitar y almacenar suficientes valores.
- ▶ Con muchos estados, o estados continuos, usamos una función parametrizada:

$$\hat{v}(s, \theta) \approx v_{\pi}(s) \quad \text{o} \quad \hat{q}(s, a, \theta) \approx q_{\pi}(s, a)$$

- ▶ La actualización ya no cambia una celda de una tabla: cambia los parámetros θ .
- ▶ Intuición: ganamos **generalización**, pero perdemos garantías simples de los métodos tabulares.

Valores vs. políticas parametrizadas

- ▶ Muchos métodos aprenden una **función de valor** y derivan una política a partir de ella:

$$Q(s, a) \Rightarrow \pi(s) = \arg \max_a Q(s, a)$$

- ▶ En **gradientes de política** parametrizamos directamente la política:

$$\pi(a|s, \theta)$$

- ▶ Queremos ajustar θ para aumentar el retorno esperado:

$$J(\theta) \doteq \mathbb{E}_{\pi_\theta}[G_t]$$

- ▶ Ventaja: podemos aprender políticas estocásticas y manejar espacios de acciones continuos.
- ▶ Costo: las estimaciones del gradiente pueden tener alta varianza y suelen requerir cuidado en la actualización.

Preguntas guía

- ▶ Si tengo un modelo del ambiente, ¿qué métodos puedo usar?
- ▶ Si solo observo episodios completos, ¿qué puedo estimar?
- ▶ ¿Qué problema resuelve TD frente a Monte Carlo?
- ▶ ¿Cuándo importa distinguir on-policy y off-policy?
- ▶ ¿Qué gano y qué pierdo al pasar de tablas a aproximación de funciones?
- ▶ ¿Por qué podría querer aprender una política directamente?

La clave: elegir el método según la información disponible, el costo de muestreo y el tipo de política que queremos aprender.