

Escaleras mágicas

Un arquitecto se dispone a diseñar su casa de verano y toma una idea de su proyecto anterior, la escuela de magia y hechicería Hogwarts. En este proyecto, las escaleras tienen un comportamiento no determinista, llevando a sus usuarios a distintos lugares siguiendo una cierta función de probabilidad.


Dado que el proyecto actual es de menor tamaño que el anterior, se anima a hacer los desarrollos a mano. Para ello contrata un ayudante, usted, a fin de asistirlo con las cuentas. Le entrega una nota que dice lo siguiente:

Diseño secreto de las escaleras mágicas de la casa de verano

- Considere los pisos numerados de 1 a 4.
- Subir del piso s a $s+1$ toma 1 minuto y se hace determinísticamente. Salvo para el primer piso, que se demora 3 minutos (por razones mágicas).
- Esperar en el descanso del piso 1 toma 2 minutos y puede dejarlo en el piso 1 o llevarlo al 4 con la misma probabilidad.
- Esperar en el descanso del piso 2 puede llevarlo al 3 o al 4 con la misma probabilidad. En cualquier caso demora 2 minutos.
- Esperar en el descanso del piso 3 puede llevarlo al 1 o al 4 con la misma probabilidad. Si va al 1, pierde 2.5 minutos; si va al 4, 1.5 minutos.
- La única manera de bajar es un tobogán mágico ubicado en el cuarto piso. Este tobogán no forma parte del modelo matemático a desarrollar.

1) Modelado

Modele el problema con un grafo con transiciones de probabilidad.



Notas:

- Para este diagrama,  significa esperar y  refiere a la acción de subir.
 - En cada vector, el array está ordenado en {acción, tiempo, probabilidad}
-

2) Cálculos analíticos

$$V(4) = 0$$

Factor de descuento $\gamma=1$

a) Calcule la utilidad esperada de la política “siempre esperar”.

- **Piso 1:** Hay un 50% de probabilidad de quedarse en el piso 1 y un 50% de ir al piso 4, tardando siempre 2 minutos.

$$V(1) = 0.5 (2 + V(1)) + 0.5 (2 + V(4))$$

$$V(1) = 1 + 0.5V(1) + 1 + 0 \Rightarrow$$

$$\Rightarrow 0.5 V(1) = 2 \Rightarrow$$

$$\Rightarrow \mathbf{V(1) = 4}$$

- **Piso 3:** Hay un 50% de ir al piso 1 (tarda 2.5 min) y 50% de ir al piso 4 (tarda 1.5 min).

$$V(3) = 0.5 (2.5 + V(1)) + 0.5 (1.5 + V(4))$$

$$V(3) = 0.5 (2.5 + 4) + 0.5 (1.5 + 0) = 3.25 + 0.75 \Rightarrow$$

$$\Rightarrow \mathbf{V(3) = 4}$$

- **Piso 2:** Hay un 50% de ir al piso 3 y 50% al piso 4, tardando 2 minutos.

$$V(2) = 0.5 (2 + V(3)) + 0.5 (2 + V(4))$$

$$V(2) = 0.5 (2 + 4) + 0.5 (2 + 0) = 3 + 1 \Rightarrow$$

$$\Rightarrow \mathbf{V(2) = 4}$$

- **Resultados:** $V(1) = 4$, $V(2) = 4$, $V(3) = 4$

b) Calcule la utilidad esperada de la política “siempre subir”.

Bajo las condiciones de este ejercicio ($\gamma=1$, política determinista y transiciones deterministas), la fórmula para cada piso s se reduce a:

$$V(s) = \text{Tiempo de viaje} + V(s+1)$$

- **Piso 3:** Subir al piso 4 toma 1 minuto.

$$V(3) = 1 + V(4) = 1 + 0 = 1$$

$$\mathbf{V(3) = 1}$$

- **Piso 2:** Subir al piso 3 toma 1 minuto.

$$V(2) = 1 + V(3) = 1 + 1 = 2$$

$$\mathbf{V(2) = 2}$$

- **Piso 1:** Subir al piso 2 toma 3 minutos (por razones mágicas).

$$V(1) = 3 + V(2) = 3 + 2 = 5$$

$$\mathbf{V(1) = 5}$$

- **Resultados:** $\mathbf{V(1) = 5}$, $\mathbf{V(2) = 2}$, $\mathbf{V(3) = 1}$

c) Calcule la utilidad esperada de la política “siempre esperar” si la probabilidad de llegar mágicamente al piso 4 por esperar en los descansos es de 0.3.

La probabilidad de llegar al piso 4 es de 0.3 $\Rightarrow$ la probabilidad de la otra transición es 0.7

- **Piso 1:** $P(1|1) = 0.7$ y $P(4|1) = 0.3$.

$$V(1) = 0.7 (2 + V(1)) + 0.3 (2 + V(4)) \Rightarrow$$

$$\Rightarrow V(1) = 1.4 + 0.7 V(1) + 0.6 + 0$$

$$\Rightarrow V(1) = 2 + 0.7 V(1) \Rightarrow$$

$$\Rightarrow 0.3 V(1) = 2 \Rightarrow$$

$$\Rightarrow \mathbf{V(1) = 6.67}$$

- **Piso 3:** $P(1|3) = 0.7$ y $P(4|3) = 0.3$.

$$V(3) = 0.7 (2.5 + V(1)) + 0.3 (1.5 + 0) \Rightarrow$$

$$\Rightarrow V(3) = 0.7 (2.5 + 6.67) + 0.45 \Rightarrow$$

$$\Rightarrow V(3) = 6.42 + 0.45$$

$$\Rightarrow \mathbf{V(3) = 6.87}$$

- **Piso 2:** $P(3|2) = 0.7$ y $P(4|2) = 0.3$.

$$V(2) = 0.7 (2 + V(3)) + 0.3 (2 + 0) \Rightarrow$$

$$\Rightarrow V(2) = 0.7 (2 + 6.87) + 0.6$$

$$\Rightarrow V(2) = 6.21 + 0.6$$

$$\Rightarrow \mathbf{V(2) = 6.81}$$

- **Resultados:** $V(1) = 6.67$, $V(2) = 6.81$, $V(3) = 6.87$

3) Policy Iteration

Asumiendo como política inicial “siempre subir” y el MDP descrito originalmente:

a) Evalúe iterativamente la policy. ¿Coincide este resultado con el punto 2) b)?

- **Piso 4:** $V(4) = 0$
- **Piso 3:** $V(3) = 1 + V(4) = 1 + 0 = 1$
- **Piso 2:** $V(2) = 1 + V(3) = 1 + 1 = 2$
- **Piso 1:** $V(1) = 3 + V(2) = 3 + 2 = 5$
- Efectivamente, los resultados de cada piso coinciden con el punto 2.b

b) Calcule un paso de policy improvement sobre dicha policy. ¿Es la mejor policy?

Para mejorar la política, calculamos el valor de la acción “Esperar” en cada piso usando los valores actuales de V y verificamos si es mejor que la acción actual (Subir).

Como buscamos minimizar tiempo, la mejor acción será la de valor más bajo:

- **Piso 1:**
 - $Q(1, \text{Subir}) = 5$
 - $Q(1, \text{Esperar}) = 0.5 (2 + V(1)) + 0.5 (2 + V(4)) \Rightarrow$
 $\Rightarrow 0.5 (2 + 5) + 0.5 (2 + 0) = 3.5 + 1 = 4.5$
 - Decisión: Como $4.5 < 5$, **cambiamos a Esperar.**
- **Piso 2:**
 - $Q(2, \text{Subir}) = 2$
 - $Q(2, \text{Esperar}) = 0.5 (2 + V(3)) + 0.5 (2 + V(4)) \Rightarrow$
 $\Rightarrow 0.5 (2 + 1) + 0.5 (2 + 0) = 1.5 + 1 = 2.5$
 - Decisión: Como $2 < 2.5$, **mantenemos Subir.**
- **Piso 3:**
 - $Q(3, \text{Subir}) = 1$
 - $Q(3, \text{Esperar}) = 0.5 (2.5 + V(1)) + 0.5 (1.5 + V(4)) \Rightarrow$
 $\Rightarrow 0.5 (2.5 + 5) + 0.5 (1.5 + 0) = 3.75 + 0.75 = 4.5$
 - Decisión: Como $1 < 4.5$, **mantenemos Subir.**

Nueva Política: {Piso 1: Esperar, Piso 2: Subir, Piso 3: Subir}.

¿Es la mejor? Aún no podemos asegurarlo; el cambio en la acción del Piso 1 podría alterar las acciones en otros pisos al volver a calcular utilidades.

c) Calcule un paso más de policy improvement sobre la nueva policy (policy iteration).
Comente los resultados obtenidos.

Primero, debemos re-evaluar los valores de los estados bajo la nueva política **{Piso 1: Esperar, Piso 2: Subir, Piso 3: Subir}**.

$$V(3) = 1 \text{ (Subir)}$$

$$V(2) = 2 \text{ (Subir)}$$

$$\begin{aligned} V(1) &= 0.5 \cdot (2 + V(1)) + 0.5 \cdot (2 + V(4)) \Rightarrow \\ &\Rightarrow 0.5 \cdot V(1) = 2 \Rightarrow \\ &\Rightarrow V(1) = 4 \text{ (Esperar)} \end{aligned}$$

Ahora aplicamos nuevamente el paso de mejora (**Policy Improvement**) con estos valores:

- **Piso 1:**
 $Q(1, \text{Subir}) = 3 + V(2) = 3 + 2 = 5$
Comparado con $V(1) = 4 \rightarrow$ Se mantiene **Esperar**
- **Piso 2:**
 $Q(2, \text{Subir}) = 2$
 $Q(2, \text{Esperar}) = 0.5 \cdot (2 + V(3)) + 0.5 \cdot (2 + 0)$
 $= 0.5 \cdot (3) + 1 = 2.5 \rightarrow$ Se mantiene **Subir**
- **Piso 3:**
 $Q(3, \text{Subir}) = 1$
 $Q(3, \text{Esperar}) = 0.5 \cdot (2.5 + V(1)) + 0.5 \cdot (1.5 + 0)$
 $= 0.5 \cdot (6.5) + 0.75 = 4 \rightarrow$ Se mantiene **Subir**

Resultados: La política no cambió en esta iteración.

Según la teoría de Programación Dinámica, cuando el paso de mejora no produce cambios en la política, se ha alcanzado la **política óptima** (π^*), y las funciones de valor han convergido a los **valores óptimos** (V^*).

Por lo tanto, la mejor estrategia es:

- **Esperar en el piso 1**
- **Subir en los demás pisos**

4) Value Iteration

Dadas las mismas condiciones que en el punto 3), calcule value iteration sobre el MDP planteado.

Considerando $\gamma = 1$, el objetivo es **minimizar el tiempo para llegar al piso 4**, con $V(4) = 0$.

Las ecuaciones de actualización para cada piso son:

Piso 1:

$$\min(3 + V(2) \text{ [Subir]}, 2 + 0.5 \cdot V(1) + 0.5 \cdot V(4) \text{ [Esperar]})$$

Piso 2:

$$\min(1 + V(3) \text{ [Subir]}, 2 + 0.5 \cdot V(3) + 0.5 \cdot V(4) \text{ [Esperar]})$$

Piso 3:

$$\min(1 + V(4) \text{ [Subir]}, 0.5 \cdot (2.5 + V(1)) + 0.5 \cdot (1.5 + V(4)) \text{ [Esperar]})$$

Desarrollo de las iteraciones

(Iniciando con $V = 0$)

Iteración 1:

$$V(1) = \min(3 + 0, 2 + 0) = 2 \rightarrow (\text{Acción: Esperar})$$

$$V(2) = \min(1 + 0, 2 + 0) = 1 \rightarrow (\text{Acción: Subir})$$

$$V(3) = \min(1 + 0, 2 + 0) = 1 \rightarrow (\text{Acción: Subir})$$

Iteración 2:

$$V(1) = \min(3 + 1, 2 + 0.5 \cdot (2)) = \min(4, 3) = 3$$

$$V(2) = \min(1 + 1, 2 + 0.5 \cdot (1)) = \min(2, 2.5) = 2$$

$$V(3) = \min(1, 2 + 0.5 \cdot (2)) = \min(1, 3) = 1$$

Iteración 3:

$$V(1) = \min(3 + 2, 2 + 0.5 \cdot (3)) = \min(5, 3.5) = 3.5$$

$$V(2) = \min(1 + 1, 2.5) = 2$$

$$V(3) = \min(1, 2 + 0.5 \cdot (3)) = 1$$

Convergencia

Si seguimos iterando, el valor de $V(1)$ sigue la secuencia: 3.75, 3.875, ... hasta converger asintóticamente a 4.

Valores finales óptimos

$$V^*(1) = 4$$

$$V^*(2) = 2$$

$$V^*(3) = 1$$

¿Qué comentarios tiene sobre este resultado y el de 3)c)?

El resultado final de Value Iteration es idéntico al obtenido en el punto 3c mediante Policy Iteration. Ambos métodos convergen a la misma utilidad óptima y, por ende, a la misma política óptima: {Piso 1: Esperar, Piso 2: Subir, Piso 3: Subir}.

En Policy Iteration, se alcanzó la solución óptima de forma más rápida porque al evaluar la política completa en cada paso se alcanzan los valores de equilibrio de esa política.

En Value Iteration, la convergencia es más lenta (especialmente para $V(1)$), ya que el valor se actualiza de forma incremental paso a paso.

Policy Iteration busca en el espacio de las políticas (mapeo de acciones), Value Iteration busca directamente en el espacio de las funciones de valor.

En este problema pequeño, Policy Iteration resultó ser más directo, pero Value Iteration debería ser más sencillo de implementar computacionalmente en problemas grandes.

Nota

Se considera $\gamma = 1$ para todos los ejercicios.