

Fecha: 12/05/2025	Duración: 2 h	Página 1 de 12
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

Ejercicio 1:

Usted ha sido contratado/a por una empresa de logística para desarrollar un sistema de control de drones autónomos de reparto. Como parte del prototipo inicial, decide modelar un entorno simplificado que le permita aplicar técnicas de planificación vistas en el curso. Para ello, le solicita a un LLM que genere un entorno de prueba. La siguiente es la propuesta generada:

Estados:

Estado S0: "Estación de carga"

Estado S1: "En reparto"

Estado S2: "Fallo de batería"

Acciones:

Acción A0: "Continuar ruta"

Acción A1: "Salir a reparto"

Acción A2: "Regresar a estación"

Acciones(S0) = {A1}

Acciones(S1) = {A0, A2}

Recompensas:

Recompensa R0: -1 (coste operativo normal)

Recompensa R1: -100 (fallo grave)

Dinámica:

$P(S1, R0 | S0, A1) = 0.9$

$P(S2, R1 | S0, A1) = 0.1$

$P(S1, R0 | S1, A0) = 0.8$

$P(S2, R1 | S1, A0) = 0.2$

$P(S0, R0 | S1, A2) = 0.5$

$P(S2, R1 | S1, A2) = 0.5$

Suponga la política π definida como:

$\pi(A1 | S0) = 1$

$\pi(A0 | S1) = 0.7$

$\pi(A2 | S1) = 0.3$

Se pide:


1. Calcule analíticamente el valor de la política π para todos los estados.
2. Calcule un paso de Policy Iteration.

Asuma $\gamma = 1$ y $\alpha = 1$.

Fecha: 12/05/2025	Duración: 2 h	Página 2 de 12
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

SOLUCIÓN:

1. Para entender mejor el problema diagramamos el MDP.



Paso 1. Sistema de ecuaciones:

- (1) $v_{\pi}(S_2) = 0$
- (2) $v_{\pi}(S_0) = 0.9 \cdot (\gamma \cdot v_{\pi}(S_1) - 1) + 0.1 \cdot (\gamma \cdot v_{\pi}(S_2) - 100)$
- (3) $v_{\pi}(S_1) = 0.3 \cdot [0.5 \cdot (\gamma \cdot v_{\pi}(S_0) - 1) + 0.5 \cdot (\gamma \cdot v_{\pi}(S_2) - 100)] + 0.7 \cdot [0.8 \cdot (\gamma \cdot v_{\pi}(S_1) - 1) + 0.2 \cdot (\gamma \cdot v_{\pi}(S_2) - 100)]$

Paso 2. Sustituyendo gamma por 1:

- (1) $v_{\pi}(S_2) = 0$
- (2) $v_{\pi}(S_0) = 0.9 \cdot (v_{\pi}(S_1) - 1) + 0.1 \cdot (v_{\pi}(S_2) - 100)$
- (3) $v_{\pi}(S_1) = 0.3 \cdot [0.5 \cdot (v_{\pi}(S_0) - 1) + 0.5 \cdot (v_{\pi}(S_2) - 100)] + 0.7 \cdot [0.8 \cdot (v_{\pi}(S_1) - 1) + 0.2 \cdot (v_{\pi}(S_2) - 100)]$

Paso 3. Sustituimos vS2 en vS0:

$$\begin{aligned}
 v_{\pi}(S_0) &= 0.9(v_{\pi}(S_1) - 1) + 0.1(0 - 100) \\
 &= 0.9v_{\pi}(S_1) - 0.9 - 10 \\
 &= 0.9v_{\pi}(S_1) - 10.9
 \end{aligned}$$

Fecha: 12/05/2025	Duración: 2 h	Página 3 de 12
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

Paso 4. Sustituimos v_{S2} en v_{S1} :

$$\begin{aligned}
 v_{\pi}(S_1) &= 0.3 \cdot [0.5(v_{\pi}(S_0) - 1) + 0.5(-100)] + 0.7 \cdot [0.8(v_{\pi}(S_1) - 1) + 0.2(-100)] \\
 &= 0.3 \cdot (0.5v_{\pi}(S_0) - 0.5 - 50) + 0.7 \cdot (0.8v_{\pi}(S_1) - 0.8 - 20) \\
 &= 0.3(0.5v_{\pi}(S_0) - 50.5) + 0.7(0.8v_{\pi}(S_1) - 20.8) \\
 &= 0.15v_{\pi}(S_0) - 15.15 + 0.56v_{\pi}(S_1) - 14.56 \\
 &= 0.15v_{\pi}(S_0) + 0.56v_{\pi}(S_1) - 29.71
 \end{aligned}$$

Paso 5. Sustituimos paso 3 en paso 4:

$$\begin{aligned}
 v_{\pi}(S_0) &= 0.9v_{\pi}(S_1) - 10.9 \\
 \Rightarrow v_{\pi}(S_1) &= 0.15(0.9v_{\pi}(S_1) - 10.9) + 0.56v_{\pi}(S_1) - 29.71 \\
 &= 0.135v_{\pi}(S_1) - 1.635 + 0.56v_{\pi}(S_1) - 29.71 \\
 &= 0.695v_{\pi}(S_1) - 31.345 \\
 \Rightarrow v_{\pi}(S_1) - 0.695v_{\pi}(S_1) &= -31.345 \\
 0.305v_{\pi}(S_1) &= -31.345 \\
 v_{\pi}(S_1) &= \frac{-31.345}{0.305} \approx -102.1
 \end{aligned}$$

Paso 6. Finalmente:

$$v_{\pi}(S_0) = 0.9 \cdot (-102.1) - 10.9 \approx -102.8$$

Resultado:

$ \begin{aligned} v_{\pi}(S_0) &\approx -102.8 \\ v_{\pi}(S_1) &\approx -102.1 \\ v_{\pi}(S_2) &= 0 \end{aligned} $

Fecha: 12/05/2025	Duración: 2 h	Página 4 de 12
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

2. Policy Evaluation con Programación dinámica:

El sistema de ecuaciones guiará el llenado de la tabla,

$$v_{\pi}^{(t)}(S_2) = 0 \quad (\text{fijo})$$

$$\begin{aligned} v_{\pi}^{(t)}(S_0) &= 0.9 \cdot (v_{\pi}^{(t-1)}(S_1) - 1) + 0.1 \cdot (0 - 100) \\ &= 0.9v_{\pi}^{(t-1)}(S_1) - 10.9 \end{aligned}$$

$$\begin{aligned} v_{\pi}^{(t)}(S_1) &= 0.3 \cdot \left[0.5 \cdot (v_{\pi}^{(t-1)}(S_0) - 1) + 0.5 \cdot (-100) \right] \\ &\quad + 0.7 \cdot \left[0.8 \cdot (v_{\pi}^{(t-1)}(S_1) - 1) + 0.2 \cdot (-100) \right] \\ &= 0.3 \cdot (0.5v_{\pi}^{(t-1)}(S_0) - 50.5) + 0.7 \cdot (0.8v_{\pi}^{(t-1)}(S_1) - 20.8) \\ &= 0.15v_{\pi}^{(t-1)}(S_0) + 0.56v_{\pi}^{(t-1)}(S_1) - 29.71 \end{aligned}$$

Paso	V(S0)	V(S1)	V(S2)	Δ (Delta)
0	0.00	0.00	0.00	—
1	-10.90	-20.80	0.00	20.80
2	-29.62	-37.44	0.00	18.72
3	-44.60	-50.75	0.00	14.98
4	-56.58	-61.40	0.00	11.98
5	-66.16	-69.92	0.00	9.58
6	-73.83	-76.74	0.00	7.67
7	-79.96	-82.19	0.00	6.13
8	-84.87	-86.55	0.00	4.91
9	-88.80	-90.04	0.00	3.93
10	-91.94	-92.83	0.00	3.14
11	-94.45	-95.07	0.00	2.51
12	-96.46	-96.85	0.00	2.01
13	-98.07	-98.28	0.00	1.61
14	-99.35	-99.43	0.00	1.29
15	-100.38	-100.34	0.00	1.03

Fecha: 12/05/2025	Duración: 2 h	Página 5 de 12
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

Ejercicio 2:

En el entorno simplificado de control de drones de reparto definido anteriormente, ahora desea entrenar un controlador usando aprendizaje por refuerzo mediante algoritmos de diferencias temporales (se considera el mismo conjunto de estados y acciones).

Usted observa las siguientes tres transiciones durante una ejecución con política ϵ -greedy:

1. (S0, A1, R = -1, S1)
2. (S1, A0, R = -1, S1)
3. (S1, A2, R = -100, S2)

Suponga que todas las $Q(s,a)$ están inicializadas en 0..

Se pide:

1. Aplique el algoritmo de **Q-Learning** paso a paso sobre las tres transiciones observadas, actualizando la tabla Q después de cada una.
2. Presente la tabla Q final obtenida luego de las tres actualizaciones.
3. ¿Qué ventajas tiene Q-Learning respecto de los métodos de planificación como *policy iteration* en este tipo de entornos?

Asuma $\gamma = 1$ y $\alpha = 1$.

SOLUCIÓN:

1. Fórmula de actualización de Q-Learning:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[R + \gamma \cdot \max_{a'} Q(s', a') - Q(s, a) \right]$$

Transición 1: (S0,A1,-1,S1)

- Estado actual: S0
- Acción: A1
- Recompensa: -1
- Siguiente estado: S1

$\max_a Q(S1,a) = 0$

Fecha: 12/05/2025	Duración: 2 h	Página 6 de 12
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

$$Q(S_0, A_1) = -1 + 1 \cdot 0 = -1$$

Transición 2: (S1,A0,-1,S1)

- Estado actual: S1
- Acción: A0
- Recompensa: -1
- Siguiendo estado: S1

$$\max_a Q(S_1, a) = 0$$

$$Q(S_1, A_0) = -1 + 1 \cdot 0 = -1$$

Transición 3: (S1,A2,-100,S2)

- Estado actual: S1
- Acción: A2
- Recompensa: -100
- Siguiendo estado: S2

$$\max_a Q(S_2, a) = 0$$

$$Q(S_1, A_2) = -100 + 1 \cdot 0 = -100$$

2.

Q	A0	A1	A2
S0	0	-1	0
S1	-1	0	-100
S2	0	0	0

3. Ventajas de Q-Learning:

No requiere conocimiento del modelo:

Q-Learning es modelo libre ("model-free"), por lo que no necesita conocer las probabilidades de transición ni recompensas del entorno.

Aprende directamente de la experiencia:

Es útil cuando el entorno es complejo o desconocido, ya que se entrena interactuando con él.

Fecha: 12/05/2025	Duración: 2 h	Página 7 de 12
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

Flexible ante cambios:

Se adapta mejor a entornos dinámicos donde el modelo puede cambiar con el tiempo.

Escalabilidad:

Puede manejar entornos grandes o continuos mejor que métodos como Policy Iteration, que requieren una descripción completa del entorno y cálculo intensivo.

Fecha: 12/05/2025	Duración: 2 h	Página 8 de 12
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	


Ejercicio 3:

Un club bailable decide innovar en su industria proponiendo el desarrollo de un robot bartender, que se encargará de atender una de sus barras vendiendo bebidas. Para ello contratan a un equipo de investigadores que construirá un prototipo inicial (que solo venderá cerveza tirada), el cual desarrollarán en base a la observación del trabajo de bartenders humanos en una de una de las barras. Para ello deciden plantear su problema de servir bebidas como un Markov Decision Process (MDP), de modo tal que partiendo de un cierto estado, ser capaz de ir seleccionando las acciones a tomar en función de la cantidad de cerveza en los barriles, a fin de mantener una carga adecuada y con esta lograr reducir el tiempo de mantenimiento de los tanques a la vez de maximizar las ventas.



Figura 1: Figura ilustrativa del robot bartender con dos clientes. Tomado de [1].

Dada la siguiente secuencia observada de la ejecución de una política humana π_h :



1. Grafique el MDP.
2. Haga una iteración del cálculo del valor de la política π_h mediante la técnica de estimación Monte Carlo de valor de políticas "every visit".

[1]Keizer, S., Foster, M.E., Lemon, O., Gaschler, A., & Giuliani, M. (2013). Training and evaluation of an MDP model for social multi-user human-robot interaction. *SIGDIAL Conference*.

Fecha: 12/05/2025	Duración: 2 h	Página 9 de 12
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

SOLUCIÓN:

En el MDP identificamos las transiciones:

Desde	Acción	Recompensa	Hacia
Lleno	Vender Cerveza	+1	Lleno
Lleno	Vender Cerveza	+1	Mediacarga
Mediacarga	Vender Cerveza	+1	Vacío
Vacío	Cargar Cerveza	-2	Mediacarga
Mediacarga	Vender Cerveza	+2	Vacío
Vacío	Cargar Cerveza	-1	Lleno
Lleno	Vender Cerveza	+3	Lleno
Lleno	Vender Cerveza	+1	Lleno
Lleno	Vender Cerveza	+2	Mediacarga
Mediacarga	Vender Cerveza	+2	Vacío
Vacío	Vender Cerveza	-12	Colapso

Esta tabla nos permite estimar p:

Contamos para cada par (s,a) cuántas veces ocurrió cada combinación (s',r):

(Lleno, Vender Cerveza)

Próximo estado	Recompensa	Cantidad	Probabilidad
Lleno	+1	2	$2 / 5 = 0.40$
Lleno	+3	1	$1 / 5 = 0.20$
Mediacarga	+1	1	$1 / 5 = 0.20$
Mediacarga	+2	1	$1 / 5 = 0.20$
Total		5	

Fecha: 12/05/2025

Evaluación: Parcial

Materia: Agentes Inteligentes

Turno: Nocturno

Duración: 2 h

Uso de Calculadora: SI

Uso de Material: NO

Puntaje Máximo: 30 Puntos

**Página 10 de
12**

(Mediacarga, Vender Cerveza)

Próximo estado	Recompensa	Cantidad	Probabilidad
Vacío	+1	1	$1 / 3 \approx 0.33$
Vacío	+2	2	$2 / 3 \approx 0.67$
Total		3	


(Vacío, Cargar Cerveza)

Próximo estado	Recompensa	Cantidad	Probabilidad
Mediacarga	-2	1	$1 / 2 = 0.50$
Lleno	-1	1	$1 / 2 = 0.50$
Total		2	

(Vacío, Vender Cerveza)

Próximo estado	Recompensa	Cantidad	Probabilidad
Colapso	-12	1	$1 / 1 = 1.00$
Total		1	

MDP:



Fecha: 12/05/2025	Duración: 2 h	Página 11 de 12
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

2.

Episodio 1				
Paso del for interno	Paso hacia atrás	G	Suma	Estado
0	T	-	-	Colapso
1	T-1	-12	-12	Vacío
2	T-2	-12+2	-10	Mediacarga
3	T-3	-12 +2 +2	-8	Lleno
4	T-4	-12 +2 +2+1	-7	Lleno
5	T-5	-12 +2 +2+1+3	-4	Lleno
6	T-6	-12 +2 +2+1+3-1	-5	Vacío
7	T-7	-12 +2 +2+1+3-1+2	-3	Mediacarga
8	T-8	-12 +2 +2+1+3-1+2-2	-5	Vacío
9	T-9	-12 +2 +2+1+3-1+2-2+1	-4	Mediacarga
10	T-10	-12 +2 +2+1+3-1+2-2+1+1	-3	Lleno
11	T-11	-12 +2 +2+1+3-1+2-2+1+1+1	-2	Lleno

Estado	Cantidad Visitas	Retornos posteriores	Promedio
Lleno	5	[-8,-7,-4,-3,-2]	-24/5
Mediacarga	3	[-10,-3,-4]	-17/3
Vacío	3	[-12, -5, -5]	-22/3
Colapso	1	-	0

Fecha: 12/05/2025	Duración: 2 h	Página 12 de 12
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

Fórmulas de interés:

$$v_{\pi}(s) = \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a) [r + \gamma v_{\pi}(s')]$$

$$q_{\pi}(s,a) = \sum_{s',r} p(s',r|s,a) [r + \gamma v_{\pi}(s')]$$