

Fecha: 12/05/2025	Duración: 2 h	Página 1 de 4
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

Ejercicio 1:

Usted ha sido contratado/a por una empresa de logística para desarrollar un sistema de control de drones autónomos de reparto. Como parte del prototipo inicial, decide modelar un entorno simplificado que le permita aplicar técnicas de planificación vistas en el curso. Para ello, le solicita a un LLM que genere un entorno de prueba. La siguiente es la propuesta generada:

Estados:

Estado S0: "Estación de carga"

Estado S1: "En reparto"

Estado S2: "Fallo de batería"

Acciones:

Acción A0: "Continuar ruta"

Acción A1: "Salir a reparto"

Acción A2: "Regresar a estación"

Acciones(S0) = {A1}

Acciones(S1) = {A0, A2}

Recompensas:

Recompensa R0: -1 (coste operativo normal)

Recompensa R1: -100 (fallo grave)

Dinámica:

$P(S1, R0 | S0, A1) = 0.9$

$P(S2, R1 | S0, A1) = 0.1$

$P(S1, R0 | S1, A0) = 0.8$

$P(S2, R1 | S1, A0) = 0.2$

$P(S0, R0 | S1, A2) = 0.5$

$P(S2, R1 | S1, A2) = 0.5$

Suponga la política π definida como:

$\pi(A1 | S0) = 1$

$\pi(A0 | S1) = 0.7$

$\pi(A2 | S1) = 0.3$

Se pide:

1. Calcule analíticamente el valor de la política π para todos los estados.
2. Calcule un paso de Policy Iteration.

Asuma $\gamma = 1$ y $\alpha = 1$.

Fecha: 12/05/2025	Duración: 2 h	Página 2 de 4
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

Ejercicio 2:

En el entorno simplificado de control de drones de reparto definido anteriormente, ahora desea entrenar un controlador usando aprendizaje por refuerzo mediante algoritmos de diferencias temporales (se considera el mismo conjunto de estados y acciones).

Usted observa las siguientes tres transiciones durante una ejecución con política ϵ -greedy:

1. ($S_0, A_1, R = -1, S_1$)
2. ($S_1, A_0, R = -1, S_1$)
3. ($S_1, A_2, R = -100, S_2$)

Suponga que todas las $Q(s,a)$ están inicializadas en 0..

Se pide:

1. Aplique el algoritmo de **Q-Learning** paso a paso sobre las tres transiciones observadas, actualizando la tabla Q después de cada una.
2. Presente la tabla Q final obtenida luego de las tres actualizaciones.
3. ¿Qué ventajas tiene Q-Learning respecto de los métodos de planificación como *policy iteration* en este tipo de entornos?

Asuma $\gamma = 1$ y $\alpha = 1$.

Fecha: 12/05/2025	Duración: 2 h	Página 3 de 4
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	


Ejercicio 3:

Un club bailable decide innovar en su industria proponiendo el desarrollo de un robot bartender, que se encargará de atender una de sus barras vendiendo bebidas. Para ello contratan a un equipo de investigadores que construirá un prototipo inicial (que solo venderá cerveza tirada), el cual desarrollarán en base a la observación del trabajo de bartenders humanos en una de una de las barras. Para ello deciden plantear su problema de servir bebidas como un Markov Decision Process (MDP), de modo tal que partiendo de un cierto estado, ser capaz de ir seleccionando las acciones a tomar en función de la cantidad de cerveza en los barriles, a fin de mantener una carga adecuada y con esta lograr reducir el tiempo de mantenimiento de los tanques a la vez de maximizar las ventas.



Figura 1: Figura ilustrativa del robot bartender con dos clientes. Tomado de [1].

Dada la siguiente secuencia observada de la ejecución de una política humana π_h :



1. Grafique el MDP.
2. Haga una iteración del cálculo del valor de la política π_h mediante la técnica de estimación Monte Carlo de valor de políticas "every visit".

[1]Keizer, S., Foster, M.E., Lemon, O., Gaschler, A., & Giuliani, M. (2013). Training and evaluation of an MDP model for social multi-user human-robot interaction. *SIGDIAL Conference*.

Fecha: 12/05/2025	Duración: 2 h	Página 4 de 4
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

Fórmulas de interés:

$$v_{\pi}(s) = \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a) [r + \gamma v_{\pi}(s')]$$

$$q_{\pi}(s,a) = \sum_{s',r} p(s',r|s,a) [r + \gamma v_{\pi}(s')]$$