

Fecha: 11/05/2026	Duración: 2 h	Página 1 de 3
Evaluación: Parcial 1	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

Ejercicio 1:

Usted ha sido contratado/a por una empresa de logística para desarrollar un sistema de control de brazos robóticos de ensamblaje. Como parte del prototipo inicial, decide modelar un entorno simplificado que le permita aplicar técnicas de planificación vistas en el curso. Para ello, le solicita a un LLM que genere un entorno de prueba. La siguiente es la propuesta generada:

Estados:

Estado S0 : "En espera" (idle)
Estado S1: "Ensamblando"
Estado S2: "Fallo mecánico"

Acciones:

Acción A0: "Continuar ensamblaje"
Acción A1: "Iniciar tarea"
Acción A2: "Pausar y verificar"

Acciones(S0) = {A1}

Acciones(S1) = {A0, A2}

Recompensas:

Recompensa R0: -16 (coste operativo normal)
Recompensa R1: -30 (fallo en línea)

Dinámica:

$P(S1, R0 | S0, A1) = 0.8$
 $P(S2, R1 | S0, A1) = 0.2$
 $P(S1, R0 | S1, A0) = 0.8$
 $P(S2, R1 | S1, A0) = 0.2$
 $P(S0, R0 | S1, A2) = 0.5$
 $P(S2, R1 | S1, A2) = 0.5$

Suponga la política π definida como:

$\pi(A1 | S0) = 1$
 $\pi(A0 | S1) = 0.5$
 $\pi(A2 | S1) = 0.5$

Se pide:

1. Grafique el MDP
2. Calcule analíticamente el valor de la política π para todos los estados.
3. Calcule Value Iteration para π .

Asuma $\gamma = 1$ y $\alpha = 1$.

Fecha: 11/05/2026	Duración: 2 h	Página 2 de 3
Evaluación: Parcial 1	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 30 Puntos	

Ejercicio 2:

En el entorno simplificado de control de brazos robóticos definido anteriormente, ahora desea entrenar un controlador usando aprendizaje por refuerzo mediante algoritmos de diferencias temporales (se considera el mismo conjunto de estados y acciones).

Usted observa las siguientes tres transiciones durante una ejecución con política ϵ -greedy:

1. (S0, A1, R = -1, S1)
2. (S1, A0, R = -1, S1)
3. (S1, A2, R = -100, S2)

Suponga que Q(s,a) está inicializada como la siguiente tabla:

Q	A0	A1	A2
S0	10	1	5
S1	1	0	30
S2	-10	-15	50

Se pide:

1. Aplique el algoritmo de **SARSA** paso a paso sobre las tres transiciones observadas, actualizando la tabla Q después de cada una.
2. Presente la tabla Q final obtenida luego de las tres actualizaciones.
3. ¿Qué diferencia tiene SARSA respecto a Q-Learning?

Asuma $\gamma = 1$ y $\alpha = 0.5$.

Si para alguna actualización necesita que una acción se seleccione al azar, asuma que esta es A0.

Fecha: 11/05/2026

Evaluación: Parcial 1

Materia: Agentes Inteligentes

Turno: Nocturno

Duración: 2 h

Uso de Calculadora: SI



Uso de Material: NO

Puntaje Máximo: 30 Puntos

Página 3 de 3

Ejercicio 3:

Las siguientes gráficas son representaciones de valores de estados computados con técnicas de estimación MonteCarlo.



1. Describa las diferencias entre las gráficas y explique a que se pueden deber.
2. ¿Cuál es la diferencia entre estas técnicas y las de diferencias temporales? Sea conciso en su explicación.

Fórmulas de interés:

$$v_{\pi}(s) = \sum_a \pi(a|s) \sum_{s', r} p(s', r|s, a) [r + \gamma v_{\pi}(s')]$$

$$q_{\pi}(s, a) = \sum_{s', r} p(s', r|s, a) [r + \gamma v_{\pi}(s')]$$