

Fecha: 07/07/2025	Duración: 2 h	Página 1 de 4
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 50 Puntos	

Ejercicio 1:

Dada la siguiente fórmula de actualización de gradientes:

$$\mathbf{w} \leftarrow \mathbf{w} + \alpha [R + \gamma \max_a \hat{q}(S', a, \mathbf{w}) - \hat{q}(S, A, \mathbf{w})] \nabla \hat{q}(S, A, \mathbf{w})$$

1. ¿A qué algoritmo visto en el curso corresponde?
2. Indique que es lo que se está derivando y lo que no. ¿Por qué se tratan así los gradientes?
3. ¿Es esta técnica on u off policy? Justifique.

Ejercicio 2:

1. Explicar por qué el bootstrapping de n pasos se considera una generalización de los métodos MC y TD.
2. ¿Qué diferencia hay entre el target de método montecarlo y el de bootstrapping de 3 pasos (tipo SARSA) para estimar Q? Planteelos.

Ejercicio 3:

Supongamos que estás diseñando un estimador de la función valor $Q(s)$ para un agente de DQN que opera en un entorno con un espacio de observación de dimensión 256 (por ejemplo, un robot que percibe su entorno mediante 256 sensores).

Proponés utilizar una red neuronal con la siguiente arquitectura:

Capa de Entrada: 256 neuronas

Capa Oculta 1: 128 neuronas

Capa Oculta 2: 64 neuronas

Capa de Salida: 10 neuronas

Fecha: 07/07/2025	Duración: 2 h	Página 2 de 4
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 50 Puntos	

Se utilizan funciones de activación ReLU para las capas ocultas y Softmax para la salida.

Capa	# de Pesos	# de Neuronas de Entrada	# de Neuronas de Salida	# de Sesgos	# Total de Parámetros
FC1					
FC2					
FC3					

Se pide:

1. Completa la tabla indicando el número de pesos, sesgos y parámetros totales en cada capa.
2. Calcula el número total de parámetros entrenables de la red.
3. ¿Cuántas acciones puede hacer el robot?

Fecha: 07/07/2025	Duración: 2 h	Página 3 de 4
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 50 Puntos	

Ejercicio 4:

Dados el siguiente pseudo-código:

Tabular Dyna-Q


```

Initialize  $Q(s, a)$  and  $Model(s, a)$  for all  $s \in \mathcal{S}$  and  $a \in \mathcal{A}(s)$ 
Loop forever:
  (a)  $S \leftarrow$  current (nonterminal) state
  (b)  $A \leftarrow \varepsilon$ -greedy( $S, Q$ )
  (c) Take action  $A$ ; observe resultant reward,  $R$ , and state,  $S'$ 
  (d)  $Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma \max_a Q(S', a) - Q(S, A)]$ 
  (e)  $Model(S, A) \leftarrow R, S'$  (assuming deterministic environment)
  (f) Loop repeat  $n$  times:
     $S \leftarrow$  random previously observed state
     $A \leftarrow$  random action previously taken in  $S$ 
     $R, S' \leftarrow Model(S, A)$ 
     $Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma \max_a Q(S', a) - Q(S, A)]$ 

```

Se pide:

1. Explicar en detalle para el algoritmo A) qué instrucciones realizan cada uno de los pasos "acting", "direct RL", "model learning" y "planning", según el siguiente diagrama de planificación online:



2. Explique qué pasos del algoritmo modificaría y cómo, a fin de implementar barrido priorizado y como afecta esto a la actualización de valores, sea conciso.

Fecha: 07/07/2025	Duración: 2 h	Página 4 de 4
Evaluación: Parcial	Uso de Calculadora: SI	
Materia: Agentes Inteligentes	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo: 50 Puntos	

Fórmulas de interés:

$$v_{\pi}(s) = \sum_a \pi(a|s) \sum_{s',r} p(s',r|s,a) [r + \gamma v_{\pi}(s')]$$

$$q_{\pi}(s,a) = \sum_{s',r} p(s',r|s,a) [r + \gamma v_{\pi}(s')]$$