

Fecha: 24/02/2026	Duración: 2 h	Página 1 de 3
Evaluación: Segunda Instancia	Uso de Calculadora: SI	
Materia: Inteligencia Artificial Generativa	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo/Mínimo: 30/ 1 Puntos	

Ejercicio 1 - Language Models (LMs) (8 puntos)

- ¿Qué es un Language Model?
- Implementa en pseudocódigo el proceso de generación de secuencias de un LM.

Ejercicio 2 - Generative Adversarial Networks (GANs) (8 puntos)

- La siguiente expresión corresponde a la pérdida adversarial utilizada en GANs clásicas:

$$\min_G \max_D \mathbb{E}_{x \sim p_{\text{data}}} [\log D(x)] + \mathbb{E}_{z \sim p(z)} [\log(1 - D(G(z)))]$$


Explique brevemente el rol de cada uno de los dos términos y cómo se relacionan con los objetivos del generador y el discriminador.

- Describa en pseudocódigo simple cómo se entrena la GAN.
Debe incluir:
 - muestras reales,
 - muestras falsas,
 - actualización de D,
 - actualización de G
- ¿Cómo se generan nuevas muestras durante la inferencia?(Explique en 1 o 2 líneas.)

Fecha: 24/02/2026	Duración: 2 h	Página 2 de 3
Evaluación: Segunda Instancia	Uso de Calculadora: SI	
Materia: Inteligencia Artificial Generativa	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo/Mínimo: 30/ 1 Puntos	

Ejercicio 3 - Diffusion Models (6 puntos)

Dada la siguiente imagen:



1. Explique a alto nivel qué significa “aprender a invertir el proceso de difusión” y por qué esto permite generar imágenes desde ruido.
2. En clase vimos que en la práctica, el entrenamiento del modelo de difusión se reduce a minimizar:

$$\mathcal{L}_{VLB} \approx \mathbb{E}_{t, \mathbf{x}_0, \epsilon} \left[\|\epsilon - \epsilon_{\theta}(\mathbf{x}_t, t)\|^2 \right]$$

Explique:

- a) Qué representa cada término de la expresión.
- b) Por qué esta pérdida MSE es equivalente a optimizar la cota variacional.
- c) Qué significa intuitivamente “aprender a predecir el ruido”.

Fecha: 24/02/2026	Duración: 2 h	Página 3 de 3
Evaluación: Segunda Instancia	Uso de Calculadora: SI	
Materia: Inteligencia Artificial Generativa	Uso de Material: NO	
Turno: Nocturno	Puntaje Máximo/Mínimo: 30/ 1 Puntos	

Ejercicio 4 - Variational Autoencoders (VAEs) (8 puntos)

- Dado el siguiente desarrollo que presenta una equivalencia para el gradiente de una esperanza sobre una distribución parametrizada por θ :

$$\begin{aligned}
 \nabla_{\theta} \mathbb{E}_{p_{\theta}(z)} [f_{\theta}(z)] &= \nabla_{\theta} \left[\int_z p_{\theta}(z) f_{\theta}(z) dz \right] \\
 &= \int_z \nabla_{\theta} [p_{\theta}(z) f_{\theta}(z)] dz \\
 &= \int_z f_{\theta}(z) \nabla_{\theta} p_{\theta}(z) dz + \int_z p_{\theta}(z) \nabla_{\theta} f_{\theta}(z) dz \\
 &= \underbrace{\int_z f_{\theta}(z) \nabla_{\theta} p_{\theta}(z) dz}_{\text{Reconstruct the Input Data}} + \mathbb{E}_{p_{\theta}(z)} [\nabla_{\theta} f_{\theta}(z)]
 \end{aligned}$$

Se pide:

- Explique por qué este término NO puede estimarse directamente mediante muestreo Monte Carlo usando muestras de $p_{\theta}(z)$. Mencione la idea general de cómo la reparametrización soluciona esta limitación.
- Describa qué problema práctico genera esto al entrenar modelos como los VAEs.

- La siguiente fórmula expresa el término de Loss utilizado para entrenar VAEs.

$$\log p_{\theta}(x^{(i)}) \geq \mathcal{L}(x^{(i)}, \theta, \phi) = \underbrace{\mathbb{E}_z \left[\log p_{\theta}(x^{(i)} | z) \right]}_{\text{Reconstruct the Input Data}} - \underbrace{D_{KL} \left(q_{\phi}(z | x^{(i)}) \parallel p_{\theta}(z) \right)}_{\text{KL Divergence}}$$

$$\theta^*, \phi^* = \arg \max_{\theta, \phi} \sum_{i=1}^N \mathcal{L}(x^{(i)}, \theta, \phi)$$

Explique por qué el KL tiende a regularizar el espacio latente y qué ocurriría si se retirara completamente.