

# Inteligencia Artificial Generativa

## Historia, motivación y probabilidad básica

Maestría en Inteligencia Artificial

Universidad ORT Uruguay

18 de agosto de 2026

# Objetivos de la clase

- Entender qué estudia la IA generativa y por qué aparece como tema central.
- Ubicar el curso dentro de la evolución IA  $\rightarrow$  ML  $\rightarrow$  deep learning  $\rightarrow$  modelos generativos.
- Repasar la lectura probabilística básica: variables aleatorias, observaciones y distribuciones.
- Conectar probabilidades con una primera tarea práctica: el dataset de tenis.

## Evaluación

- Obligatorio: 40 puntos.
- Trabajos de laboratorio: 30 puntos.
- Parcial: 30 puntos.
- Grupos de hasta 3 estudiantes.

## Herramientas

- Python y notebooks.
- Hugging Face.
- LangChain y ecosistema LLM.
- Bibliografía indicada por clase.

# Recorrido del semestre

| Clase | Teórico                                     | Práctico             |
|-------|---------------------------------------------|----------------------|
| 1     | Historia y motivación. Probabilidad básica. | Tenis, parte 1.      |
| 2     | Probabilidad condicional. Redes bayesianas. | Tenis, parte 2.      |
| 3     | Variables continuas. Perceptrón de Hinton.  | Iris.                |
| 4     | Hinton. KL divergence.                      | Perceptrón MNIST.    |
| 5     | VAE.                                        | Prácticos previos.   |
| 6     | VAE y GAN.                                  | VAE.                 |
| 7     | GAN.                                        | GAN.                 |
| 8     | Letra de obligatorio.                       | Trabajo en práctico. |
| 9     | Introducción a LLM.                         | LLM.                 |
| 10    | Evaluación de LLMs.                         | Continuación LLMs.   |
| 11    | Prácticas de IA generativa.                 | RAG, CoT, ReAct.     |
| 12    | Diffusion models.                           | A definir.           |
| 13    | Consultas obligatorio.                      | Trabajo guiado.      |
| 14    | Prácticas de parcial.                       | Repaso.              |

## Modelado generativo

Aprender una distribución de probabilidad a partir de datos y usarla para generar, completar, transformar o razonar sobre observaciones.

$$p_{\text{data}}(x) \rightsquigarrow p_{\text{model}}(x)$$

La pregunta recurrente del curso será:

**¿Qué estructura de los datos logró capturar el modelo?**

# Una intuición antigua


Ada Lovelace ya imaginaba en 1842 que una máquina analítica podría operar sobre símbolos más allá de los números.

*“The engine might compose elaborate and scientific pieces of music of any degree of complexity or extent.”*

## Lectura moderna


- Una máquina puede manipular representaciones.
- Si la música, el lenguaje o las imágenes tienen estructura, esa estructura puede ser modelada.
- Generar no es copiar: es muestrear desde una representación aprendida.

## MACHINE LEARNING TIMELINE



Fuente: <https://www.algotive.ai/blog/machine-learning-what-is-ml-and-how-does-it-work>


# De IA a IA generativa



- La IA clásica enfatiza reglas, búsqueda y representación explícita.
- Machine learning desplaza el foco hacia datos y generalización.
- Deep learning aprende representaciones jerárquicas.
- Los modelos generativos aprenden distribuciones de datos complejas.



# Deep learning: una historia de arquitecturas



Fuente: D. Mourtzis y J. Angelopoulos. <https://link.springer.com/article/10.1007/s00170-020-06192-y>


# ¿Por qué ahora?

- Más datos digitales: texto, imágenes, audio, video, código, interacciones.
- Más cómputo: GPUs, clusters y entrenamiento distribuido.
- Mejores arquitecturas: VAEs, GANs, transformers, diffusion models.
- Ecosistemas maduros: datasets, modelos preentrenados y APIs.

## Cambio importante

Pasamos de modelos diseñados para una tarea cerrada a modelos capaces de producir objetos nuevos con estructura.

# IA generativa: modelos y familias



Fuente: David Foster. Founding Partner, ADSP. Author of *Generative Deep Learning* (O'Reilly).

# También aparecen riesgos

- Alucinaciones y respuestas no verificadas.
- Sesgos aprendidos de los datos.
- Uso indebido: fraude, desinformación, generación de contenido dañino.
- Incidentes operacionales por integrar modelos sin evaluación suficiente.

**La capacidad generativa aumenta el valor, pero también el costo de equivocarse.**

# Qué queremos modelar

## Datos observados

$$x^{(1)}, x^{(2)}, \dots, x^{(n)}$$


- Textos.
- Imágenes.
- Audio.
- Código.
- Tablas.

## Modelo aprendido

$$p_{\text{model}}(x) \approx p_{\text{data}}(x)$$

- Generar muestras.
- Completar información.
- Estimar probabilidades.
- Aprender representaciones.

# Aplicaciones de modelos generativos profundos



**Fig. 1.3** Various potential applications of deep generative modeling

Fuente: *Deep Generative Modeling*. Jakub M. Tomczak. 2022.

# Datos como tabla

| $X_1$ | $X_2$ | $X_3$   |
|-------|-------|---------|
| 0     | 3     | llueve  |
| 1.5   | -10   | soleado |
| 30    | 49    | nublado |

- Las columnas representan variables aleatorias.
- Las filas representan observaciones.
- Una observación es una realización concreta de esas variables.

# Variables aleatorias y observaciones

## Variable aleatoria

Una variable aleatoria  $X$  asigna valores posibles a resultados de un experimento.

$$X = \text{clima}, \quad x = \text{lluvia}$$

## Observación

Una observación es un valor concreto observado:

$$X = x$$



## Distribución

La distribución de  $X$  indica qué probabilidad tiene cada valor posible.

$$\Pr[X = x] = p_X(x)$$

| Clima   | $\Pr[X = x]$ |
|---------|--------------|
| soleado | 0.5          |
| nublado | 0.2          |
| lluvia  | 0.3          |

# Distribución de datos y distribución del modelo

## Distribución de datos

$$p_{\text{data}}(x)$$

Es la distribución real que produjo los datos.

No la conocemos directamente.

## Distribución del modelo

$$p_{\text{model}}(x)$$

Es la aproximación que aprendemos con datos finitos.

La usamos para estimar, generar o decidir.

$$p_{\text{data}}(x) \approx p_{\text{model}}(x)$$

## Idea

Cuando tenemos varias variables, queremos describir su comportamiento conjunto.

$$p(x, y) = \Pr[X = x, Y = y]$$

- Captura valores individuales.
- Captura dependencias entre variables.
- Es el objeto probabilístico más completo.

## Ejemplo discreto: clima y decisión

|                      | $Y = \text{jugar}$ | $Y = \text{no jugar}$ |
|----------------------|--------------------|-----------------------|
| $X = \text{soleado}$ | 0.25               | 0.25                  |
| $X = \text{nublado}$ | 0.20               | 0.00                  |
| $X = \text{lluvia}$  | 0.10               | 0.20                  |

Cada celda representa:

$$p(x, y)$$

La suma de todas las celdas debe ser 1.

## Pregunta

Si conozco  $p(x, y)$ , ¿cómo recupero  $p(x)$ ?

Sumando sobre los valores posibles de  $Y$ :

$$p(x) = \sum_y p(x, y)$$

Ejemplo:

$$\begin{aligned} p(X = \text{lluvia}) &= p(\text{lluvia, jugar}) + p(\text{lluvia, no jugar}) \\ &= 0,10 + 0,20 = 0,30 \end{aligned}$$

## Idea

Una probabilidad condicional describe una variable cuando otra ya fue observada.

$$p(y \mid x) = \Pr[Y = y \mid X = x]$$

$$p(y \mid x) = \frac{p(x, y)}{p(x)}$$

**Condicionar es actualizar el universo de casos que estamos mirando.**

# Regla del producto

La definición de condicional puede reescribirse como:

$$p(x, y) = p(x) p(y \mid x)$$

Para tres variables:

$$p(x, y, z) = p(x) p(y \mid x) p(z \mid x, y)$$

## Idea clave

La regla del producto permite descomponer una distribución conjunta compleja en piezas más pequeñas.

## Discriminativo

$$p(y \mid x)$$

- Predice una etiqueta.
- Ejemplo: clasificar si se juega tenis.
- Aprende fronteras de decisión.

## Generativo

$$p(x, y) \quad \text{o} \quad p(x \mid y)$$

- Modela cómo se generan los datos.
- Puede muestrear nuevos ejemplos.
- Permite razonar con datos faltantes.



Si aprendimos una distribución:

$$p_{\text{model}}(x)$$

podemos producir una muestra:

$$x_{\text{nuevo}} \sim p_{\text{model}}(x)$$

- Texto: próxima palabra o secuencia.
- Imagen: píxeles o representación latente.
- Audio: forma de onda o espectrograma.
- Tablas: nuevas filas plausibles.

# Aprender parámetros

Muchos modelos se escriben como una familia parametrizada:

$$p_{\theta}(x)$$

Entrenar consiste en elegir  $\theta$  usando datos:

$$x^{(1)}, x^{(2)}, \dots, x^{(n)}$$

$$\theta^* \quad \Rightarrow \quad p_{\theta^*}(x) \approx p_{\text{data}}(x)$$

# Dataset de tenis

| Clima   | Temperatura | Humedad | Viento | Jugar |
|---------|-------------|---------|--------|-------|
| soleado | alta        | alta    | débil  | no    |
| soleado | alta        | alta    | fuerte | no    |
| nublado | alta        | alta    | débil  | sí    |
| lluvia  | templada    | alta    | débil  | sí    |
| lluvia  | baja        | normal  | débil  | sí    |

- Variables: clima, temperatura, humedad, viento, jugar.
- Observaciones: días registrados.
- Objetivo inicial: estimar probabilidades desde frecuencias.

# Frecuencias como primera estimación

Con datos finitos podemos estimar:

$$\hat{p}(x) = \frac{\#\{i : x^{(i)} = x\}}{n}$$

Por ejemplo:

$$\hat{p}(\text{clima} = \text{soleado}) = \frac{\#\text{días soleados}}{\#\text{días}}$$

## Cuidado

La distribución empírica es una aproximación. Con pocos datos puede ser muy inestable.

# Preguntas para el práctico

- ¿Cuál es la distribución marginal de Jugar?
- ¿Cuál es la distribución marginal de Clima?
- ¿Cómo estimamos  $p(\text{Jugar} = \text{sí} \mid \text{Clima} = \text{lluvia})$ ?
- ¿Qué pasa si una combinación nunca aparece en el dataset?

**Estas preguntas anticipan probabilidad condicional y redes bayesianas.**

- La IA generativa busca aprender distribuciones de datos.
- Los datos pueden verse como observaciones de variables aleatorias.
- Una distribución conjunta captura el comportamiento de varias variables.
- Marginalizar y condicionar son operaciones básicas para razonar con datos.
- El práctico de tenis sirve como laboratorio pequeño para estas ideas.

## Idea central

Un modelo generativo no aprende solamente una etiqueta o una decisión: intenta aprender cómo se distribuyen los datos.

$$p_{\text{data}}(x) \approx p_{\text{model}}(x)$$

En la próxima clase vamos a profundizar en:

- probabilidad condicional;
- independencia;
- redes bayesianas.

1. Dada una tabla de frecuencias para  $X$  e  $Y$ , calcular  $p(x)$ ,  $p(y)$  y  $p(x, y)$ .
2. Usar una tabla conjunta para calcular  $p(y \mid x)$ .
3. Explicar con palabras la diferencia entre modelar  $p(y \mid x)$  y modelar  $p(x, y)$ .
4. Dar un ejemplo de generación en texto, imagen o audio como muestreo desde un modelo.



- David Foster. *Generative Deep Learning*. O'Reilly.
- Jakub M. Tomczak. *Deep Generative Modeling*. Springer, 2022.
- Stanford AI Index Report. *Measuring Trends in Artificial Intelligence*.
- Ada Lovelace y Luigi Menabrea. *Sketch of the Analytical Engine*, 1842.