

Probabilidad Condicional y Redes Bayesianas

Factorizaciones, independencia y modelos gráficos

Maestría en Inteligencia Artificial


Universidad ORT Uruguay

1 de setiembre de 2026

Objetivos de la clase

- Reforzar la regla del producto para dos, tres y n variables.
- Entender independencia e independencia condicional.
- Ver cómo una red bayesiana factoriza una distribución conjunta.
- Usar redes simples para razonar con probabilidades.
- Continuar el práctico de Tenis con probabilidades condicionales.

Dónde estamos en el curso



Motivación

Antes de estudiar modelos generativos profundos necesitamos una forma disciplinada de descomponer distribuciones complejas.

Objetivo probabilístico

En IA generativa queremos estimar distribuciones conjuntas:

$$p_{\text{data}}(x, y)$$

La idea general es aprender un modelo:

$$M_{\theta} \approx p(x, y)$$

para poder:

- calcular probabilidades;
- condicionar en evidencia;
- muestrear nuevas observaciones;
- razonar con variables faltantes.

Por qué necesitamos factorizar

Si tenemos n variables binarias:

$$X_1, \dots, X_n$$

la tabla conjunta completa requiere:

$$2^n - 1$$

parámetros libres.

Para MNIST:

$$n = 28 \times 28 = 784$$

La tabla conjunta es imposible de estimar directamente.

Recordatorio: distribución conjunta

Para dos variables aleatorias X e Y :

$$p(x, y) = \Pr[X = x, Y = y]$$

La distribución conjunta contiene:

- las probabilidades marginales de cada variable;
- la relación estadística entre las variables;
- toda la información necesaria para condicionar o marginalizar.

Regla del producto

La probabilidad condicional se define como:

$$p(y \mid x) = \frac{p(x, y)}{p(x)}$$

Reordenando:

$$p(x, y) = p(x) p(y \mid x)$$

La conjunta se puede escribir como marginal por condicional.

La misma conjunta, dos factorizaciones

$$p(x, y) = p(x) p(y \mid x)$$

$$p(x, y) = p(y) p(x \mid y)$$

Ambas son correctas siempre que las probabilidades estén bien definidas.

Lectura

Elegir una factorización no cambia la distribución; cambia la forma en que la representamos y la estimamos.

Tres variables

Para X, Y, Z :

$$p(x, y, z) = p(x) p(y \mid x) p(z \mid x, y)$$

Regla de cadena

Cada nuevo factor condiciona en todo lo que vino antes.

La dificultad aparece cuando hay muchas variables:

$$p(x_1, \dots, x_n)$$

puede volverse muy costosa de representar directamente.

Regla de cadena general

Para n variables:

$$p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i \mid x_1, \dots, x_{i-1})$$

Con la convención:

$$p(x_1 \mid x_1, \dots, x_0) = p(x_1)$$

Esto siempre es cierto. El problema es que puede ser enorme.

Dos variables X e Y son independientes si conocer una no cambia la distribución de la otra:

$$X \perp\!\!\!\perp Y$$

Equivalencias:

$$p(x, y) = p(x) p(y)$$

$$p(y \mid x) = p(y)$$

$$p(x \mid y) = p(x)$$

Qué significa en una tabla

	$Y = 0$	$Y = 1$
$X = 0$	0.20	0.30
$X = 1$	0.20	0.30

En cada fila, la distribución de Y es la misma:

$$p(Y = 1 \mid X = 0) = p(Y = 1 \mid X = 1)$$

Entonces observar X no aporta información sobre Y .

Independencia condicional

La independencia puede aparecer solo después de observar una tercera variable.

$$X \perp\!\!\!\perp Z \mid Y$$

Definición:

$$p(x, z \mid y) = p(x \mid y) p(z \mid y)$$

Equivalencia útil:

$$p(z \mid x, y) = p(z \mid y)$$

Dado Y , conocer X ya no agrega información sobre Z .

Deducción útil

Queremos ver que:

$$X \perp\!\!\!\perp Z \mid Y \Rightarrow p(z \mid x, y) = p(z \mid y)$$

Por regla del producto:

$$p(x, z \mid y) = p(z \mid x, y) p(x \mid y)$$

Por independencia condicional:

$$p(x, z \mid y) = p(x \mid y) p(z \mid y)$$

Si $p(x \mid y) > 0$, igualando y dividiendo:

$$p(z \mid x, y) = p(z \mid y)$$

Ejemplo: edad, enfermedad y síntoma

Supongamos:

Edad $\rightarrow$ Enfermedad $\rightarrow$ Síntoma

Puede ocurrir que:

Síntoma $\not\perp$ Edad

pero:

Síntoma $\perp\!\!\!\perp$ Edad $\mid$ Enfermedad

Lectura

Si ya sabemos la enfermedad, conocer la edad puede no agregar información adicional sobre el síntoma.

Factorización usando independencia condicional

Partimos de la regla del producto:

$$p(x, y, z) = p(x) p(y \mid x) p(z \mid x, y)$$

Si:

$$X \perp\!\!\!\perp Z \mid Y$$

entonces:

$$p(z \mid x, y) = p(z \mid y)$$

Por lo tanto:

$$p(x, y, z) = p(x) p(y \mid x) p(z \mid y)$$

Por qué importa

Sin supuestos:

$$p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i \mid x_1, \dots, x_{i-1})$$

Con supuestos de independencia condicional, algunos factores se simplifican.

Idea clave

Los modelos probabilísticos útiles no evitan la distribución conjunta: la representan de forma más compacta.

Ejemplo: dependencia local

Supongamos una secuencia:

$$X_1, X_2, \dots, X_n$$

Si cada variable depende solo de la anterior:

$$X_{i+1} \perp\!\!\!\perp X_1, \dots, X_{i-1} \mid X_i$$

entonces:

$$p(x_1, \dots, x_n) = p(x_1) \prod_{i=2}^n p(x_i \mid x_{i-1})$$

Esta es una primera forma de reducir una conjunta grande.

Definición

Una red bayesiana es un grafo dirigido y acíclico que representa una factorización de una distribución conjunta.

- Cada nodo representa una variable aleatoria.
- Un arco $X_i \rightarrow X_j$ modela una dependencia directa en la factorización.
- Cada nodo tiene una distribución condicional dada por sus padres.

Propiedad local de Markov

Una red bayesiana codifica el supuesto:


$$X_i \perp\!\!\!\perp \text{no descendientes de } X_i \mid \text{Pa}(X_i)$$

En palabras:

si conozco los padres de un nodo, los no descendientes que no son padres ya no aportan información directa.

Esto es lo que permite pasar de la regla de cadena completa a una factorización local:

$$p(x_1, \dots, x_n) = \prod_i p(x_i \mid \text{Pa}(X_i))$$



$$\text{Pa}(X_3) = \{X_1, X_2\}$$

El nodo X_3 requiere:

$$p(x_3 \mid x_1, x_2)$$

Factorización de una red bayesiana


Si G es una red bayesiana sobre $X_1, \dots, X_n$, entonces:

$$p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i \mid \text{Pa}(X_i))$$

Interpretación

La red declara qué variables son padres directos de cada variable. Esa estructura define qué condicionales hay que estimar.


Ejemplo: una factorización intermedia



$$p(x_1, x_2, x_3, y) = p(x_1) p(x_2) p(y \mid x_1, x_2) p(x_3 \mid y)$$

La estructura queda entre dos extremos: tabla conjunta completa e independencia total.

Ejemplo de factorización



$$p(x_1, x_2, x_3, x_4) = p(x_1) p(x_2 \mid x_1) p(x_3 \mid x_1) p(x_4 \mid x_2, x_3)$$

Sin estructura

$$p(x_1, \dots, x_n)$$

puede requerir una tabla enorme.

Para variables binarias:

$$2^n - 1$$

parámetros libres.

Con estructura

$$\prod_i p(x_i \mid \text{Pa}(X_i))$$

solo estimamos condicionales locales.


Para variables binarias:

$$\sum_i 2^{|\text{Pa}(X_i)|}$$

parámetros.

Es mucho menor si cada nodo tiene pocos padres.

Ejemplo: Sally's alarm



B: burglar, *E*: earthquake, *A*: alarm, *R*: radio, *J*: John calls, *M*: Mary calls.

La red define:

$$p(b, e, a, r, j, m) = p(b) p(e) p(a \mid b, e) p(r \mid e) p(j \mid a) p(m \mid a)$$

- B y E no tienen padres.
- A depende de B y E .
- R depende de E .
- J y M dependen de A .

Sally: calcular una asignación

Por ejemplo:

$$p(B = 0, E = 0, A = 1, J = 1, M = 1)$$

Usando la factorización:

$$p(b, e, a, j, m) = p(b) p(e) p(a \mid b, e) p(j \mid a) p(m \mid a)$$

$$= 0,999 \cdot 0,998 \cdot 0,001 \cdot 0,90 \cdot 0,70 \approx 0,000628$$

El grafo nos dice qué números de las tablas hay que multiplicar.

Tablas de probabilidad condicional

A	$p(J = 1 \mid A)$
0	0.05
1	0.90

A	$p(M = 1 \mid A)$
0	0.01
1	0.70

B	E	$p(A = 1 \mid B, E)$
0	0	0.001
0	1	0.29
1	0	0.94
1	1	0.95

$$p(B = 1) = 0,001, \quad p(E = 1) = 0,002$$

Una red bayesiana permite responder preguntas como:

$$p(B = 1 \mid J = 1, M = 1)$$

Es decir:

si John y Mary llaman, ¿cuán probable es que haya habido un robo?

Para responder, combinamos:

- la estructura del grafo;
- las tablas condicionales;
- marginalización sobre variables no observadas.

Marginalizar variables ocultas

Si no observamos E , A ni R , debemos sumar sobre sus valores:

$$p(B, J, M) = \sum_e \sum_a \sum_r p(B, e, a, r, J, M)$$

Luego:

$$p(B \mid J, M) = \frac{p(B, J, M)}{\sum_b p(b, J, M)}$$

Idea

Inferir en redes bayesianas suele requerir sumar sobre variables no observadas.

Volvemos al dataset de tenis

Clima	Temperatura	Humedad	Viento	Jugar
soleado	alta	alta	débil	no
soleado	alta	alta	fuerte	no
nublado	alta	alta	débil	sí
lluvia	templada	alta	débil	sí
lluvia	baja	normal	débil	sí


Ahora no miramos solo marginales:

$$p(\text{Jugar})$$

sino condicionales:

$$p(\text{Jugar} \mid \text{Clima, Humedad, } \dots)$$

Una red simple para Tenis



$$p(c, t, h, v, j) = p(c) p(t) p(h) p(v) p(j \mid c, t, h, v)$$

Esta red es simple, pero la tabla de $p(j \mid c, t, h, v)$ puede crecer rápido.

1. Calcular marginales de cada atributo del dataset de Tenis.
2. Calcular condicionales de la forma $p(\text{Jugar} \mid \text{atributo})$.
3. Usar una factorización propuesta para calcular una probabilidad conjunta.
4. Discutir qué independencias condicionales son razonables y cuáles son discutibles.

Puente: imágenes como muchas variables

Una imagen binaria puede pensarse como:

$$X_1, \dots, X_{784}$$

donde cada X_i indica si un pixel está apagado o encendido.

Cada pixel puede modelarse como:

$$X_i \sim \text{Ber}(p_i)$$

Si los pixels fueran independientes:

$$p(x_1, \dots, x_n) = \prod_i p(x_i)$$

Pero

Los pixels de una imagen real no son independientes: la estructura visual aparece en sus dependencias.

Puente: factorización autoregresiva

Una alternativa es usar la regla de cadena:

$$p(x_1, \dots, x_n) = p(x_1) \prod_{i=2}^n p(x_i \mid x_1, \dots, x_{i-1})$$

En imágenes o texto, esto sugiere estimar cada condicional con un modelo:

$$\hat{p}_i = p_{\theta}(x_i = 1 \mid x_1, \dots, x_{i-1})$$

Por ejemplo:

$$\hat{p}_i = \sigma(w_i^{\top} x_{<i} + b_i)$$

La idea de factorizar la conjunta sobrevive cuando el modelo deja de ser una tabla.

- La regla del producto permite descomponer distribuciones conjuntas.
- La independencia reduce factores: $p(x, y) = p(x)p(y)$.
- La independencia condicional permite simplificar modelos sin asumir independencia total.
- Una red bayesiana representa esas simplificaciones como un DAG.
- Tenis permite practicar estimación de condicionales e inferencia simple.

Idea central

Una red bayesiana es una forma compacta de decir qué dependencias directas vamos a modelar y qué independencias condicionales vamos a asumir.

$$p(x_1, \dots, x_n) = \prod_i p(x_i \mid \text{Pa}(X_i))$$

La próxima clase pasa de variables discretas a variables continuas y conecta estas ideas con redes neuronales simples.

1. Dada una conjunta $p(x, y)$, verificar si X e Y son independientes.
2. Dada una tabla $p(x, z \mid y)$, verificar si $X \perp\!\!\!\perp Z \mid Y$.
3. Escribir la factorización de una red bayesiana dada por un grafo.
4. Para el dataset de Tenis, estimar $p(\text{Clima} = \text{lluvia} \mid \text{Jugar} = \text{sí})$.
5. Explicar qué supuesto de independencia condicional aparece en una red dada.

Bibliografía sugerida

- David Barber. *Bayesian Reasoning and Machine Learning*. Cambridge University Press, 2012. Capítulos 3.1, 3.2 y 3.3.1.
- Christopher Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- Kevin Murphy. *Probabilistic Machine Learning: An Introduction*. MIT Press, 2022.