

Variables Continuas y Primeros Modelos Neuronales

Densidades, mezclas, Iris y perceptrón de Hinton

Maestría en Inteligencia Artificial

Universidad ORT Uruguay

8 de setiembre de 2026

Objetivos de la clase

- Pasar de variables discretas a variables continuas.
- Entender densidades, integrales y distribuciones continuas básicas.
- Modelar datos continuos condicionando en variables categóricas.
- Usar Iris como ejemplo de mezcla generativa simple.
- Introducir modelos autorregresivos neuronales para variables binarias.

Continuidad con la Clase 2

En Clase 2 trabajamos con:

$$p(x_1, \dots, x_n) = \prod_i p(x_i \mid \text{Pa}(X_i))$$

Hoy cambiamos dos cosas:

- algunas variables dejan de ser discretas;
- algunos factores condicionales pasan a ser parametrizados por modelos neuronales.

Idea

La estructura probabilística sigue siendo la misma; cambia la familia de distribuciones que usamos para cada factor.

Variable discreta

$$X \in \{0, 1, 2, \dots\}$$

$$p(x) = \Pr[X = x]$$

$$\sum_x p(x) = 1$$

Variable continua

$$X \in \mathbb{R}$$

$p(x)$ es densidad

$$\int_{-\infty}^{\infty} p(x) dx = 1$$

Densidad no es probabilidad puntual

Para una variable continua:

$$\Pr[X = x] = 0$$

Lo que tiene probabilidad positiva es un intervalo:

$$\Pr[a \leq X \leq b] = \int_a^b p(x) dx$$

Cuidado


La densidad $p(x)$ puede ser mayor que 1. Lo que debe sumar 1 es el área total bajo la curva.

Probabilidad como área

Para variables continuas:

$$\Pr[a \leq X \leq b] = \int_a^b p(x) dx$$

La altura de la curva es densidad; la probabilidad es el área sombreada.



Regla de la suma: discreto y continuo

Si Y es discreta:

$$p_X(x) = \sum_y p_{X,Y}(x, y)$$

Si Y es continua:

$$p_X(x) = \int p_{X,Y}(x, y) dy$$

En ambos casos estamos marginalizando una variable.

Regla de la cadena

La regla de la cadena sigue valiendo:

$$p_{X,Y}(x,y) = p_Y(y) p_{X|Y}(x | y)$$

Por lo tanto:

$$p_X(x) = \sum_y p_Y(y) p_{X|Y}(x | y)$$

si Y es discreta.

Esta forma será clave para construir mezclas.

La identidad anterior también puede leerse como una esperanza:

$$p_X(x) = \mathbb{E}_{y \sim p_Y} [p_{X|Y}(x | y)]$$

La distribución marginal de X es un promedio de condicionales.

Si:

$$X \sim U(a, b)$$

entonces:

$$p(x) = \frac{1}{b-a} 1_{a \leq x \leq b}$$

- Todos los valores del intervalo son igualmente densos.
- Fuera del intervalo la densidad es cero.
- Es útil como prior simple o ruido acotado.

Si:

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

entonces:

$$p(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right]$$

- μ controla el centro.
- σ controla la dispersión.
- Aparece como supuesto natural para ruido y variabilidad acumulada.

Si:

$$X \sim \text{Lap}(\mu, b)$$

entonces:

$$p(x) = \frac{1}{2b} \exp \left[-\frac{|x - \mu|}{b} \right]$$

- Tiene pico más agudo en μ .
- Tiene colas más pesadas que una normal.
- Es útil cuando esperamos errores con valores extremos más frecuentes.


Comparación conceptual

Distribución	Soporte	Uso típico
Uniforme	intervalo finito	incertidumbre acotada
Normal	$\mathbb{R}$	ruido suave, mediciones
Laplace	$\mathbb{R}$	errores con colas más pesadas

Elección de modelo

Elegir una distribución es elegir qué tipos de variabilidad consideramos plausibles.

Formas de densidad



- La normal distribuye masa de forma suave alrededor de μ .
- Laplace concentra más masa cerca de μ y deja colas más pesadas.

Variable categórica y observación continua

Supongamos:

$$Y \sim \mathcal{B}(p)$$

y:

$$X \mid (Y = b) \sim \mathcal{N}(\mu_b, \sigma_b^2) \quad b \in \{0, 1\}$$

Entonces:

$$p_X(x) = p\mathcal{N}(x; \mu_1, \sigma_1^2) + (1 - p)\mathcal{N}(x; \mu_0, \sigma_0^2)$$

La marginal de X es una mezcla de normales.

Ejemplo: peso de gatos

Supongamos:

$$Y \in \{\text{hembra, macho}\} \quad X = \text{peso}$$

Si:

$$X \mid Y = \text{hembra} \sim \mathcal{N}(\mu_H, \sigma_H^2)$$

$$X \mid Y = \text{macho} \sim \mathcal{N}(\mu_M, \sigma_M^2)$$

entonces la distribución marginal de pesos puede tener dos zonas de alta densidad:

$$p_X(x) = \theta \mathcal{N}(x; \mu_M, \sigma_M^2) + (1 - \theta) \mathcal{N}(x; \mu_H, \sigma_H^2)$$

Si:

$$Y \sim \text{Cat}(p_1, \dots, p_K)$$

y:

$$X \mid (Y = k) \sim \mathcal{N}(\mu_k, \sigma_k^2)$$

entonces:

$$p_X(x) = \sum_{k=1}^K p_k \mathcal{N}(x; \mu_k, \sigma_k^2)$$

Una distribución compleja puede construirse mezclando distribuciones simples.


Para generar una observación:

1. Muestrear una clase latente:

$$z \sim \text{Cat}(p_1, \dots, p_K)$$

2. Muestrear la observación desde la clase:

$$x \sim \mathcal{N}(\mu_z, \sigma_z^2)$$



Variable latente

Una variable latente es una variable que participa en el modelo generativo, pero no necesariamente se observa directamente en el dataset.

$$Z \rightarrow X$$

- En Iris, la especie puede estar observada.
- En clustering, la clase puede no estar observada.
- En VAEs, la variable latente representa factores no etiquetados.

Iris contiene mediciones continuas de flores:

- largo del sépalo;
- ancho del sépalo;
- largo del pétalo;
- ancho del pétalo.

Y una variable categórica:

$$Z \in \{\text{setosa}, \text{versicolor}, \text{virginica}\}$$

$$X \in \mathbb{R}^4$$

Modelo generativo para Iris

Un modelo simple:

$$Z \sim \text{Cat}(p_1, p_2, p_3)$$

$$X \mid (Z = k) \sim \mathcal{N}(\mu_k, \Sigma_k)$$

La marginal de X :

$$p(x) = \sum_{k=1}^3 p_k \mathcal{N}(x; \mu_k, \Sigma_k)$$

Esto es una mezcla gaussiana supervisada si conocemos la especie.

Clasificar con el modelo generativo

Para una flor nueva x :

$$p(z = k \mid x) = \frac{p(z = k) p(x \mid z = k)}{\sum_j p(z = j) p(x \mid z = j)}$$

Luego elegimos:

$$\hat{z} = \arg \max_k p(z = k \mid x)$$

Clasificar también puede hacerse desde un modelo generativo.

Qué estimamos en el práctico

Para cada clase k :

- prior de clase:

$$\hat{p}_k = \frac{n_k}{n}$$

- media:

$$\hat{\mu}_k = \frac{1}{n_k} \sum_{i:z_i=k} x^{(i)}$$

- covarianza:

$$\hat{\Sigma}_k = \frac{1}{n_k} \sum_{i:z_i=k} (x^{(i)} - \hat{\mu}_k)(x^{(i)} - \hat{\mu}_k)^\top$$

Volvemos a variables discretas

Supongamos una observación binaria:

$$x = (x_1, \dots, x_n) \quad x_i \in \{0, 1\}$$

Por regla de cadena:

$$p(x) = \prod_{i=1}^n p(x_i \mid x_{<i})$$

donde:

$$x_{<i} = (x_1, \dots, x_{i-1})$$

Cada factor como Bernoulli

Como x_i es binaria:

$$X_i \mid x_{<i} \sim \mathcal{B}(p_i)$$

Necesitamos estimar:

$$p_i = p(x_i = 1 \mid x_{<i})$$

La pregunta es:

¿Cómo construimos p_i a partir de $x_{<i}$?

Primeros factores

Para $x = (x_1, x_2, x_3)$:

$$p(x_1, x_2, x_3) = p(x_1) p(x_2 \mid x_1) p(x_3 \mid x_1, x_2)$$

Como las variables son binarias:

$$p(x_1) = \mathcal{B}(x_1; \theta_1)$$

$$p(x_2 \mid x_1) = \mathcal{B}(x_2; \theta_2(x_1))$$

$$p(x_3 \mid x_1, x_2) = \mathcal{B}(x_3; \theta_3(x_1, x_2))$$

Sin parametrizar, θ_3 sería una tabla con una entrada para cada combinación de (x_1, x_2) .

Una opción lineal:

$$p_i = \text{sigmoid}(w_i^\top x_{<i} + b_i)$$

donde:

$$\text{sigmoid}(a) = \frac{1}{1 + \exp(-a)}$$

Entonces:

$$p(x_i \mid x_{<i}) = \mathcal{B} \left(\text{sigmoid}(w_i^\top x_{<i} + b_i) \right)$$

De tabla a función

Para cada posición i , el condicional ideal es una función:

$$\theta_i : \{0, 1\}^{i-1} \rightarrow [0, 1]$$

Una tabla aprende un parámetro distinto para cada patrón anterior.

Un perceptrón aprende una función compartida:

$$\theta_i(x_{<i}) = \text{sigmoid}(w_i^\top x_{<i} + b_i)$$

Cambio de perspectiva

Pasamos de estimar parámetros de una tabla a aprender los parámetros de una función.

$$p(x) = \prod_{i=1}^n \mathcal{B} \left(x_i; \text{sigmoid}(w_i^\top x_{<i} + b_i) \right)$$

- Cada variable se predice usando las anteriores.
- El orden de las variables importa.
- Para n grande, aparecen muchos parámetros.

Esta idea aparece en belief networks tempranas de Frey, Hinton y Dayan.

Notación matricial y máscara

Podemos aplanar la observación:

$$x = (x_1, \dots, x_n)$$

y calcular todos los logits juntos:

$$z = Wx + b, \quad p = \text{sigmoid}(z)$$

Para respetar el orden autoregresivo, W debe ser triangular:

$$W_{ij} = 0 \quad \text{si } j \geq i$$

El pixel i solo puede mirar pixels anteriores.

No es una hipótesis Markoviana

En un modelo Markoviano de orden 1:

$$p(x_i \mid x_{<i}) = p(x_i \mid x_{i-1})$$


En el modelo autoregresivo general:

$$p(x_i \mid x_{<i}) = p(x_i \mid x_1, \dots, x_{i-1})$$

Idea

El orden limita qué variables pueden usarse, pero no obliga a depender solo de la variable inmediatamente anterior.

Ejemplo visual



$$p(x_1, x_2, x_3) = p(x_1) p(x_2 \mid x_1) p(x_3 \mid x_1, x_2)$$

MLP para cada condicional

En lugar de una función lineal:

$$p_i = \text{sigmoid}(w_i^\top x_{<i} + b_i)$$

podemos usar una red:

$$h_i = \text{sigmoid}(V_i x_{<i} + v_i)$$

$$p_i = \text{sigmoid}(a_i^\top h_i + b_i)$$

Ventaja

El factor condicional puede capturar relaciones no lineales entre las variables previas.

Problema de parámetros

Si usamos un MLP distinto para cada posición i :

- hay muchos pesos;
- se repite trabajo;
- entrenar puede volverse costoso.

Los modelos posteriores comparten parámetros entre posiciones.

Esta es una de las ideas detrás de NADE y modelos autorregresivos modernos.

Entrenamiento por log-verosimilitud

Dado un ejemplo x :

$$\log p_{\theta}(x) = \sum_{i=1}^n \log p_{\theta}(x_i \mid x_{<i})$$

La pérdida para un ejemplo:

$$\ell(\theta, x) = - \sum_{i=1}^n \log p_{\theta}(x_i \mid x_{<i})$$

La próxima clase conectará esta pérdida con KL y riesgo empírico.

- Para variables continuas trabajamos con densidades e integrales.
- Uniforme, normal y Laplace son familias continuas básicas.
- Mezclar condicionales simples permite representar distribuciones más complejas.
- Iris puede modelarse como $Z \rightarrow X$, con X gaussiana por clase.
- Los modelos autorregresivos descomponen $p(x)$ en factores condicionales.

Idea central

Los modelos generativos combinan dos decisiones: cómo factorizar la distribución y qué familia usar para cada factor.

$$p(x) = \prod_i p_{\theta}(x_i \mid x_{<i})$$

En modelos neuronales, los parámetros de esas distribuciones pueden ser la salida de una red.

1. Cargar Iris y separar X y Z .
2. Estimar $p(z)$, μ_z y Σ_z para cada especie.
3. Evaluar $p(x | z)$ para nuevas flores.
4. Clasificar usando Bayes.
5. Comparar el enfoque generativo con un clasificador discriminativo simple.

1. Calcular la densidad de una normal en un punto dado.
2. Escribir la marginal de X cuando Z es categórica y $X \mid Z$ es normal.
3. Explicar por qué $p(x)$ en una mezcla puede ser multimodal.
4. Factorizar $p(x_1, x_2, x_3, x_4)$ de forma autorregresiva.
5. Escribir la pérdida negativa log-verosimilitud para una observación binaria.

- B. J. Frey, G. E. Hinton y P. Dayan. *Does the Wake-Sleep Algorithm Learn Good Density Estimators?* NeurIPS, 1996.
- Y. Bengio y S. Bengio. *Modeling High-Dimensional Discrete Data with Multi-Layer Neural Networks*. NeurIPS, 2000.
- B. Uria et al. *Neural Autoregressive Distribution Estimation*. JMLR, 2016.
- Christopher Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.