

Variables Latentes y VAE

Del modelo generativo al autoencoder variacional

Maestría en Inteligencia Artificial

Universidad ORT Uruguay

22 de setiembre de 2026

Objetivos de la clase

- Repasar la diferencia entre modelos discriminativos y generativos.
- Conectar los modelos autoregresivos con otra hipótesis generativa.
- Introducir variables latentes como causas no observadas.
- Entender la arquitectura encoder-decoder de un VAE.
- Leer prior, likelihood, evidence y posterior en un modelo latente.

Hoy construimos el modelo. La próxima clase vemos cómo entrenarlo.

Qué queda para la Clase 6

En esta clase no vamos a desarrollar:

- la función de pérdida completa;
- la derivación de la cota variacional;
- el término KL como regularizador de entrenamiento;
- el truco de reparametrización en detalle;
- la implementación completa de la optimización.

Puente

Al final vamos a dejar planteado por qué necesitamos una cota para entrenar.

Modelo discriminativo

$$p(y \mid x)$$

Predice una etiqueta o salida dado un dato.

Ejemplo:

$$x \longrightarrow y$$

Modelo generativo


$$p(x, y) \quad \text{o} \quad p(x)$$

Describe cómo podrían generarse los datos.

Permite muestrear datos nuevos.

Familias que venimos usando

- Redes bayesianas discretas.
- Modelos condicionales estimados por frecuencias.
- Perceptrón de Hinton / FVSBN.
- Modelos autoregresivos neuronales.
- Ahora: modelos con variables latentes y VAE.



La pregunta generativa

Queremos modelar datos de alta dimensión:

$$x = (x_1, x_2, \dots, x_n)$$

La pregunta es:

$$p_{\theta}(x_1, x_2, \dots, x_n) \approx p_{\text{data}}(x)$$

Como la distribución conjunta completa es enorme, necesitamos imponer estructura.

Cada modelo generativo propone una forma distinta de factorizar o explicar x .

Una opción es usar la regla de la cadena:

$$p_{\theta}(x) = \prod_{i=1}^n p_{\theta}(x_i \mid x_{<i})$$

Esta hipótesis supone un orden:

$$x_1 \rightarrow x_2 \rightarrow \cdots \rightarrow x_n$$

En imágenes, por ejemplo, el orden puede ser de izquierda a derecha y de arriba abajo.

Qué aporta un modelo autoregresivo

- Convierte una conjunta grande en muchos problemas condicionales.
- Cada factor puede parametrizarse con una red.
- Para variables binarias, cada factor puede estimar la probabilidad de valer 1.
- La generación ocurre paso a paso.

Limitación

El orden es parte del sesgo inductivo y puede ser artificial para objetos con estructura global.

Antes de pasar a VAE, recordemos una idea simple.

Si z es una variable discreta:

$$p(x) = \sum_z p(x \mid z)p(z)$$

Si z es continua:

$$p(x) = \int p(x \mid z)p(z) dz$$

Podemos explicar x promediando sobre causas posibles z .

Ejemplo conocido: Iris

En Iris podíamos pensar:

$$z \in \{\text{setosa}, \text{versicolor}, \text{virginica}\}$$

Primero se elige una clase:

$$z \sim \text{Cat}(\pi)$$

Luego se genera una medición:

$$x \mid z \sim \mathcal{N}(\mu_z, \sigma_z)$$

La distribución final es una mezcla:

$$p(x) = \sum_z p(z) \mathcal{N}(x; \mu_z, \sigma_z)$$

El salto conceptual

En Iris, z puede ser la especie y a veces la conocemos.

En otros problemas, la causa detrás del dato no está etiquetada:

- estilo de escritura;
- identidad del objeto;
- pose;
- iluminación;
- factores que no sabemos nombrar.

A esas causas no observadas las llamamos variables latentes.

Variable observable vs variable latente

Observable

x

Dato medido o visto por el modelo.

Ejemplos:

- píxeles de una imagen;
- longitud de pétalo;
- audio;
- texto.

Latente

z

Factor no observado que ayuda a explicar el dato.

Ejemplos:

- clase no etiquetada;
- estilo;
- pose;
- intención.

Ejemplo intuitivo

Vemos una foto y afirmamos: “esto es un gato”.

El dato observado son los píxeles:

x

La categoría o factores que inferimos no vienen escritos en la imagen:

z

Idea

Los humanos inferimos variables latentes para explicar observaciones.

Nuevo sesgo inductivo


Ahora proponemos:

$$z \sim p(z)$$

$$x \sim p_{\theta}(x \mid z)$$

Es decir:

$$p_{\theta}(x, z) = p(z)p_{\theta}(x \mid z)$$



Qué significa generar

Para generar una muestra:

1. muestreamos una causa latente:

$$z \sim p(z)$$

2. el decoder produce una observación compatible:

$$x \sim p_{\theta}(x \mid z)$$

El decoder define la distribución generativa.

El prior describe lo que creemos sobre z antes de observar x :

$$p(z)$$

En VAE se elige casi siempre:

$$p(z) = \mathcal{N}(0, I)$$


Motivos prácticos:

- es fácil de muestrear;
- es continuo;
- tiene una geometría simple;
- permite construir un espacio latente organizado.

La likelihood condicional dice qué tan compatible es un dato con un latente dado:

$$p_{\theta}(x \mid z)$$

En VAE esta distribución está parametrizada por el decoder.



Si solo observamos x , el modelo debe considerar todos los z posibles:

$$p_{\theta}(x) = \int p_{\theta}(x \mid z)p(z) dz$$

Interpretación:

Probabilidad que el modelo le asigna a x , considerando todas las causas latentes posibles.

Esta cantidad será central para entrenar, pero no la vamos a resolver hoy.

Después de observar x , podemos preguntar:

$$p_{\theta}(z \mid x)$$

Lectura:

¿Qué valores latentes podrían haber generado este dato?

Por Bayes:

$$p_{\theta}(z \mid x) = \frac{p_{\theta}(x \mid z)p(z)}{p_{\theta}(x)}$$

Prior, likelihood, evidence, posterior


Nombre	Fórmula	Lectura
Prior	$p(z)$	creencia sobre z antes de ver x
Likelihood	$p_{\theta}(x z)$	compatibilidad de x con un z
Evidence	$p_{\theta}(x)$	probabilidad total del dato
Posterior	$p_{\theta}(z x)$	latentes posibles dado x

Este vocabulario conecta VAE con inferencia bayesiana.

Autoencoder clásico

Un autoencoder aprende a reconstruir:

$$x \rightarrow z \rightarrow \hat{x}$$



Sirve para compresión, embeddings y reconstrucción.

Qué cambia en un VAE

En un autoencoder clásico, el encoder devuelve un código:

$$z = f_{\phi}(x)$$

En un VAE, el encoder devuelve una distribución:


$$q_{\phi}(z \mid x)$$

Por ejemplo:

$$q_{\phi}(z \mid x) = \mathcal{N}(z; \mu_{\phi}(x), \Sigma_{\phi}(x))$$

El código latente pasa a ser estocástico.

Arquitectura VAE



El encoder aproxima qué latentes son plausibles para x ; el decoder genera desde un latente.

Si $z \in \mathbb{R}^d$, el encoder debe producir parámetros para una distribución en d dimensiones.

$$z \mid x \sim \mathcal{N}(\mu_\phi(x), \Sigma_\phi(x))$$


- $\mu_\phi(x)$: vector de medias.
- $\Sigma_\phi(x)$: matriz de covarianzas.
- En práctica suele usarse una covarianza diagonal.

Para dos dimensiones:

$$\mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \text{Var}(z_1) & \text{Cov}(z_1, z_2) \\ \text{Cov}(z_2, z_1) & \text{Var}(z_2) \end{bmatrix}$$

La varianza controla qué tan ancha es la campana en cada dirección.

La covarianza controla si las dimensiones se mueven juntas.



En muchas implementaciones de VAE simplificamos a elipses alineadas con los ejes.

Por qué el encoder devuelve incertidumbre

Para un mismo dato x , puede haber varios z razonables.

El encoder no dice solo:

este es el código

Dice:

estos códigos son plausibles, con esta incertidumbre

Idea VAE

Codificar como distribución permite muestrear variaciones y conectar inferencia con generación.

Inferencia aproximada

$$x \rightarrow q_{\phi}(z \mid x)$$

Si observo x , ¿qué z lo explican?

Generación

$$z \rightarrow p_{\theta}(x \mid z)$$

Si tengo un z , ¿qué x puedo generar?

VAE une inferencia y generación en una misma arquitectura.

Dos problemas pendientes

Hasta ahora sabemos proponer el modelo:

$$z \sim p(z), \quad x \sim p_{\theta}(x \mid z)$$

Y sabemos aproximar:

$$p_{\theta}(z \mid x) \quad \text{con} \quad q_{\phi}(z \mid x)$$

Pero quedan dos preguntas:

1. ¿Cómo entrenamos si $p_{\theta}(x)$ tiene una integral difícil?
2. ¿Cómo hacemos backpropagation si muestreamos z ?

Por qué aparece una integral difícil

El dataset tiene observaciones:

$$T = \{x^{(1)}, \dots, x^{(m)}\}$$

No tenemos los latentes reales:

$$T \neq \{(x^{(i)}, z^{(i)})\}_{i=1}^m$$

Entonces, para evaluar un dato, el modelo debe integrar todas las posibilidades:

$$p_{\theta}(x) = \int p_{\theta}(x \mid z) p(z) dz$$

En la próxima clase vamos a usar una herramienta variacional para resolver el entrenamiento.

La idea será:

- construir una cota inferior para la log-probabilidad del dato;
- convertir esa cota en una función objetivo;
- entender los términos que aparecen en la loss;
- resolver el problema de muestrear z y entrenar con backpropagation.

Nombre de esa herramienta: ELBO.

- Un modelo generativo busca describir cómo se producen los datos.
- Los modelos autoregresivos explican x mediante un orden de variables.
- Un modelo latente explica x mediante causas no observadas z .
- En VAE, el decoder modela $p_{\theta}(x \mid z)$.
- El encoder aproxima qué z podrían haber generado un x .

Idea central

Un VAE propone que los datos observados se generan a partir de variables latentes continuas, y aprende simultáneamente una dirección generativa y una dirección inferencial.

$$z \sim p(z), \quad x \sim p_{\theta}(x \mid z), \quad q_{\phi}(z \mid x) \approx p_{\theta}(z \mid x)$$

Preguntas para chequear

1. ¿Qué diferencia hay entre $p(y \mid x)$ y $p(x)$?
2. ¿Qué hipótesis introduce un modelo autoregresivo?
3. ¿Qué significa que z sea latente?
4. ¿Qué rol cumple el decoder?
5. ¿Qué rol cumple el encoder?
6. ¿Por qué aparece una integral al calcular $p_{\theta}(x)$?

- Diederik Kingma y Max Welling. *Auto-Encoding Variational Bayes*. ICLR, 2014.
- Carl Doersch. *Tutorial on Variational Autoencoders*. arXiv, 2016/2021.
- Christopher Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- Jakub M. Tomczak. *Deep Generative Modeling*. Springer, 2022.