

Modelos de Deep Learning

Skip connections

Universidad ORT Uruguay

27 de Octubre, 2025


Motivación

- Consideremos tres secuencias genéricas de capas f_1 , f_2 y f_3
- Y dos modelos donde uno es un subconjunto del otro:

$$g_1(x) = (f_3 \circ f_1)(x), \quad g_2(x) = (f_3 \circ f_2 \circ f_1)(x).$$

- Debería ser posible que $f_2(x) \approx x$, en cuyo caso $g_2(x) \approx g_1(x)$.
- Deberían existir parámetros donde el segundo modelo (más profundo) performe tan bien como el primero.
- Sin embargo, esto **no se observa en la práctica**.

Mayor profundidad $\nRightarrow$ menor error de entrenamiento



Error de entrenamiento (izquierda) y error de prueba (derecha) en CIFAR-10 con redes “planas” de 20 y 56 capas. La red más profunda presenta un error de entrenamiento mayor y también un error de validación más alto.

Redes profundas: Problemas

- Los pesos en las primeras capas cambian más lentamente que al final:
 - La regla de la cadena multiplica gradientes muchas veces, podemos llegar a multiplicar números pequeños muchas veces haciéndolos todavía más pequeños.
 - Esto causa que las actualizaciones por SGD sean de muy pequeña magnitud y los pesos de la red (en las primeras capas) demoren en cambiar.
 - Los pesos de las capas iniciales tienen menor influencia que el resto de la red.
- **Vanishing gradients:** ¿cómo darle más influencia a esos pesos y ayudar a la propagación de los gradientes?
 - “Saltar” una capa en la red conectando la capa anterior con las siguientes
 - Dos maneras: 1) Concatenación 2) Aditiva (Suma)


Conexión residual

- En lugar de ajustar directamente una función deseada
- Ajustamos una **función residual**
- Si la función deseada es $H(x)$: ajustamos

$$F(x) := H(x) - x.$$

- La función original es

$$F(x) + x.$$



Idea clave

- Sesgar los bloques de la red hacia la identidad con una **conexión residual**:

$$H(x) = F(x) + x.$$

- Así, el bloque modela desviaciones respecto de la **identidad**

$$F(x) = H(x) - x$$

en lugar de desviaciones respecto de la **función cero**.

- Este truco facilita **el entrenamiento** de modelos con cientos de capas.
- **Red residual** (ResNet) modelo convolucional compuesto por bloques residuales.

Compatibilidad de dimensiones y normalización

- Las conexiones residuales funcionan bien con **batch normalization** en el camino residual.
- Las conexiones residuales pueden añadirse solo si la **dimensionalidad de entrada y salida** de $F(x)$ coincide.
- Puede añadirse un reescalado en la conexión residual:
Por ejemplo, si x es una imagen y $F(x)$ modifica el número de canales, se puede añadir una convolución 1×1 :

$$H(x) = f(x) + \text{Conv2D}_{1 \times 1}(x).$$

Diseño del bloque residual: caso básico



- Considera el bloque con **batch normalization**:

$$h = \underbrace{(\text{ReLU} \circ \text{BN} \circ \text{Conv2D})}_{=F(x)}(x) + x.$$

- Como ReLU es no negativa, se tiene $h \geq x$ (elemento a elemento).
- Una pila de bloques de esta forma incrementa o anula los valores del tensor de entrada.
- Para evitar esta asimetría se elimina la última activación:

$$h = (\text{BN} \circ \text{Conv2D} \circ \text{ReLU} \circ \text{BN} \circ \text{Conv2D})(x) + x.$$

Ejemplo de diseño de bloque



Bloque original de ResNet.

Suma de caminos residuales

Considera una red con dos bloques residuales:


$$h_1 = f_1(x) + x, \quad h_2 = f_2(h_1) + h_1.$$

Si desenrollamos el cómputo:

$$h_2 = f_2(f_1(x) + x) + f_1(x) + x.$$



Esto corresponde a la suma de varios caminos en la red: la entrada pasa sin modificación, pasa por solo una transformación (f_1 o f_2), o por su combinación.

Ensamble implícito




- Caminos residuales: las rutas negra, roja y azul están implementadas explícitamente; la verde es solo implícita.
- El número de caminos crece exponencialmente con el número de bloques residuales.
- Las ResNets pueden verse como un **ensamble** de un número muy grande de modelos pequeños, implementado mediante **weight sharing**.

Efecto regularizador





Superficies de costo de ResNet-56 sin y con skip connections.

Arquitecturas ResNet originales




Ejemplo de desempeño




Entrenamiento en ImageNet. Las curvas finas indican el error de entrenamiento, y las curvas en negrita indican el error de validación. Izquierda: redes “planas” de 18 y 34 capas. Derecha: ResNets de 18 y 34 capas.

Skip Connections: Concatenación



DenseNet: Residual con concatenación



ResNet vs. DenseNet: diferencias clave

Aspecto	ResNet	DenseNet
Conexión entre capas	Suma (+)	Concatenación ([.])
Flujo de información	Aditivo	Acumulativo y explícito
Canales	Se mantiene	Crece capa a capa
Estructura	Bloques residuales con <i>skip</i>	<i>Dense blocks + transition</i>
Propósito principal	Facilitar gradientes en redes profundas	Reutilizar características y ser eficiente en parámetros
Costo de memoria	Moderado	Mayor
Parámetros por capa	Típicamente más	Menos, por reutilización sistemática
Año	2016 (He et al.)	2017 (Huang et al.)
Ejemplos	ResNet-18/34/50/101	DenseNet-121/169/201

Bibliografía

- Scardapane, Simone. "Alice's Adventures in a Differentiable Wonderland—Volume I, A Tour of the Land." arXiv preprint arXiv:2404.17625 (2024).
- He, Kaiming, et al. Deep residual learning for image recognition. Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.