

Modelos de Deep Learning


NLP

Universidad ORT Uruguay

27 de Octubre, 2025

NLP: contexto y usos en la práctica

- Sentiment Analysis
- Machine Translation
- Question Answering
- Text Summarization
- Text Classification
- Text-to-Speech
- Speech Recognition



NLP: comprender el lenguaje natural



Commercial transaction

SELLER: *Cynthia*

BUYER: *Bob*


GOODS: *the bike*

PRICE: *\$200*

Input: *Cynthia sold the bike to Bob for \$200*

Output: **SELLER** **PREDICATE** **GOODS** **BUYER** **PRICE**

NLP dificultades: ambigüedad



NLP dificultades: sinónimos

what are other
words for
culture?




cultivation, civilization,
refinement, polish, society,
enlightenment, erudition,
breeding, lifestyle, education



 Thesaurus.plus


NLP dificultades: dependencia

*“I voted for Nader because he was most
aligned with my values,” she said.*



The diagram illustrates dependencies between words in the sentence. It features three curved arrows: one from 'Nader' to 'I', one from 'she' to 'aligned', and one from 'he' to 'most'.

NLP: Enfoque en este curso



Tokenización

Proceso de descomponer un texto en palabras individuales o **tokens**.
Estos tokens son los bloques básicos para realizar análisis posteriores.

Ejemplo:

Input:

“Los perros son animales muy leales y se llevan bien con las personas.”

Output:

[“Los”, “perros”, “son”, “animales”, “muy”, “leales”, “y”, “se”, “llevan”, “bien”, “con”, “las”, “personas”, “.”]

Remoción de stop words

Las **stop words** son palabras comunes que suelen eliminarse para enfocar el análisis en las palabras más relevantes.

En este caso, las stop words son: “Los”, “son”, “y”, “se”, “con”, “las”, “.”.

Ejemplo:

Input:


[“Los”, “perros”, “son”, “animales”, “muy”, “leales”, “y”, “se”, “llevan”, “bien”, “con”, “las”, “personas”, “.”]

Output:

[“perros”, “animales”, “muy”, “leales”, “llevan”, “bien”, “personas”].

Reducción a la raíz

Flexión: Proceso mediante el cual se generan formas distintas de una misma palabra en función de diversas informaciones gramaticales (género, número, persona, etc.).



Reducción a la raíz

- **Stemming:** reducción de la flexión de las palabras a sus formas raíz. Mapea un grupo de palabras a la misma raíz (incluso si la raíz en sí misma no es una palabra válida en el idioma).

Elige Stemming: cuando deseas simplicidad y velocidad, y las palabras no válidas son aceptables.

- **Lematización:** reduce las palabras flexionadas de forma correcta (asegurando que la palabra raíz pertenezca al idioma).

Elige Lematización: cuando es crítico mantener la validez de las palabras y comprender el contexto.

Reducción a la raíz

■ Ejemplo 1:

Original: "Dancing, dancer, danced."

Stemming Result: ["danc", "dancer", "danc"]

Lemmatization Result: ["dance", "dancer", "dance"]

■ Ejemplo 2:

Original: "Organization, organizational, organized."

Stemming Result: ["organ", "organ", "organ"]

Lemmatization Result: ["organization", "organizational", "organize"]

■ Ejemplo 3:

Original: "Happiness, happier, happiest."

Stemming Result: ["happi", "happier", "happiest"]

Lemmatization Result: ["happiness", "happy", "happy"]

Vectorización - Bag of Words

- Se construye una tabla donde
 - Filas son los documentos d del corpus D .
 - Columnas son los tokens t del vocabulario.
 - La entrada de la fila d y columna t es

$$f(t, d) = \# \text{ ocurrencias de } t \text{ en } d$$

■ Ejemplo:

d_1 : The quick brown fox jumped over the lazy dog.

d_2 : The dog hunts a fox.

	the	quick	brown	fox	jumped	over	lazy	dog	hunts	a
d_1	2	1	1	1	1	1	1	1	0	0
d_2	1	0	0	1	0	0	0	1	1	1

Vectorización - TFIDF

■ **TF** (Token Frequency):

$$\text{tf}(t, d) = \frac{f(t, d)}{\sum_{t' \in d} f(t', d)}$$

■ **IDF** (Inverse Document Frequency):

$$\text{idf}(t, D) = \log_2 \left(\frac{\#D}{\#\{d \in D : t \in d\}} \right)$$

■ **TFIDF**:

$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$

TFIDF - Ejemplo

```
corpus = [  
    'This is the first document.',  
    'This is the second second document.',  
    'And the third one.',  
    'Is this the first document?'  
]
```

		Bag of Words									
		and	document	first	is	one	second	the	third	is	$\Sigma f(t,d)$
df(t,D)		0	1	1	1	0	0	1	0	1	5
		0	1	0	1	0	2	1	0	1	6
		1	0	0	0	1	0	1	1	0	4
		0	1	1	1	0	0	1	0	1	5
		1	3	2	3	1	2	4	1	3	
idf(t,D)		2.00	0.42	1.00	0.42	2.00	1.00	0.00	2.00	0.42	

TFIDF - Ejemplo

		Bag of Words									
		and	document	first	is	one	second	the	third	is	$\Sigma f(t,d)$
df(t,D) idf(t,D)		0	1	1	1	0	0	1	0	1	5
		0	1	0	1	0	2	1	0	1	6
		1	0	0	0	1	0	1	1	0	4
		0	1	1	1	0	0	1	0	1	5
		1	3	2	3	1	2	4	1	3	
		2.00	0.42	1.00	0.42	2.00	1.00	0.00	2.00	0.42	

TFIDF									
and	document	first	is	one	second	the	third	is	Norma
0.000	0.083	0.200	0.083	0.000	0.000	0.000	0.000	0.083	0.246
0.000	0.069	0.000	0.069	0.000	0.333	0.000	0.000	0.069	0.354
0.500	0.000	0.000	0.000	0.500	0.000	0.000	0.500	0.000	0.866
0.000	0.083	0.200	0.083	0.000	0.000	0.000	0.000	0.083	0.246


TFIDF Normalizado								
and	document	first	is	one	second	the	third	is
0.00	0.34	0.81	0.34	0.00	0.00	0.00	0.00	0.34
0.00	0.20	0.00	0.20	0.00	0.94	0.00	0.00	0.20
0.58	0.00	0.00	0.00	0.58	0.00	0.00	0.58	0.00
0.00	0.34	0.81	0.34	0.00	0.00	0.00	0.00	0.34

One-hot vs Word Embeddings



One-hot word vectors:

- Sparse
- High-dimensional
- Hardcoded



Word embeddings:

- Dense
- Lower-dimensional
- Learned from data



One-hot word vectors:

- Representaciones *sparse* y de alta dimensión
- Cada palabra es independiente (vectores ortogonales)
- No capturan relaciones semánticas

Word embeddings:

- Vectores *densos* y de menor dimensión
- Aprendidos desde los datos
- Capturan la estructura semántica del lenguaje
- Palabras similares → vectores cercanos en el espacio

Vectorization: Word Embeddings



Estructura y uso de los Word Embeddings


Relaciones geométricas significativas:

- Los vectores de palabras reflejan relaciones semánticas.
- Ejemplos:
 - $king + \text{"female"} \rightarrow queen$
 - $king + \text{"plural"} \rightarrow kings$
- Existen miles de direcciones interpretables (género, número, tiempo verbal, etc.).


Formas de obtener embeddings:

- **Entrenados desde cero:** Se aprenden junto con la tarea principal (p. ej. clasificación o análisis de sentimiento).
- **Pre-entrenados:** Derivados de otras tareas de ML y reutilizados en nuevos modelos.

Word2Vec




CBOW



Skip-gram

Word2Vec: Efficient Estimation of Word Representations in Vector Space (2013)

Word2Vec - Arquitectura



Word2Vec - Train Dataset

Input text

This is the first document.

This is the first document.

This is the first document.

...

Train data (window = 1)

- (this, is)

- (is, this)


- (is, the)

- (the, is)


- (the, first)

...

Word2Vec - CBOW



Word2Vec - Skip Gram



Bibliografía

- All about Tokenization, Stop words, Stemming and Lemmatization in NLP. Abhishek Jain. 2024
- All You Need to Know About Bag of Words and Word2Vec. Albers Uzila. 2022
- Word2Vec Research Paper Explained. Nikhil Birajdar. 2021
- Learn Natural Language Processing from scratch. Balakrishnan Sathiyakugan. 2018