

Modelos de Deep Learning

Modelos de Lenguaje

Universidad ORT Uruguay

10 de Noviembre, 2025

Modelos de Lenguaje (LM)

- Predecir la siguiente palabra en una secuencia
- Ejemplo:
 - Necesito un vaso de ...
 - Agua
 - Cerveza
 - Vino
- Los usamos constantemente
- Tradicionalmente dominado por técnicas estadísticas, queremos predecir la probabilidad de cada palabra de ser la siguiente

Modelos de Lenguaje - Formalmente

Dada una secuencia de palabras

$$x^{(1)}, x^{(2)}, \dots, x^{(t)},$$

queremos calcular la distribución de probabilidad de la siguiente palabra $x^{(t+1)}$:

$$P(x^{(t+1)} \mid x^{(t)}, x^{(t-1)}, \dots, x^{(1)})$$

donde $x^{(t+1)}$ es cualquier palabra en un vocabulario

$$V = \{w_1, w_2, \dots, w_{|V|}\}.$$

Modelos de Lenguaje: N-Gramas

- Un N-Grama es una secuencia de N tokens consecutivos.

Ejemplo: I need a glass of ..

- Unigramas: I, need, a, glass, of
- Bigramas: I need, need a, a glass, glass of
- Trigramas: I need a, need a glass, a glass of
- Se generaliza para N .

Recolectando información estadística sobre la **frecuencia** de cada n-grama podemos predecir la siguiente palabra.

Modelo de Lenguaje: Probabilidad con N-Gramas

- **Idea:** aproximar la probabilidad condicional completa con una ventana N :

$$P(x^{(t+1)} \mid x^{(t)}, x^{(t-1)}, \dots, x^{(1)}) \approx P(x^{(t+1)} \mid x^{(t)}, x^{(t-1)}, \dots, x^{(t-N+2)})$$

- Por ejemplo, para un modelo **trigram**:

$$P(x^{(t+1)} \mid x^{(t)}, x^{(t-1)})$$

- Estas probabilidades se estiman **empíricamente** a partir de **frecuencias**:

$$P(x^{(t+1)} \mid x^{(t)}, \dots, x^{(t-N+2)}) = \frac{\text{conteo}(x^{(t-N+2)}, \dots, x^{(t)}, x^{(t+1)})}{\text{conteo}(x^{(t-N+2)}, \dots, x^{(t)})}.$$

N-Gramas: Ejemplo 4-Gramas

~~"I know what these cookies are missing, I need a glass of _____"~~

Descartamos

Condicionamos por esto

$$P(w \mid \text{a glass of}) \approx \frac{\text{count}(\text{a glass of } w)}{\text{count}(\text{a glass of})}$$

$$\text{count}(\text{a glass of}) = 1000$$

$$\text{count}(\text{a glass of water}) = 400 \quad \Rightarrow \quad P(\text{water} \mid \text{a glass of}) = 0.4$$

$$\text{count}(\text{a glass of milk}) = 100 \quad \Rightarrow \quad P(\text{milk} \mid \text{a glass of}) = 0.1$$

N-Gramas: Problemas

- Si N es muy chico:
 - El modelo suele ser débil.
 - Solo puede modelar dependencias cortas (modelo “corto de vista”).
- Si N es muy grande:
 - El tamaño del modelo crece exponencialmente con N .
 - Es *disperso* (*sparse*): la mayoría de los N-gramas aparece muy pocas veces.
- Para cualquier N , siempre existe una oración muy larga que el modelo no puede representar.
- Tienden a funcionar peor en lenguas con orden de palabras flexible, pues hay combinaciones muy dispersas y difíciles de estimar.

Modelos de Lenguaje con Redes (MLP)

- Recordando el problema:

$$P(x^{(t+1)} \mid x^{(t)}, x^{(t-1)}, \dots, x^{(t-N+2)})$$

- **Idea:** usar una red neuronal (p.ej. MLP) que reciba los vectores de las últimas N palabras:
 - N es fijo $\Rightarrow$ tenemos un número finito de entradas.
 - Podemos pensarlo como una **ventana deslizante** sobre el texto.
 - Cada palabra $x^{(t)}$ se representa con un vector (*embedding*) aprendido.

$$(x^{(t-n+2)}, \dots, x^{(t-1)}, x^{(t)}) \xrightarrow{\text{MLP}} \hat{x}^{(t+1)}$$

Modelos de Lenguaje con Redes (MLP)

Distribución de salida


$$\hat{\mathbf{y}} = \text{softmax}(\mathbf{U}\mathbf{h} + \mathbf{b}_2) \in \mathbb{R}^{|\mathcal{V}|}$$

Capa oculta

$$\mathbf{h} = f(\mathbf{W}\mathbf{e} + \mathbf{b})$$

Embeddings de palabras

$$\mathbf{e} = [\mathbf{e}_1; \mathbf{e}_2; \mathbf{e}_3; \mathbf{e}_4]$$




Modelos de Lenguaje con Redes (MLP)

Mejoras

- Nos olvidamos del problema de la dispersión.
- No necesitamos computar ni almacenar todos los n -gramas.

Problemas todavía presentes


- La ventana siempre va a ser chica.
- Agrandar la ventana agranda W .
- Las palabras se multiplican por pesos distintos en W : estamos aprendiendo funciones “similares” varias veces.



De MLPs a Redes Recurrentes (RNN)


- Su costo (en número de pesos) no escala con el tamaño de la ventana.
- Pueden aprender dependencias temporales largas (**LSTM**, **GRU**).
- Mucho más eficientes y rápidas que un modelo de N-gramas muy grande.
- Usan los mismos pesos para cada paso temporal T .
- No se aprenden N funciones distintas sino una sola función recurrente.
- Dominaron el campo hasta la llegada de los **Transformers**.
- Aún se utilizan ampliamente en la industria y la academia.

Modelos de Lenguaje con Redes Recurrentes (RNN)



- Como **salida** obtenemos la **distribución de probabilidad** sobre las palabras
- **Predicción**: palabra con mayor probabilidad.

Modelos de Lenguaje con Redes Recurrentes (RNN)



- Esperamos que **W** sea la siguiente palabra en la secuencia (en cada paso) y sumamos el error al total para entrenar.
- Luego le damos **la palabra correcta como input** y esperamos lo mismo con la siguiente $P(\text{brown} | \text{the, quick})$.
- Esta manera de entrenar se conoce como **teacher forcing**.