

Modelos de Deep Learning

Secuencia a Secuencia

Universidad ORT Uruguay

10 de Noviembre, 2025

Modelos Secuencia-a-Secuencia (Seq2Seq)

- Aprender a transformar una **secuencia de entrada**

$$(x_1, x_2, \dots, x_T)$$

en una **secuencia de salida**

$$(y_1, y_2, \dots, y_{T'}).$$

- Generaliza los LM: el objetivo no es predecir la siguiente palabra, sino una **traducción, resumen o respuesta**.
- Ejemplos de aplicaciones:
 - Traducción automática.
 - Resumen y subtitulado automático.

Secuencia-a-Secuencia: Desafíos

- Las secuencias pueden tener **distinta longitud**.

“Where is the train station?” → “¿Dónde está la estación de trenes?”

- **Orden diferente** entre entrada y salida.

“The red house” → “La casa roja”

- Requiere **memoria a largo plazo**:

“¿De quién era el cumpleaños?”

- Es necesario definir claramente **inicio y fin** de cada secuencia, o el modelo puede entrar en **loops infinitos**.

Algunas Soluciones

- Agregamos **tokens especiales** para el comienzo y el fin de una secuencia:

SOS (start of sentence), EOS (end of sentence).

- Las RNNs están diseñadas para **recordar información del pasado**.
- Y pueden manejar **diferencias en el orden** entre los **inputs** y los **outputs**.
- Ya estamos prontos, no necesitamos nada más.

Algunas Soluciones


- Agregamos **tokens especiales** para el comienzo y el fin de una secuencia:

SOS (start of sentence), EOS (end of sentence).

- Las RNNs están diseñadas para **recordar información del pasado**.
- Y pueden manejar **diferencias en el orden** entre los **inputs** y los **outputs**.
- ~~Ya estamos prontos, no necesitamos nada más.~~

Algunas Soluciones

Las RNN no pueden manejar inputs y outputs de **distinto tamaño**.



Unrolled Recurrent Neural Network



X, h y S todos van hasta T!

Arquitecturas de Encoder–Decoder

- Combinamos dos modelos.
- Uno puede aprender a **codificar información relevante** en la secuencia de entrada → **Encoder**.
- El otro **decodifica esa información** y la usa para generar la secuencia de salida → **Decoder**.
- Los modelos son independientes uno del otro, pero usamos el mismo **bucle de entrenamiento** para optimizarlos a ambos simultáneamente.

Encoders


- Su objetivo es generar un **vector de contexto** que contenga toda la información importante sobre la secuencia de entrada.
- Este contexto no es más que el **estado oculto final** de una red recurrente.
- En principio, los **outputs intermedios** de la red recurrente en cada paso t también podrían utilizarse para agregar información adicional.




Decoders

- El **estado oculto** de la red se inicializa con los valores finales del **encoder**.
- Durante el entrenamiento, el **input del decoder** consiste en la secuencia objetivo con un token SOS al comienzo.
- En cada paso temporal, el decoder observa el **contexto** y la **palabra anterior**, y con eso genera una predicción para la siguiente palabra.
- Esto permite manejar **secuencias de distinta longitud**.
- En **inferencia**, el decoder comienza recibiendo el token SOS y luego utiliza sus propios outputs hasta generar un token EOS (o alcanzar un máximo).


Decoders - Entrenamiento



Decoder durante entrenamiento




Decoders - Inferencia (Predicción)




Decoder en inferencia, su output en $t-1$ se convierte en el input en tiempo t

Training vs Predicting

Training




Predicting



Encoder-Decoder

- Aunque los modelos **Encoder** y **Decoder** puedan ser diferentes, se entrenan de forma conjunta (*end-to-end*).
- Usamos la loss del decoder en cada tiempo para calcular el costo total.
- Se usan los resultados de ambos modelos para ajustar sus parámetros mediante **backpropagation**.



Teacher Forcing

- **Teacher forcing** es una técnica de entrenamiento donde, sin importar lo que genere el **decoder**, el siguiente input siempre es la palabra real del conjunto de entrenamiento.
- Si el modelo se entrena **solo** con teacher forcing, su desempeño empeora en inferencia, ya que nunca aprendió a corregirse a partir de sus propios errores.
- Una solución práctica consiste en alternar aleatoriamente entre usar teacher forcing y usar las propias predicciones del modelo durante el entrenamiento.

Bibliografía

- Scardapane, Simone. "Alice's Adventures in a Differentiable Wonderland–Volume I, A Tour of the Land." arXiv preprint arXiv:2404.17625 (2024).
- Seq2Seq Models : French to English translation using encoder-decoder model with attention.
- NLP From Scratch: Translation with a Sequence to Sequence Network and Attention
- Seq2seq - Wikipedia