

Machine Learning para Inteligencia Artificial

¿Qué es Machine Learning?

Universidad ORT Uruguay

`matias.carrasco@fi365.ort.edu.uy`

19 de Marzo, 2025

¿Qué entendemos realmente por Machine Learning?

El *campo* de Machine Learning busca:

- Construir sistemas que mejoren automáticamente con la experiencia
- Descubrir leyes fundamentales que rigen todos los procesos de aprendizaje

¿Qué significa que una máquina aprenda?

Una máquina aprende respecto a una tarea particular \mathbf{T} , métrica de desempeño \mathbf{P} , y tipo de experiencia \mathbf{E} , si el sistema mejora de forma fiable su rendimiento \mathbf{P} en la tarea \mathbf{T} , siguiendo la experiencia \mathbf{E} .

Ejemplos de problemas de Machine Learning

■ Aprender a sumar

- T : sumar dos números naturales en forma binaria
- P : porcentaje de respuestas correctas
- E : envía respuestas a un profesor de matemáticas

■ Reconocimiento de tumores por imágenes médicas

- T : reconocer un tumor en una imagen médica
- P : porcentaje de respuestas correctas
- E : conjunto de datos de imágenes correctamente clasificadas

■ Aprender a jugar al Pacman

- T : jugar al Pacman
- P : porcentaje de juegos ganados
- E : jugar al juego

■ ¿Otros ejemplos?

Participantes y sus roles

- **Activo:** el **learner** aprende haciendo preguntas a un *teacher*
 - Ejemplo: sumar números en binario
- **Pasivo:** el **learner** aprende de *ejemplos* (datos) que no son elegidos
 - Ejemplo: reconocimiento de tumores
- **Refuerzo:** el **learner** aprende guiado por *recompensas/castigos*
 - Ejemplo: jugar al Pacman

¿Cuándo ocurre?

■ **Online**

- Incremental: online con memoria limitada
- Ejemplo: jugar al Pacman

■ **Offline** (o batch)

- Ejemplo: reconocimiento de tumores

■ **Combinado** offline/online

- Ejemplo: juegos, robots

Propiedad de los datos disponibles y pregunta a responder

■ **Supervisado:** datos etiquetados

- Input Space: **atributos, características, variables predictoras, etc.**
- Output Space: **etiquetas, targets, respuestas, etc.**
- La muestra es un conjunto de ejemplos de la forma (atributos, etiqueta).
- Objetivo: predecir etiqueta a partir de los atributos.
- Ejemplos: clasificación de imágenes, predicción de precios, etc.

■ **No supervisado:** datos no etiquetados

- La muestra es un conjunto de ejemplos de la forma (atributos).
- Objetivo: inventar una etiqueta dado los atributos.
- Se usa una **similitud** para agrupar observaciones.
- Ejemplos: Market segmentation, identificación de comunidades, etc.

Tipos de aprendizaje supervisado

Construir una **hipótesis** o **modelo** que predice una etiqueta para **cualquier** input.

- **Regresión**: targets (etiquetas) son **números reales** (int o floats)

- Ejemplo: predicción de precios en el mercado inmobiliario (metros², precio)

$$\text{precio} = 1500 \times \text{metros}^2$$

- **Clasificación**: targets (etiquetas) son **clases** (strings)

- Puede ser binaria o multiclase

- Ejemplo: clasificación de imágenes (img, gato/perro)


$$\text{mascota}(\text{img}) = \begin{cases} \text{gato} & \text{si img tiene nariz chica y orejas punteagudas} \\ \text{perro} & \text{si no} \end{cases}$$

Tipos de aprendizaje según tipo de hipótesis

Exacto: Se construye una hipótesis que es **siempre cierta**

MULTIPLEOF5($w[1..n]$):

```
rem ← 0
for i ← 1 to n
  rem ← (2 · rem + w[i]) mod 5
if rem = 0
  return TRUE
else
  return FALSE
```



State-transition graph for MULTIPLEOF5

374 en binario es = 00101110110 y $(374 \text{ Mod } 5) = 4$

0 $\xrightarrow{0}$ 0 $\xrightarrow{0}$ 0 $\xrightarrow{1}$ 1 $\xrightarrow{0}$ 2 $\xrightarrow{1}$ 0 $\xrightarrow{1}$ 1 $\xrightarrow{1}$ 3 $\xrightarrow{0}$ 1 $\xrightarrow{1}$ 3 $\xrightarrow{1}$ 2 $\xrightarrow{0}$ 4

Tipos de aprendizaje según tipo de hipótesis

Estadístico

- Se aprende de muestras (**distribución** desconocida).
- **Función de pérdida** penaliza el error cometido por una hipótesis **inexacta**.

A modo de ejemplos:

- Clasificación: $\text{Loss}(\text{clase}, \text{predicción}) = \begin{cases} 1 & \text{predicción} \neq \text{clase} \\ 0 & \text{predicción} = \text{clase} \end{cases}$

- Regresión:

$$\text{Loss}(\text{precio}, \text{predicción}) = (\text{precio} - \text{predicción})^2$$

- Minimizar el **costo empírico** (best effort sobre datos de entrenamiento).
- **Generalización**: se monitorea el costo en datos no vistos.

En este curso

- Estadístico
- Pasivo
- Offline
- Supervisado
- Clasificación y regresión

Bibliografía

- Machine Learning - A First Course for Engineers and Scientists. Capítulo 1.
- T. Mitchell. Machine Learning. McGraw-Hill, 1997. Capítulo 1, Pg 1-5.
- Understanding Machine Learning: From Theory to Algorithms. Secc. 1.1-1.4, Pg. 19-24.