

# Machine Learning para Inteligencia Artificial

Regresión con Árboles de Decisión

Universidad ORT Uruguay

2 de Abril, 2025

# Ingredientes de la regresión

- **Espacio de atributos:**  $\mathcal{X} \subset \mathbb{R}^D$
- **Espacio de etiquetas:**  $\mathcal{Y} \subset \mathbb{R}$  (la etiqueta es una variable continua)
- **Conjunto de datos:**  $T = \{(\mathbf{x}_i, y_i)\}_{i=1}^N$  muestra iid de  $\mathcal{D}$
- **Función de pérdida:** por ejemplo **quadratic loss**  $\text{Loss}(\hat{y}, y) = (\hat{y} - y)^2$
- **Sesgo inductivo:**  $\mathcal{H} = \{h : \mathcal{X} \rightarrow \mathcal{Y}\}$

# La función a aprender: $h_{\text{opt}}$

- Relación  $\mathbf{x} \rightsquigarrow y$  estocástica:  $p(y \mid \mathbf{x})$
- La mejor hipótesis  $h_{\text{opt}} \in \mathcal{H}$ :

$$h_{\text{opt}}(\mathbf{x}) = \arg \min_{h \in \mathcal{H}} \mathbf{E} \left[ \text{Loss}(h(\mathbf{x}), y) \mid \mathbf{x} \right]$$

- Es la función que queremos aprender
- Desconocida en la práctica
- Datos: muestra iid de la forma


$$y_i = h_{\text{opt}}(\mathbf{x}_i) + \epsilon_i$$

para  $i = 1, \dots, N$


- $\epsilon_i$  error aleatorio

Si  $\text{Loss}(\hat{y}, y) = (\hat{y} - y)^2$  quadratic loss

$$h_{\text{opt}}(\mathbf{x}) = \text{reg}(\mathbf{x}) = \mathbf{E}[y \mid \mathbf{x}]$$



# Ejemplo



# Predecir con una constante (sin hacer preguntas)

Consideremos un **sesgo inductivo** muy simple:

$$\mathcal{H}_0 = \{h : \mathcal{X} \rightarrow \mathcal{Y} \mid h \text{ es constante}\}$$


y la **función de pérdida cuadrática**.

Costo empírico = Mean Squared Error (MSE)

$$J_T(h) = \text{MSE}(h) = \frac{1}{|T|} \sum_{i=1}^N (h(x_i) - y_i)^2$$

Es sencillo ver (derivar e igualar a cero) que

$$\text{promedio} = \bar{y} = \arg \min_{h \in \mathcal{H}_0} \text{MSE}(h)$$



# Me permito hacer una pregunta

Consideremos ahora el **sesgo inductivo**  $\mathcal{H}_1$  donde  $h(x) = \begin{cases} c_1 & \text{si } x \leq v \\ c_2 & \text{si } x > v \end{cases}$

Queremos  $(c_1, c_2, v)$  que **minimizan la MSE**:

$$J_T(h) = \text{MSE}(h) = \frac{1}{|T|} \left[ \sum_{x_i < v} (y_i - c_1)^2 + \sum_{x_i \geq v} (y_i - c_2)^2 \right]$$

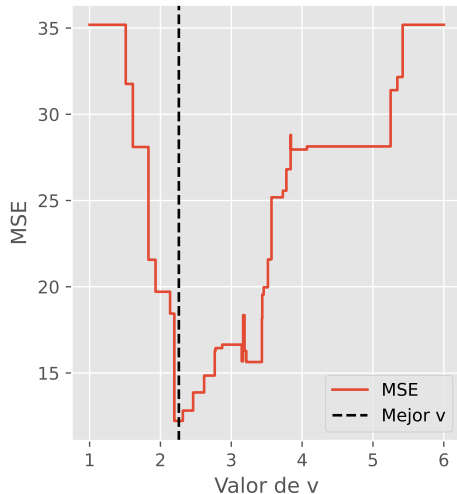
**Fijando**  $v$ , la MSE se minimiza para

$$\begin{cases} c_1 = \bar{y}_1 = \text{promedio}\{y_i : x_i \leq v\} \\ c_2 = \bar{y}_2 = \text{promedio}\{y_i : x_i > v\} \end{cases}$$

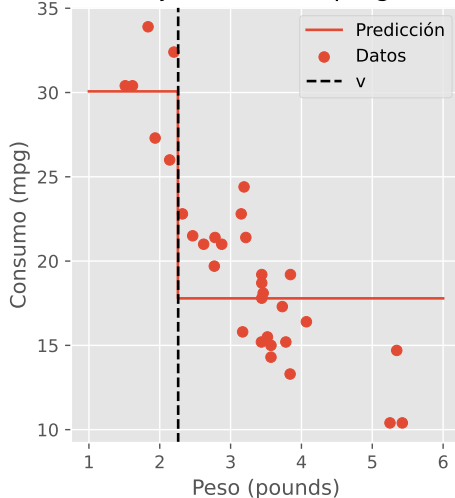
¿Cuál es el mejor  $v$ ?

# Me permito hacer una pregunta

¿Cuál es el mejor  $v$ ?




La mejor  $h$  con una pregunta



# $\mathcal{H}_1 = \{\text{árboles de profundidad 1}\}$

Una **pregunta**  $P: x \leq v?$  divide los datos en dos:



■ La MSE de la predicción **promedio**  $\bar{y}$  en una hoja  $H$  es igual a la **varianza**

$$\text{MSE}_H(\bar{y}) = \frac{1}{|H|} \sum_H (y - \bar{y})^2 = \text{Var}(y; H)$$




# ¿Qué es un árbol de decisión?

Nodos =  
preguntas

Arcos =  
respuestas

Hojas =  
predicción



# ¿Cómo se construye?

Algoritmo *greedy*

Se comienza por la raíz igual al conjunto  $T$  de datos de entrenamiento

Se repite el siguiente proceso para cada hoja  $H$

- Se **elige** una **pregunta**  $P$  para dividir  $H$
- Se construye un arco por cada respuesta  $a \in \{\text{True}, \text{False}\}$  a  $P$
- Se desciende por cada arco  $a$  con el conjunto:

$$H_a = \{s \in H \mid P(s) = a\} \quad a \in \{\text{True}, \text{False}\}$$

La **predicción** en una hoja del árbol es el **promedio**.

## La mejor pregunta

Sea  $P$ : ¿ $A < v$ ? una pregunta (en el caso categórico  $P$ : ¿ $A = v$ ?)

$$H_a = \{s \in H \mid P(s) = a\} \quad a \in \{\text{True}, \text{False}\}$$

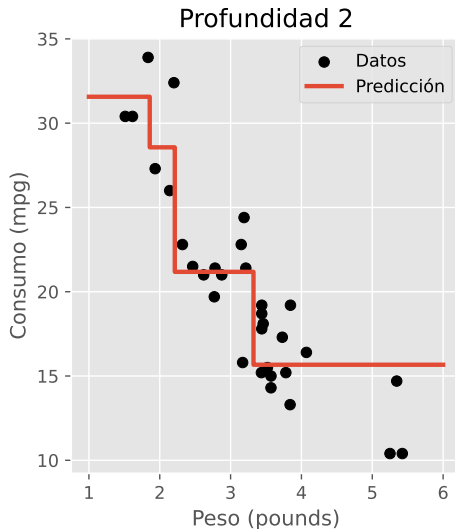

La varianza **esperada** después de dividir una hoja  $H$  usando  $P$  es:

$$\text{Var}_P(H) = \frac{|H_{\text{True}}|}{|H|} \cdot \text{Var}(y; H_{\text{True}}) + \frac{|H_{\text{False}}|}{|H|} \cdot \text{Var}(y; H_{\text{False}})$$



Se elige  $P$  correspondiente al par  $(A, v)$  que minimiza la **varianza**:

$$P^* = \arg \min_P \text{Var}_P(H)$$

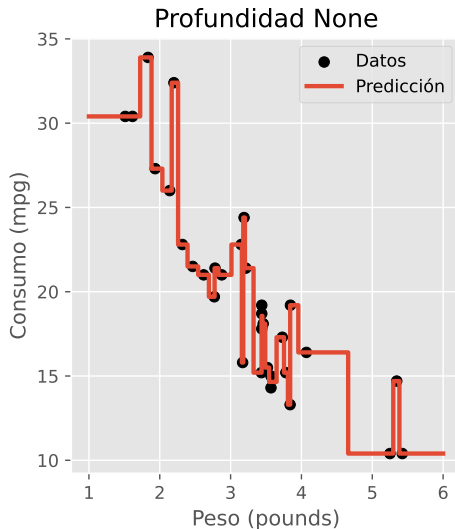
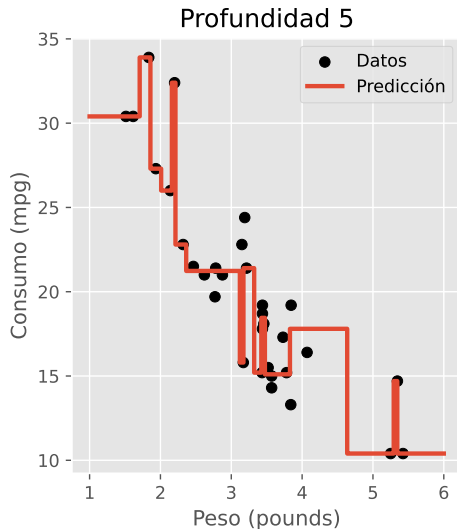
# Recursive Binary Splitting



# Recursive Binary Splitting



# Recursive Binary Splitting



# Bibliografía

- An introduction to statistical learning with applications in Python. Cap 8.
- Machine Learning - A First Course for Engineers and Scientists. Cap 2.3.
- Machine Learning Refined: Foundations, Algorithms, and Applications. Cap 14.
- Raschka, S. [Introduction to Machine Learning](#). Lecture 6. (2021)