

# Machine Learning para Inteligencia Artificial

## Descomposición del Error

Universidad ORT Uruguay

30 de Abril, 2025

# La predicción óptima

■ Loss cuadrática:  $\text{Loss}(\hat{y}, y) = (\hat{y} - y)^2$

■ La relación  $\mathbf{x} \rightsquigarrow y$  estocástica

$$y = f(\mathbf{x}) + \epsilon, \quad \mathbf{E}[\epsilon|\mathbf{x}] = 0$$


■  $f: \mathcal{X} \rightarrow \mathcal{Y}$  es la **función a aprender**

$$f(\mathbf{x}) = \text{reg}(\mathbf{x}) = \mathbf{E}[y | \mathbf{x}]$$


■ Los datos son una **muestra iid** de la forma:

$$y_i = f(\mathbf{x}_i) + \epsilon_i$$

para  $i = 1, \dots, N$



# Idea intuitiva de sesgo y varianza



● Predicción óptima  $\text{reg}(x)$

● Valor real de  $y$

● Predicción  $\hat{y}$








● Predicción promedio  $\bar{y}$

— Sesgo  $B(x)$

○ Varianza  $V(x)$

○ Error irreducible  $N(x)$

# Sesgo y varianza: dependencia con $\mathcal{H}$



**Sesgo Inductivo:**  
Árbol de profundidad 1

**Baja varianza:** la hipótesis varía poco con los datos

**Alto sesgo:** el modelo se ajusta peor a los datos

**Sesgo Inductivo:**  
Árbol de profundidad 4

**Alta varianza:** la hipótesis varía mucho con los datos

**Bajo sesgo:** el modelo se ajusta bien a los datos

# Error cuadrático medio (MSE)

- Un algoritmo  $A$  busca la mejor hipótesis en el sesgo inductivo  $\mathcal{H}$ .
- Su output  $h_T$  depende del dataset  $T \sim \mathcal{D}^N$ .
- Fijado un  $\mathbf{x} \in \mathcal{X}$  el riesgo esperado (MSE) en  $\mathbf{x}$  es

$$\text{MSE}(\mathbf{x}) = \mathbf{E}_{T \sim \mathcal{D}^N} \left\{ \mathbf{E}_y \left[ (h_T(\mathbf{x}) - y)^2 \mid \mathbf{x} \right] \right\}$$

# Sesgo

Fijado un  $\mathbf{x} \in \mathcal{X}$ :

- $\bar{h}(\mathbf{x}) = \mathbf{E}_{T \sim D^N} [h_T(\mathbf{x})]$  la **predicción promedio** del algoritmo en  $\mathbf{x}$
- El **sesgo** en  $\mathbf{x}$  se define como

$$B(\mathbf{x}) = (\bar{h}(\mathbf{x}) - \text{reg}(\mathbf{x}))^2$$

# Varianza

Fijado un  $\mathbf{x} \in \mathcal{X}$ , la **varianza** en  $\mathbf{x}$  es:

$$V(\mathbf{x}) = \mathbf{E}_{T \sim D^N} \left[ (h_T(\mathbf{x}) - \bar{h}(\mathbf{x}))^2 \right]$$

# Error Irreducible

Fijado un  $\mathbf{x} \in \mathcal{X}$ , el **error irreducible** (o ruido) en  $\mathbf{x}$  es:

$$N(\mathbf{x}) = \mathbf{E}_y \left[ (y - \text{reg}(\mathbf{x}))^2 \mid \mathbf{x} \right] = \text{var}(y \mid \mathbf{x})$$




# Descomposición del error

$$\underbrace{\text{Error esperado}}_{\text{MSE}(x)} = \underbrace{\text{Sesgo}}_{\text{B}(x)} + \underbrace{\text{Varianza}}_{\text{V}(x)} + \underbrace{\text{Error Irreducible}}_{\text{N}(x)}$$

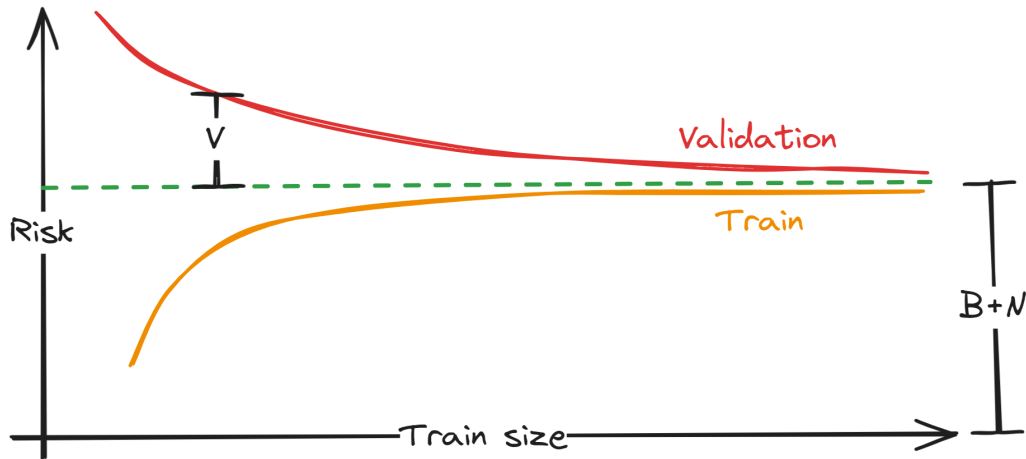
- El **sesgo** tiende a **bajar** cuando aumenta la *complejidad* (o *flexibilidad*)
- La **varianza** tiende a **aumentar** cuando aumenta la *complejidad*
- El **error irreducible** es la varianza de  $y \mid x$

# Descomposición del error



Fuente: [Blog TDS de Giorgos Papachristoudis](#)

# Descomposición del error - Learning curve



## Opcional: Demostración de la descomposición del error

- Fijamos un  $\mathbf{x} \in \mathcal{X}$ . La MSE en ese  $\mathbf{x}$  es

$$\text{MSE}(\mathbf{x}) = \mathbf{E}_{T \sim D^N} \left\{ \mathbf{E}_y \left[ (h_T(\mathbf{x}) - y)^2 \mid \mathbf{x} \right] \right\}$$

- Sumamos y restamos la función de regresión  $\text{reg}(\mathbf{x})$ :

$$(h_T(\mathbf{x}) - y)^2 = (h_T(\mathbf{x}) - \text{reg}(\mathbf{x}) + \text{reg}(\mathbf{x}) - y)^2$$

$$\begin{aligned} & (h_T(\mathbf{x}) - \text{reg}(\mathbf{x}))^2 && (B + V) \\ & + \\ & = (\text{reg}(\mathbf{x}) - y)^2 && (N) \\ & + \\ & 2(h_T(\mathbf{x}) - \text{reg}(\mathbf{x}))(\text{reg}(\mathbf{x}) - y) && (0) \end{aligned}$$

## Opcional: Demostración de la descomposición del error

- El término  $(N)$  al promediar en  $y$  da lugar a:

$$\mathbf{E}_y \left[ (\text{reg}(\mathbf{x}) - y)^2 \mid \mathbf{x} \right] = N(\mathbf{x})$$

- El término  $(0)$  al promediar en  $y$  desaparece:

$$\underbrace{2(h_T(\mathbf{x}) - \text{reg}(\mathbf{x}))}_{\text{No depende de } y} \underbrace{\mathbf{E}_y[(\text{reg}(\mathbf{x}) - y) \mid \mathbf{x}]}_{=0 \text{ por def. de } \text{reg}(\mathbf{x})} = 0$$

## Opcional: Demostración de la descomposición del error

- Al término  $(B + V)$  le sumamos y restamos la predicción promedio  $\bar{h}(\mathbf{x})$ :

$$(h_T(\mathbf{x}) - \text{reg}(\mathbf{x}))^2 = (h_T(\mathbf{x}) - \bar{h}(\mathbf{x}) + \bar{h}(\mathbf{x}) - \text{reg}(\mathbf{x}))^2$$

$$\begin{aligned} & \begin{aligned} & (h_T(\mathbf{x}) - \bar{h}(\mathbf{x}))^2 && (V) \\ & + \\ & (\bar{h}(\mathbf{x}) - \text{reg}(\mathbf{x}))^2 && (B) \\ & + \\ & 2(h_T(\mathbf{x}) - \bar{h}(\mathbf{x}))(\bar{h}(\mathbf{x}) - \text{reg}(\mathbf{x})) && (0) \end{aligned} \\ = & \end{aligned}$$

## Opcional: Demostración de la descomposición del error

- El término  $(V)$  al promediar en  $T$  da lugar a:

$$\mathbf{E}_{T \sim D^N} \left[ (h_T(\mathbf{x}) - \bar{h}(\mathbf{x}))^2 \mid \mathbf{x} \right] = V(\mathbf{x})$$

- El término  $(0)$  al promediar en  $T$  desaparece:

$$\underbrace{2(\bar{h}(\mathbf{x}) - \text{reg}(\mathbf{x}))}_{\text{No depende de } T} \underbrace{\mathbf{E}_y [(h_T(\mathbf{x}) - \bar{h}(\mathbf{x})) \mid \mathbf{x}]}_{=0 \text{ por def. de } \bar{h}(\mathbf{x})} = 0$$

- El término  $(B)$  es  $B(\mathbf{x})$ .

# Bibliografía

- An introduction to statistical learning with applications in Python. Capítulo 5.1.
- Machine Learning - A First Course for Engineers and Scientists. Capítulo 4.