

Machine Learning para Inteligencia Artificial

Ensembles: Bagging y Random Forest

Universidad ORT Uruguay

7 de Mayo, 2025

Índice

Ensembles: combinar modelos

Bagging

Random Forest

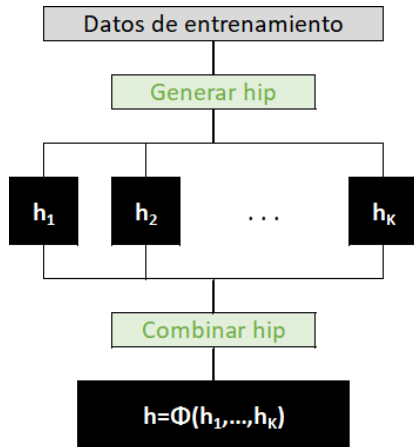
Definición general de ensemble

La técnica de **ensemble** consiste en:

1. **Generar** varias (K) hipótesis h_1, \dots, h_K
2. **Combinarlas** en una hipótesis h mediante:


$$h(x) = \Phi(h_1(x), \dots, h_K(x))$$

La función Φ define **cómo** combinar las hipótesis y puede ser **fija o aprendida** durante el entrenamiento.




Tres razones para combinar hipótesis


- Varianza estadística: pequeño cambio en T genera gran cambio en h
- Varianza computacional: óptimo local, algoritmo glotón
- Sesgo inductivo (o de representación)



(a) Statistical



(b) Computational



(c) Representational

Ensemble: regresión

Promedio

$$h(\mathbf{x}) = \frac{1}{K} \sum_{k=1}^K h_k(\mathbf{x})$$

Suma pesada

$$h_{\mathbf{w}}(\mathbf{x}) = \sum_{k=1}^K w_k h_k(\mathbf{x})$$

- Si los h_k son **independientes** (difícil de conseguir en la práctica):

$$\text{MSE}(h) \leq \frac{1}{K} \sum_k \text{MSE}(h_k)$$

- Más aún, si los **sesgos** de h_k son pequeños $\text{MSE}(h) \ll \frac{1}{K} \sum_k \text{MSE}(h_k)$
- Suma pesada: hay que buscar los pesos \mathbf{w} **óptimos**
- **Occam's razor**: Promedio suele ser mejor (no over-fitting, comp. simple)

Promedios: Idea intuitiva

- El sesgo del ensemble promedio $h = \frac{1}{K} \sum_k h_k$ satisface

$$B(h) \leq \frac{1}{K} \sum_{k=1}^K B(h_k)$$

- Si los h_1, \dots, h_K son **independientes**, la varianza satisface

$$V(h) = \frac{1}{K^2} \sum_{k=1}^K V(h_k) = \frac{1}{K} \underbrace{\left(\frac{1}{K} \sum_{k=1}^K V(h_k) \right)}_{\text{promedio de varianzas}}$$

- Entonces la MSE esperada del ensemble promedio satisface

$$\text{MSE}(h) \leq \frac{1}{K} \sum_k \text{MSE}(h_k)$$

Ensemble: clasificación

Voto mayoritario de los clasificadores


$$h(x) = \arg \max_c \sum_{k=1}^K \mathbb{1}(h_k(x) = c)$$

$$\mathbb{1}(u) = \begin{cases} 0 & \text{if } u = \text{FALSE} \\ 1 & \text{if } u = \text{TRUE} \end{cases}$$

Caso binario:

Si los h_k son independientes y tienen exactitud $p > 0.5$, la exactitud de h tiende a 1 cuando $K \rightarrow +\infty$

Pero no es esperable en la práctica



Ensemble: clasificación

Voto **pesado** de los clasificadores

$$h(x) = \arg \max_c \sum_{k=1}^K w_k \mathbb{1}(h_k(x) = c)$$

Soft-voting: la predicción de las hipótesis es una probabilidad

$$h_k^c(x) = \widehat{\text{Prob}}_k[Y = c \mid X = x]$$

$$h^c(x) = \sum_{k=1}^K w_k h_k^c(x)$$

$$h(x) = \arg \max_c h^c(x)$$

Bagging (Bootstrap Aggregation)

Ensemble: Promediar reduce la varianza

¿Cómo hacemos para generar K hipótesis diferentes?

Primera idea: **bagging**

Para $k \in \{1, \dots, K\}$ tomar muestra **bootstrap** de T :


- Construir $B_k \subset S$, tal que¹ $\#B_k = M$, con **selección aleatoria con reemplazo**

Construir el clasificador (e.g., árbol) h_k usando B_k

Problema: correlación entre los h_k

¹Se suele usar $\#B_k = \#T$ pero puede ser distinto.

Bagging (Bootstrap Aggregation)



https://en.wikipedia.org/wiki/Bootstrap_aggregating

Bagging (Bootstrap Aggregation)

Algoritmo Bagging

- 1: Sea K el número de muestras bootstrap
- 2:
- 3: para $k = 1$ a K repetir
- 4: Tomar muestra bootstrap B_k de tamaño M
- 5: Entrenar h_k en B_k
- 6: $h = \Phi(h_1, \dots, h_K)$

La forma de combinar las hipótesis Φ puede ser:

- Promedio, Suma pesada (regresión)
- Voto mayoritario, Voto pesado, Soft-voting (clasificación)

Bagging (Bootstrap Aggregation)

- Mismo algoritmo - diferentes subconjuntos de datos (muestras bootstrap).
- Mejora el desempeño de algoritmos inestables (alta varianza, sobreajuste).
- Out-of-bag samples (OOB)



- En un dataset de tamaño N la probabilidad de un dato dado de ser elegido es

$$\mathbb{P}(\text{elegido}) = 1 - \left(1 - \frac{1}{N}\right)^N \approx 1 - \frac{1}{e} = 0.632$$

Bagging (Bootstrap Aggregation)

Out-of-bag error (OOB error):

- Sea S_{OOB} las instancias que han sido OOB para algún h_k .
- Sea (\mathbf{x}, y) una instancia dada en S_{OOB} .
- Tomar los modelos h_k que no hayan sido entrenados con (\mathbf{x}, y) .
- El error OOB en (\mathbf{x}, y) :
Voto mayoritario/promedio de estos $h_k(\mathbf{x})$ vs. el valor real y .
- El error OOB en S_{OOB} :
Promediar el error OOB de (\mathbf{x}, y) para todas las instancias en S_{OOB} .

Árboles de decisión

Ventajas

- Alto poder *explicativo*
- Representación visual

Desventajas

- Suelen tener menor *exactitud* que otros modelos
- Poco *robustos* o *alta varianza*
 - un pequeño cambio en los datos puede generar un gran cambio en el Árbol

Bajar la varianza ...

Ensemble: Random Forest


Para $k \in \{1, \dots, K\}$

- Construir B_k como en bagging
- Elegir aleatoriamente un conjunto A_k de atributos con $\#A_k \ll \#\text{Atributos}$
- Usualmente $A_k \sim \sqrt{\#\text{Atributos}}$
- Construir el árbol h_k usando B_k y A_k

Generaliza mejor que bagging

Ensemble: Bagging vs RF

- **Heart dataset** (clasificación binaria) $N = 303$ pacientes.
- **Sí** indica la presencia de enfermedad cardíaca.
- **No** significa que no hay enfermedad cardíaca.
- Hay 13 predictores que incluyen **edad**, **sexo**, **colesterol**, etc.




Ensemble: Random Forest y Variable Importance

En los árboles tenemos una manera directa de medir la importancia atributos:

- Cada nodo divide un dataset en base a un atributo.
- Se basa en la impureza (Gini/entropía en clasificación, MSE en regresión).
- Cuánto contribuye un atributo a disminuir la impureza ponderada:
disminución media en las impurezas ponderadas para todos los nodos que se dividieron con dicho atributo.
- En Random Forest promediar la disminución de impurezas sobre los árboles.

Ensemble: Random Forest y Variable Importance



Bibliografía

- An introduction to statistical learning with applications in Python. Cap 8.
- Machine Learning - A First Course for Engineers and Scientists. Capítulo 7.
- Raschka, S. [Introduction to Machine Learning](#). Lecture 7. (2021)
- M. Stamp. Introduction to ML with Applications to Information Security, 7.4 y 7.5.
- Zhi-Hua Zhou. Ensemble Methods: Foundations and Algorithms.