

# Machine Learning para Inteligencia Artificial

Modelos Lineales: Regresión Logística

Universidad ORT Uruguay

28 de Mayo, 2025

# Definiciones preliminares

## Logits

- Si un evento tiene probabilidad  $p$ , su **odds ratio** es  $p/(1 - p)$ .
- Su **logit** o **log-odds** es  $\text{logit}(p) = \ln[\text{odds}] = \ln [p/(1 - p)]$ .



## La función sigmoidea

- $\text{logit} : (0, 1) \rightarrow \mathbb{R}$  es invertible y su inversa es la función **sigmoidea**:

$$\sigma : \mathbb{R} \rightarrow (0, 1)$$
$$\sigma(z) = \text{logit}^{-1}(z) = \frac{1}{1 + \exp(-z)}$$

- Es una forma muy utilizada de **parametrizar probabilidades**.

# Logits y función sigmoidea



# Regresión logística: caso univariado (binario)

- A pesar del nombre **regresión** es un algoritmo de **clasificación**.
- Consiste en **aprender** la probabilidad condicional  $p = \text{Prob}\{y = 1 \mid x\}$ .
- Es un **modelo lineal** en los **logits**:

$$\text{logit}(p) = b + wx = [1, x] \begin{bmatrix} b \\ w \end{bmatrix} = \mathbf{x}^\top \boldsymbol{\theta}, \quad \boldsymbol{\theta} = \begin{bmatrix} b \\ w \end{bmatrix} \in \mathbb{R}^2$$

- De forma equivalente:

$$\text{Prob}\{y = 1 \mid x\} = \sigma(\mathbf{x}^\top \boldsymbol{\theta})$$


- **Clasificador**: Por defecto  $h(\mathbf{x}) = 1$  si y solo si  $\text{Prob}\{y = 1 \mid x\} \geq 1/2$ .

# Función de pérdida

- La función de pérdida es la **Binary Cross-Entropy (BCE)**:

$$\text{BCE}(\hat{p}, y) = \text{Loss}(\hat{p}, y) = -\left[y \ln \{\hat{p}\} + (1 - y) \ln \{1 - \hat{p}\}\right]$$

- **Motivación:** máxima verosimilitud



# Binary Cross Entropy Cost = Neg Log Likelihood

$$\begin{aligned}\text{Cost}_T(\boldsymbol{\theta}) &= \frac{1}{N} \sum_{i=1}^N \text{BCE}(\hat{p}_i, y_i) \\ &= -\frac{1}{N} \sum_{i=1}^N \left[ y_i \ln \{\hat{p}_i\} + (1 - y_i) \ln \{1 - \hat{p}_i\} \right] \\ &= -\frac{1}{N} \sum_{y_i=1} \ln \{\hat{p}_i\} - \frac{1}{N} \sum_{y_i=0} \ln \{1 - \hat{p}_i\}\end{aligned}$$

$$\text{Cost}_T(\boldsymbol{\theta}) = \mathbf{E} \left\{ \underbrace{-\ln \left[ \text{Prob}(y = y_i \mid \mathbf{x}_i) \right]}_{\text{Neg Log Likelihood}} \right\}$$

# Ejemplo: predicción del sexo

Etiqueta

■ Sexo 0: Femenino, 1: Masculino


Atributos

■ Altura (cm)

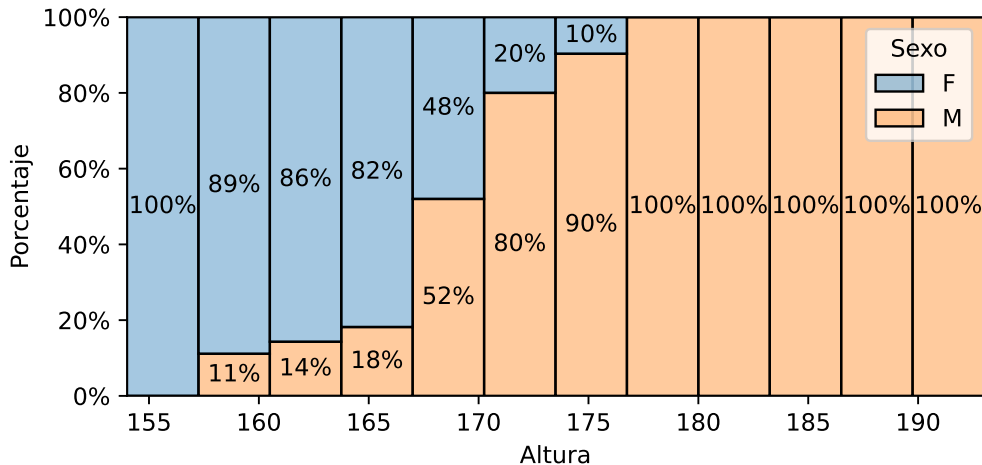
■ Mano (cm)

■ Peso (kg)

Sexo	Altura	Mano	Peso
F	164.0	19.7	56.9
M	177.8	22.5	74.7

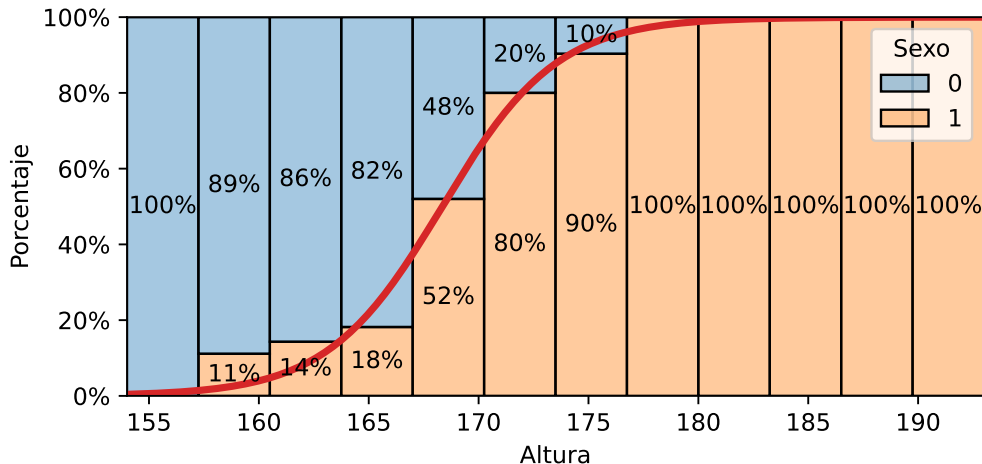


## Ejemplo: proporción en función de Altura

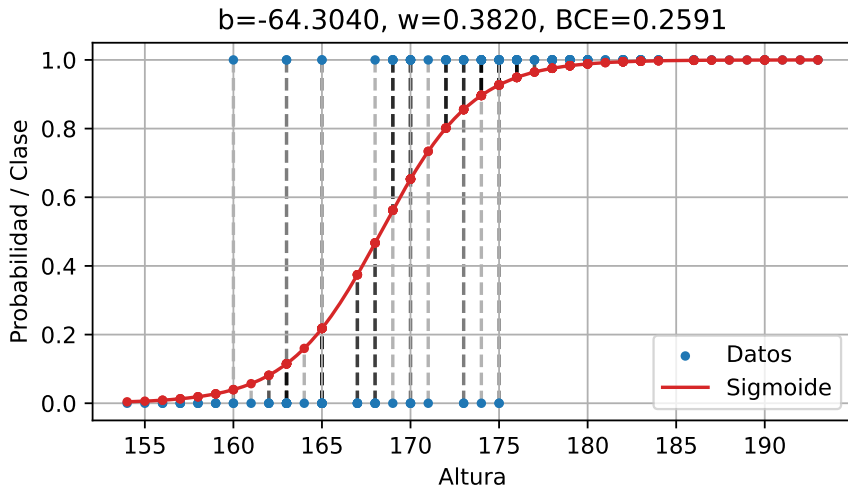




## Ejemplo: aproximamos la proporción con una sigmoide



## Ejemplo: función de pérdida y sigmoide



# Regresión logística: entrenamiento

- Queremos encontrar el  $\theta = [b, w]^T$  que **minimiza** el riesgo empírico:

$$\hat{\theta} = \arg \min_{\theta} \left\{ \text{Cost}_{\mathcal{T}}(\theta) \right\}$$

- A diferencia con Regresión Lineal, **no hay fórmula** para  $\hat{\theta}$ .
- Debe calcularse **numéricamente** con algún algoritmo de optimización.
- En **sklearn** disponemos de los siguientes métodos de optimización:

**lbfgs, liblinear, newton-cg, newton-cholesky, sag, saga**

# Regresión logística: caso multivariado (binario)

■ **Espacio de atributos:**  $\mathcal{X} \subset \mathbb{R}^D$

■ Ahora el modelo es

$$\hat{p} = \sigma(\mathbf{x}^\top \boldsymbol{\theta}) = \frac{1}{1 + e^{-\mathbf{x}^\top \boldsymbol{\theta}}}$$

en donde los vectores  $\mathbf{x}$  y  $\boldsymbol{\theta}$  están dados por

$$\mathbf{x} = \begin{bmatrix} 1 \\ x^{(1)} \\ \vdots \\ x^{(D)} \end{bmatrix} \quad \boldsymbol{\theta} = \begin{bmatrix} b \\ w_1 \\ \vdots \\ w_D \end{bmatrix}$$

# Regresión logística: caso multivariado (binario)

- El producto matricial representa

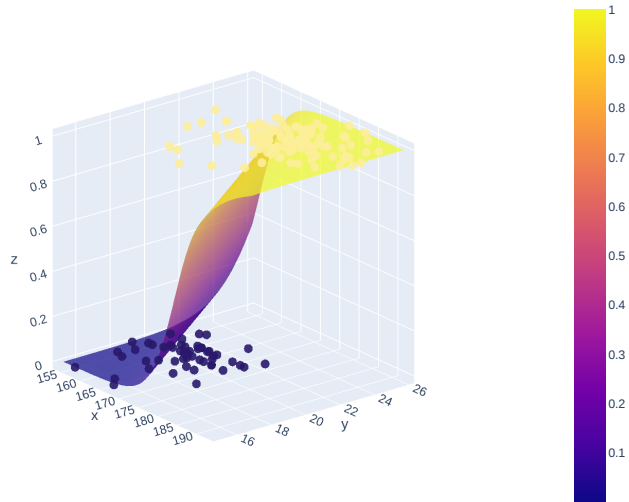
$$\text{logit}(\hat{p}) = \begin{bmatrix} 1 & x^{(1)} & \dots & x^{(D)} \end{bmatrix} \begin{bmatrix} b \\ w_1 \\ \vdots \\ w_D \end{bmatrix} = b + \sum_{j=1}^D w_j x^{(j)}$$

- Considerando la **matriz de diseño** y el **vector de etiquetas** (o targets):

$$\mathbf{X} = \begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_N^\top \end{bmatrix} = \begin{bmatrix} 1 & x_1^{(1)} & \dots & x_1^{(D)} \\ 1 & x_2^{(1)} & \dots & x_2^{(D)} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_N^{(1)} & \dots & x_N^{(D)} \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}$$


- La función de pérdida compara  $\hat{\mathbf{p}} = \sigma(\mathbf{X}\boldsymbol{\theta})$  con  $\mathbf{y}$  al igual que antes.

# Ejemplo: predicción del Sexo (2D)




# Ejemplo: clasificando manzanas y naranjas

id	Peso (g)	PH	Fruta
0	139	3.9	0 (manzana)
1	130	3.0	1 (naranja)
2	170	3.7	0 (manzana)
3	140	3.6	0 (manzana)
4	135	3.1	1 (naranja)
5	150	3.5	0 (manzana)
6	145	2.9	1 (naranja)
7	160	3.2	1 (naranja)
8	155	3.8	0 (manzana)
9	147	3.0	0 (manzana)
10	140	3.3	1 (naranja)
11	160	3.5	1 (naranja)



# Ejemplo: clasificando manzanas y naranjas

La **frontera de decisión** es la curva  $\mathbf{x}^\top \boldsymbol{\theta} = 0$  (o de forma equivalente  $\hat{p} = 1/2$ )





# Regresión logística: funciones base

- El **sesgo inductivo** es

$$\mathcal{H} = \left\{ h_{\theta} : \mathbf{x} \mapsto \sigma \left( b + w_1 h_1(\mathbf{x}) + w_2 h_2(\mathbf{x}) + \cdots + w_K h_K(\mathbf{x}) \right) \right\}$$

- Casos particulares son:

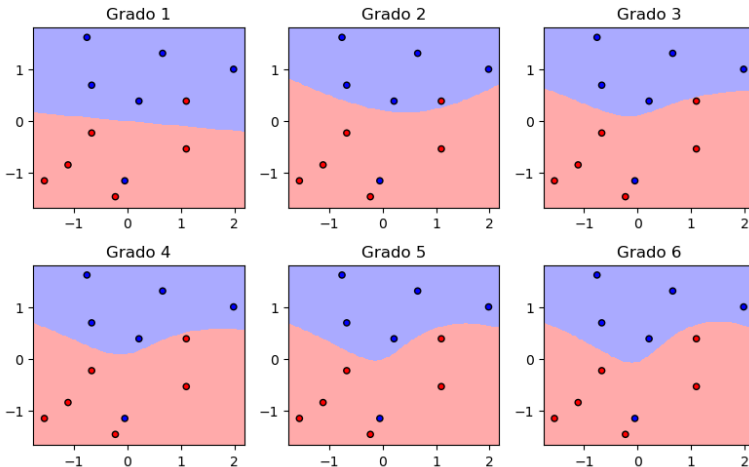
- **Regresión polinomial**: cuando  $h_j(\mathbf{x})$  son productos de potencias  $x^{(j)}$
- **Regresión trigonométrica**: cuando  $h_j(\mathbf{x})$  son funciones trigonométricas

- La relación entre **logit** ( $\hat{p}$ ) y los coeficientes  $\theta = (b, \mathbf{w})$  sigue siendo **lineal**
- Mismo procedimiento al caso multivariado considerando la matriz de diseño:

$$\mathbf{X} = \begin{bmatrix} 1 & h_1(\mathbf{x}_1) & \cdots & h_K(\mathbf{x}_1) \\ \vdots & \vdots & \vdots & \vdots \\ 1 & h_1(\mathbf{x}_N) & \cdots & h_K(\mathbf{x}_N) \end{bmatrix}$$

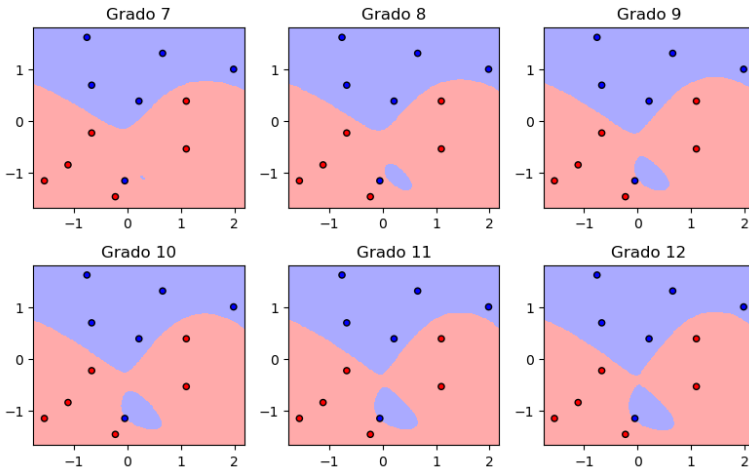
# Ejemplo: clasificando manzanas y naranjas

Fronteras de decisión para grados de 1 a 6



# Ejemplo: clasificando manzanas y naranjas

Fronteras de decisión para grados de 7 a 12



# Bibliografía

- An introduction to statistical learning with applications in Python. Cap 4.2.
- Machine Learning - A First Course for Engineers and Scientists. Capítulo 3.2.