

Machine Learning para Inteligencia Artificial


Gaussian Naive Bayes

Universidad ORT Uruguay


11 de Junio, 2025

Modelo Discriminativo

El modelo intenta aprender $p(y | \mathbf{x})$




Data



$p(y|\mathbf{x})$

$p(\text{blue}|\mathbf{x})$ is high
= certain decision!



$p(\mathbf{x}, y) = p(y|\mathbf{x}) p(\mathbf{x})$

$p(\text{blue}|\mathbf{x})$ is high
and $p(\mathbf{x})$ is low
= uncertain decision!

Modelo Generativo

El modelo intenta aprender $p(\mathbf{x}, y)$
Podemos deducir $p(y | \mathbf{x})$ y $p(\mathbf{x} | y)$

Fórmula de Bayes

- En aprendizaje supervisado se usa Bayes de la siguiente forma:

$$p(\text{target} \mid \text{feature}) = \frac{p(\text{feature} \mid \text{target}) \cdot p(\text{target})}{p(\text{feature})}$$

- En clasificación con $\{c_1, \dots, c_m\}$ clases, concretamente queda:

$$\text{Dado el input } \mathbf{x} \rightsquigarrow p(y = c_i \mid \mathbf{x}) = \frac{p(\mathbf{x} \mid y = c_i)p(y = c_i)}{p(\mathbf{x})}$$

- La marginal de \mathbf{x} se puede calcular usando probabilidad total:

$$p(\mathbf{x}) = \sum_{i=1}^m p(\mathbf{x} \mid y = c_i)p(y = c_i)$$

Prior - Likelihood - Posterior

Basta considerar las siguiente probabilidades:

- **Class Prior:** $p(y = c_i)$

Probabilidad a priori de la clase c_i , antes de observar las features \mathbf{x} .

- **Feature Likelihood:** $p(\mathbf{x} \mid y = c_i)$

Verosimilitud (credibilidad) de las features \mathbf{x} dado que la clase es c_i .

- **Class Posterior:** $p(y = c_i \mid \mathbf{x})$

Probabilidad a posteriori de que la clase sea c_i si observamos las features \mathbf{x} .

Naive Bayes

Dado un conjunto de datos de entrenamiento $T = \{(\mathbf{x}, y)\}$

- **Class Prior**: se estima contando

$$p(y = c_i) = \frac{\#\{(\mathbf{x}, y) \in T : y = c_i\}}{\#T} = \frac{N_i}{N}$$

- **Naive Assumption**: las features son condicionalmente independientes dada una clase:

$$p(\mathbf{x} \mid y = c_i) = p(x^{(1)}, \dots, x^{(D)} \mid y = c_i) = \prod_{k=1}^D p(x^{(k)} \mid y = c_i)$$

- Según sea el caso $p(x^{(k)} \mid y = c_i)$ puede modelarse de diferentes maneras.

Gaussian Naive Bayes

- Se asume que la likelihood de las features es Gaussiana (normal).
- Los parámetros de la Gaussiana para cada clase c_i y se estiman mediante máxima verosimilitud:
 - Media (μ): $\hat{\mu}_{ki} = \frac{1}{N_i} \sum_{(\mathbf{x}, y): y=c_i} x^{(k)}$
 - Varianza (σ^2): $\hat{\sigma}_{ki}^2 = \frac{1}{N_i} \sum_{(\mathbf{x}, y): y=c_i} (x^{(k)} - \hat{\mu}_{ki})^2$
- Recordar que la función de densidad de la Gaussiana es:

$$p(x \mid y = c_i) = \frac{1}{\sqrt{2\pi\sigma_{ki}^2}} \exp\left(-\frac{(x - \mu_{ki})^2}{2\sigma_{ki}^2}\right)$$

donde μ_{ki} y σ_{ki}^2 son la media y varianza de la feature k para la clase c_i .